

TUGAS AKHIR - EF234801

ASESMEN KEPRIBADIAN PADA VIDEO SINGKAT MENGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM

Alief Gilang Permana Putra

NRP 5025221193

Dosen Pembimbing

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

NPP 1987202012004

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026



TUGAS AKHIR - EF234801

ASESMEN KEPRIBADIAN PADA VIDEO SINGKAT MENGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM

Alief Gilang Permana Putra

NRP 5025221193

Dosen Pembimbing

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

NPP 1987202012004

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan



FINAL PROJECT - EF234801

PERSONALITY ASSESSMENT IN SHORT VIDEOS USING A HYBRID APPROACH: BIG FIVE PERSONALITY PREDICTION BASED ON TRANSFORMERS AND DESCRIPTIVE INTERPRETATION BASED ON LLM

Alief Gilang Permana Putra

NRP 5025221193

Advisor

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

NPP 1987202012004

Undergraduate Study Program of Informatics

Department of Informatics

Faculty of Intelligent Electrical and Informatics Technology

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan

LEMBAR PENGESAHAN

ASESMEN KEPERIBADIAN PADA VIDEO SINGKAT MENGGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknik Informatika
Departemen Teknik Informatika
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **ALIEF GILANG PERMANA PUTRA**
NRP. 5025221193

Disetujui oleh Tim Penguji Tugas Akhir:

- | | |
|--|------------|
| 1. Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D. | Pembimbing |
| 2. Dosen Penguji 1 | Penguji |
| 3. Dosen Penguji 2 | Penguji |

SURABAYA
Juni, 2026

Halaman ini sengaja dikosongkan

APPROVAL SHEET

PERSONALITY ASSESSMENT IN SHORT VIDEOS USING A HYBRID APPROACH: BIG FIVE PERSONALITY PREDICTION BASED ON TRANSFORMERS AND DESCRIPTIVE INTERPRETATION BASED ON LLM

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a Bachelor of Computer Science degree at
Undergraduate Study Program of Informatics
Department of Informatics
Faculty of Intelligent Electrical and Informatics Technology
Institut Teknologi Sepuluh Nopember

By: **ALIEF GILANG PERMANA PUTRA**

NRP. 5025221193

Approved by Final Project Examiner Team:

1. Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

Advisor

2. Dosen Penguji 1

Examiner 1

3. Dosen Penguji 2

Examiner 2

SURABAYA

June, 2026

Halaman ini sengaja dikosongkan

PERNYATAAN ORISINALITAS

Yang bertanda tangan dibawah ini:

Nama Mahasiswa / NRP : Alief Gilang Permana Putra / 5025221193
Departemen : Teknik Informatika
Dosen Pembimbing / NPP : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D. /
1987202012004

dengan ini menyatakan bahwa Tugas Akhir dengan judul "ASESMEN KEPERIBADIAN PADA VIDEO SINGKAT MENGGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Mengetahui
Dosen Pembimbing

Surabaya, Juni 2026
Mahasiswa

**Shintami Chusnul Hidayati, S.Kom.,
M.Sc., Ph.D.**
NPP. 1987202012004

Alief Gilang Permana Putra
NRP. 5025221193

Halaman ini sengaja dikosongkan

STATEMENT OF ORIGINALITY

The undersigned:

Student Name / Student ID : Alief Gilang Permana Putra / 5025221193
Study Program : Bachelor of Informatics
Advisor / Employee ID : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D. /
1987202012004

hereby declares that the Final Project entitled "PERSONALITY ASSESSMENT IN SHORT VIDEOS USING A HYBRID APPROACH: BIG FIVE PERSONALITY PREDICTION BASED ON TRANSFORMERS AND DESCRIPTIVE INTERPRETATION BASED ON LLM" is my own work, is original, and was written in accordance with the rules of scientific writing. If any discrepancies with this statement are found in the future, I am willing to accept sanctions in accordance with the provisions of Institut Teknologi Sepuluh Nopember.

Acknowledged
Advisor

Surabaya, June 2026
Student

**Shintami Chusnul Hidayati, S.Kom.,
M.Sc., Ph.D.**
NPP. 1987202012004

Alief Gilang Permana Putra
NRP. 5025221193

Halaman ini sengaja dikosongkan

PERNYATAAN KODE ETIK
PENGUNAAN AI GENERATIF
Code of Conduct Statement: Generative AI or AI-Assisted Usage

Saya yang bertanda tangan di bawah ini:

I, the undersigned:

Nama Mahasiswa / NRP : Alief Gilang Permana Putra / 5025221193

Full Name / Student ID

Program Studi : S-1 Teknik Informatika

Study Program

Judul Tugas Akhir : ASESMEN KEPERIBADIAN PADA VIDEO SINGKAT
MENGGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI
BIG FIVE PERSONALITY BERBASIS TRANSFORMER
DAN INTERPRETASI DESKRIPTIF BERBASIS LLM

Final Project Title

dengan ini menyatakan bahwa pada Tugas Akhir dengan judul di atas tersebut:

hereby declare that in the Final Project with the above title:

No.	Pernyataan <i>Statement</i>	(✓)
1	Saya hanya menggunakan AI generatif sebagai alat bantu untuk memperbaiki tata bahasa. AI generatif tidak digunakan untuk membuat isi Tugas Akhir. <i>I only used generative AI as a tool to improve the readability or language of the text in my Final Project. It was not used to generate a complete text of my work.</i>	✓
2	Saya telah memeriksa dan/atau memperbaiki seluruh bagian dari Tugas Akhir saya yang dibantu oleh AI generatif agar sesuai dengan baku mutu penulisan karya ilmiah. <i>I have reviewed and refined all aspects of my work that generative AI assists with, ensuring it adheres to the standards of academic writing.</i>	✓
3	Saya tidak menggunakan AI generatif untuk pembuatan data primer, grafik dan/atau tabel pada Tugas Akhir saya. <i>I did not use generative AI to generate primary data, figures, and/or tables in my work.</i>	✓
4	Saya telah memberikan atribusi/pengakuan terhadap alat AI yang digunakan, secara rinci pada suatu bagian pada lampiran. <i>I have acknowledged the use of generative AI in any part of the work in the specific appendix page.</i>	✓
5	Saya memastikan tidak ada plagiarisme, termasuk hal yang berasal dari penggunaan AI generatif. <i>I have ensured that there is no plagiarism issue in the work, including any parts generated by AI.</i>	✓

Surabaya, Juni 2026
Mahasiswa

Alief Gilang Permana Putra
NRP. 5025221193

Halaman ini sengaja dikosongkan

ABSTRAK

ASESMEN KEPERIBADIAN PADA VIDEO SINGKAT MENGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM

Nama Mahasiswa / NRP : Alief Gilang Permana Putra / 5025221193
Departemen : Teknik Informatika
Dosen Pembimbing : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

Abstrak

Penilaian kepribadian tradisional berbasis kuesioner sering kali rentan terhadap bias subjektivitas dan pemalsuan respons. Meskipun teknologi kecerdasan buatan telah memungkinkan prediksi kepribadian secara otomatis berdasarkan data visual, hasil keluaran yang diberikan umumnya masih berupa skor numerik kontinu yang sulit dipahami secara kualitatif oleh pengguna awam. Penelitian ini mengusulkan sistem asesmen kepribadian hibrida pada potongan video singkat dengan menggabungkan model regresi Transformer untuk memprediksi skor Big Five Personality dan Large Language Model (LLM) untuk menghasilkan interpretasi profil kepribadian yang deskriptif. Metodologi penelitian mencakup ekstraksi *frame* gambar dari dataset *ChaLearn First Impression*, yang kemudian diproses menggunakan berbagai varian model Transformer (ViT, SwinV2, PVTv2) dengan modifikasi *custom regression head* yang terdiri dari lapisan linear, fungsi aktivasi GELU, *dropout*, dan sigmoid. Hasil prediksi regresi selanjutnya diintegrasikan ke dalam LLM melalui teknik *prompt engineering multimodal* dengan menerapkan skenario *standard prompting* dan *roleplay prompting*. Hasil eksperimen menunjukkan bahwa arsitektur ViT-B/16 AugReg (IN21k) dengan penerapan skenario *arch tuning* beserta augmentasi merupakan model prediksi regresi terbaik, dengan tingkat akurasi mencapai 0,911 dan nilai *coefficient of determination* (R^2) sebesar 0,416. Pada tahap interpretasi teks yang dievaluasi menggunakan metrik G-Eval, penelitian ini mengimplementasikan pendekatan dua model alternatif. Model Qwen3-VL-32B-Instruct ditetapkan sebagai LLM utama yang meraih skor keseluruhan tertinggi (0,9136) dengan narasi persona psikolog yang kuat, sedangkan model Gemma-4-31B-IT ditetapkan sebagai alternatif dengan keunggulan pada akurasi psikologis (0,9566) dan kedisiplinan format *output*.

Kata Kunci: Asesmen Kepribadian, Big Five Personality, ChaLearn, Large Language Model, Transformer.

Halaman ini sengaja dikosongkan

ABSTRACT

PERSONALITY ASSESSMENT IN SHORT VIDEOS USING A HYBRID APPROACH: BIG FIVE PERSONALITY PREDICTION BASED ON TRANSFORMERS AND DESCRIPTIVE INTERPRETATION BASED ON LLM

Name / NRP : Alief Gilang Permana Putra / 5025221193
Department : Informatics
Advisors : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

Abstract

Traditional questionnaire-based personality assessments are often prone to subjectivity and response falsification. Although artificial intelligence technology has enabled automated personality predictions based on visual data, the output is generally still in the form of continuous numerical scores that are difficult for lay users to interpret qualitatively. This study proposes a hybrid personality assessment system for short video clips by combining a Transformer regression model to predict Big Five Personality scores and a Large Language Model (LLM) to generate descriptive interpretations of personality profiles. The research methodology involves extracting image frames from the ChaLearn First Impression dataset, which are then processed using various variants of the Transformer model (ViT, SwinV2, PVTv2) with a custom regression head consisting of a linear layer, the GELU activation function, dropout, and a sigmoid function. The regression prediction results were then integrated into the LLM via multimodal prompt engineering techniques, applying both standard prompting and roleplay prompting scenarios. The experimental results show that the ViT-B/16 AugReg (IN21k) architecture, with the implementation of arch tuning and data augmentation, is the best regression prediction model, achieving an accuracy of 0.911 and a coefficient of determination (R^2) of 0.416. In the text interpretation stage, which was evaluated using the G-Eval metric, this study implemented two alternative model approaches. The Qwen3-VL-32B-Instruct model was identified as the primary LLM, achieving the highest overall score (0.9136) with a strong psychologist persona narrative, while the Gemma-4-31B-IT model was identified as the alternative, excelling in psychological accuracy (0.9566) and output format consistency.

Keywords: Big Five Personality, ChaLearn, Large Language Model, Personality Assessment, Transformer.

Halaman ini sengaja dikosongkan

KATA PENGANTAR

Puji dan syukur kehadiran Allah SWT atas rahmat dan karunia -Nya penulis dapat menyelesaikan tugas akhir ini dengan judul "ASESMEN KEPRIBADIAN PADA VIDEO SINGKAT MENGGUNAKAN PENDEKATAN HIBRIDA: PREDIKSI BIG FIVE PERSONALITY BERBASIS TRANSFORMER DAN INTERPRETASI DESKRIPTIF BERBASIS LLM" dengan baik. Tugas akhir ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi S-1 Teknik Informatika, Departemen Teknik Informatika, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember.

Penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada semua pihak yang telah memberikan dukungan, baik secara langsung maupun tidak langsung selama proses penyusunan tugas akhir ini kepada:

1. Allah SWT atas segala kemudahan, kekuatan, kesehatan, dan kesempatan yang diberikan selama proses perkuliahan hingga penyusunan tugas akhir ini.
2. Ibu, Bapak, Saudara, dan Keluarga yang memberikan dukungan doa, moral, maupun material yang tak ternilai besarnya.
3. Ibu Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D., selaku dosen pembimbing, atas bimbingan, arahan, dan ilmu yang diberikan selama proses penyusunan tugas akhir ini.
4. Bapak/Ibu Dosen Penguji atas masukan, kritik, dan saran yang diberikan dalam proses penyempurnaan buku tugas akhir ini.
5. Ivan, Daffa, Alfi, dan Dwipa yang memberikan semangat, dukungan, serta motivasi dalam menyelesaikan tugas akhir ini.
6. Teman-teman dalam grup TCFiesta yang memberikan dukungan dalam bentuk diskusi dan motivasi dalam proses penyusunan tugas akhir ini.
7. Teman-teman angkatan 2022 Departemen Teknik Informatika ITS yang telah berjuang bersama penulis selama menempuh masa studi di Teknik Informatika ITS.
8. Serta semua pihak yang turut membantu penulis dalam menyelesaikan tugas akhir yang tidak dapat disebutkan satu per satu.

Akhir kata, penulis menyadari bahwa tugas akhir ini jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan penulis untuk perbaikan dan pengembangan penelitian di masa mendatang.

Surabaya, Juni 2026

Alief Gilang Permana Putra

Halaman ini sengaja dikosongkan

DAFTAR ISI

LEMBAR PENGESAHAN	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
PERNYATAAN KODE ETIK PENGGUNAAN AI GENERATIF	ix
ABSTRAK	xi
ABSTRACT	xiii
KATA PENGANTAR	xv
DAFTAR ISI	xvii
DAFTAR GAMBAR	xix
DAFTAR TABEL	xxi
DAFTAR KODE SEMU	xxiii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	2
1.4 Tujuan	3
1.5 Manfaat	3
1.5.1 Manfaat Teoritis	3
1.5.2 Manfaat Praktis	3
1.5.3 Manfaat Sosial	4
BAB 2 TINJAUAN PUSTAKA	5
2.1 Hasil Penelitian Terdahulu	5
2.2 Dasar Teori	7
2.2.1 <i>Big Five Personality</i>	7
2.2.2 <i>ChaLearn First Impressions</i>	8
2.2.3 <i>Deep Learning</i>	9
2.2.4 Deteksi dan Ekstraksi Wajah	10
2.2.5 Transformer	10
2.2.6 Vision Transformer (ViT)	12
2.2.7 Swin Transformer	12
2.2.8 Pyramid Vision Transformer (PVT)	14

2.2.9	<i>Large Language Model</i>	16
2.2.10	<i>Prompt Engineering</i>	17
2.2.11	Gemma	18
2.2.12	Qwen-VL	18
2.2.13	Metrik Evaluasi	19
BAB 3	METODOLOGI	23
3.1	Metode yang digunakan	23
3.1.1	Praproses Dataset Video menjadi Gambar	23
3.1.2	Arsitektur Model Regresi Transformer	24
3.1.3	Mekanisme Prediksi dan Pelatihan Model Kepribadian <i>Big Five</i>	25
3.1.4	Perancangan <i>Prompt</i> Interpretasi Kepribadian	26
3.1.5	Integrasi LLM untuk Interpretasi Kepribadian	27
3.1.6	Perancangan Sistem Asesmen Interpretasi Kepribadian	28
3.1.7	Skenario Evaluasi	30
3.2	Bahan dan Peralatan yang Digunakan	33
3.3	Urutan Pelaksanaan Penelitian	34
3.3.1	Implementasi Praproses Dataset	34
3.3.2	Implementasi Alur Pelatihan Model	36
3.3.3	Implementasi Sistem Asesmen Kepribadian	37
3.3.4	Implementasi Alur Evaluasi Sistem Asesmen	39
BAB 4	HASIL DAN PEMBAHASAN	43
4.1	Hasil Penelitian	43
4.1.1	Hasil Transformasi Dataset Video Menjadi Gambar	43
4.1.2	Hasil Praproses Dataset	45
4.1.3	Hasil Pelatihan Model Prediksi Kepribadian	47
4.1.4	Hasil Interpretasi Kepribadian	50
4.2	Pembahasan	54
4.2.1	Evaluasi Model Prediksi Kepribadian	54
4.2.2	Evaluasi Kualitas Interpretasi Kepribadian	59
BAB 5	KESIMPULAN DAN SARAN	65
5.1	Kesimpulan	65
5.2	Saran	66
	DAFTAR PUSTAKA	67
	BIOGRAFI PENULIS	73

DAFTAR GAMBAR

Gambar 2.1	Cuplikan Video dengan Label pada Dataset ChaLearn	8
Gambar 2.2	Representasi Model Matematika Neuron Buatan (<i>Perceptron</i>) (Sarker, 2021)	9
Gambar 2.3	Arsitektur Transformer (Vaswani dkk., 2023)	11
Gambar 2.4	Arsitektur Vision Transformer (Dosovitskiy dkk., 2021)	12
Gambar 2.5	Perbedaan Arsitektur Swin Transformer dengan ViT (Z. Liu dkk., 2021)	13
Gambar 2.6	Arsitektur Swin Transformer (Z. Liu dkk., 2021)	13
Gambar 2.7	Perbedaan Swin Transformer V2 dengan V1 (Z. Liu dkk., 2022)	14
Gambar 2.8	Arsitektur Piramida pada PVT (W. Wang dkk., 2021)	15
Gambar 2.9	Perbandingan Mekanisme SRA pada PVT v1 dan <i>Linear</i> SRA pada PVT v2 (W. Wang dkk., 2023)	15
Gambar 2.10	Mekanisme <i>Overlapping Patch Embedding</i> dan <i>Convolutional Feed-Forward Network</i> (W. Wang dkk., 2023)	16
Gambar 2.11	Kerangka Kerja G-Eval (Confident AI, 2025)	21
Gambar 3.1	Diagram Alir Penelitian	23
Gambar 3.2	Diagram Alir Praproses Dataset	23
Gambar 3.3	Arsitektur Model Transformer untuk Regresi <i>Multi Target</i>	24
Gambar 3.4	Proses Prediksi dan Pelatihan Model Prediksi Kepribadian <i>Big Five</i>	25
Gambar 3.5	Rancangan Struktur Prompt dengan Injeksi Konteks Multimodal	26
Gambar 3.6	Diagram Alir Proses Interpretasi Kepribadian dengan LLM	27
Gambar 3.7	Diagram Alir Sistem Interpretasi Kepribadian	28
Gambar 3.8	<i>Wireframe</i> Tampilan Inferensi	29
Gambar 3.9	<i>Wireframe</i> Tampilan Interpretasi	30
Gambar 4.1	Perbandingan Nilai <i>traits</i> pada <i>Split</i> Dataset (<i>Train, Validation, Test</i>)	44
Gambar 4.2	Proses Transformasi Dataset Video Menjadi Gambar	45
Gambar 4.3	Contoh Sampel Gambar pada Dataset dengan Skor Kepribadian <i>Big Five</i>	46
Gambar 4.4	Tahap Praproses Gambar dengan Augmentasi	47
Gambar 4.5	Grafik Pelatihan Setiap Model pada Setiap Skenario	48
Gambar 4.6	Metrik Kinerja Terbaik Model pada Proses Pelatihan	49
Gambar 4.7	Contoh Hasil Interpretasi Kepribadian pada Antarmuka Pengguna	51
Gambar 4.8	Contoh Hasil Interpretasi Kepribadian pada Model Gemma4	52
Gambar 4.9	Contoh Hasil Interpretasi Kepribadian pada Model Qwen3-VL	53
Gambar 4.10	Metrik Kinerja Model pada Dataset <i>Test</i>	54
Gambar 4.11	Hasil Prediksi Model dengan Skenario <i>Arch Tuning + Augmentation</i> pada beberapa Sampel <i>Test</i>	59

Halaman ini sengaja dikosongkan

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu	5
Tabel 3.1 Daftar Model Transformer <i>Pretrained</i> yang Diujikan	31
Tabel 3.2 Konfigurasi <i>Hyperparameter</i> Pelatihan Model Prediksi Kepribadian	31
Tabel 3.3 Daftar Skenario Model Prediksi yang Diujikan	32
Tabel 3.4 Kriteria Evaluasi Teks Interpretasi Kepribadian dengan G-Eval	33
Tabel 4.1 Statistik Dataset (Train, Validation, Test)	43
Tabel 4.2 Perbandingan Akurasi Model Prediksi Kepribadian pada Berbagai Skenario	55
Tabel 4.3 Perbandingan Nilai R^2 Model Prediksi Kepribadian pada Berbagai Skenario	57
Tabel 4.4 Hasil Evaluasi Metrik Interpretasi Kepribadian G-Eval pada Berbagai Skenario	61

Halaman ini sengaja dikosongkan

DAFTAR KODE SEMU

Kode Semu 3.1 Implementasi Praproses Dataset dari Video menjadi Gambar	35
Kode Semu 3.2 Pemberian Label dan Upload Dataset ke HuggingFace	35
Kode Semu 3.3 Implementasi Pengubahan Ukuran Gambar, Augmentasi, dan Normalisasi	36
Kode Semu 3.4 Proses Pelatihan Model Prediksi Kepribadian dengan Berbagai Skenario	37
Kode Semu 3.5 Alur Utama API Inferensi Prediksi Kepribadian <i>Big Five</i>	38
Kode Semu 3.6 Alur Utama API Interpretasi Kepribadian	39
Kode Semu 3.7 Alur Evaluasi dan Pemilihan Model Prediksi Regresi <i>Big Five</i> Terbaik	40
Kode Semu 3.8 Alur Evaluasi Hasil Interpretasi Kepribadian Menggunakan G-Eval .	41

Halaman ini sengaja dikosongkan

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kepribadian merupakan salah satu aspek krusial yang membentuk identitas dan perilaku manusia. Kepribadian dapat didefinisikan sebagai karakteristik dan perilaku abadi yang membentuk cara hidup suatu individu yang mencakup sifat, minat, dorongan, nilai-nilai, konsep diri, bakat, dan pola emosional. Kepribadian dapat dipengaruhi oleh berbagai faktor antara lain genetik, pendidikan usia dini, budaya, pengalaman, dan hubungan dengan individu lain. Berbagai penelitian mengenai struktur dan perkembangan kepribadian menyimpulkan bahwa perilaku suatu individu dipengaruhi oleh kepribadian (American Psychological Association, 2018). Oleh sebab itu, identifikasi sifat-sifat kepribadian memiliki banyak manfaat terutama untuk memahami karakteristik sifat individu yang memengaruhi kehidupan sehari-hari, seperti preferensi, keinginan, dan pilihan hidup (Ilmini & Fernando, 2024).

Salah satu cara untuk mengidentifikasi kepribadian seseorang adalah dengan melakukan tes kepribadian. Tes ini merupakan proses asesmen penting dalam psikologi yang bertujuan untuk mengukur karakteristik individu yang mencerminkan kecenderungan untuk bertindak, merasa, berpikir, dan berinteraksi (Krishnamurthy dkk., 2022). Saat ini, model kepribadian yang populer digunakan untuk mengukur kepribadian seseorang adalah *Big Five Personality* atau biasanya disingkat OCEAN (*openness, conscientiousness, extraversion, agreeableness, neuroticism*) (Ilmini & Fernando, 2024; Suman dkk., 2022). Penelitian sebelumnya menunjukkan model OCEAN telah digunakan pada tes kepribadian berbasis kuisioner IPIP-NEO-120 dan *Brown and Taylor's short 15-item personality test* (Bose dkk., 2023; Hilliard dkk., 2022).

Meskipun tes kepribadian berbasis kuisioner memiliki dasar yang kuat dan validitas yang tinggi pada penelitian psikometri, metode ini memiliki kelemahan dalam praktiknya terutama pada konteks dengan risiko tinggi seperti rekrutmen atau seleksi karyawan (Hilliard dkk., 2022). Salah satu kelemahan utama adalah ketergantungan pada kejujuran dan kemampuan individu untuk memberikan penilaian sendiri (*self-assessment*) secara akurat (Tavakol & Dennick, 2021). Responden cenderung melakukan taktik manajemen impresi atau bahkan melakukan pemalsuan respons (*faking*) untuk menampilkan kepribadian ideal dan mengesankan yang mengakibatkan inflasi skor kepribadian (Hilliard dkk., 2022; Krishnamurthy dkk., 2022). Hal tersebut menyebabkan hasil tes kepribadian cenderung bias dan sangat bervariasi (Ponce-López dkk., 2016). Tantangan dan keterbatasan dalam objektivitas penilaian kepribadian sejati (*real personality traits*) membuat fokus penelitian mengenai kepribadian bergeser menuju identifikasi kepribadian yang tampak (*apparent personality*). Berbeda dengan kepribadian sejati, penilaian kepribadian yang tampak didasarkan pada persepsi orang lain terhadap perilaku dan penampilan fisik suatu individu (Ilmini & Fernando, 2024).

Seiring dengan kemajuan teknologi *Artificial Intelligence* (AI) mendorong perkembangan asesmen kepribadian otomatis/*automatic personality assesment* menggunakan metode *deep learning* yang dapat menganalisis berbagai modalitas data seperti teks, audio, gambar, dan video. Selain itu, perkembangan teknik ekstraksi data ciri-ciri kepribadian personal melalui media teknologi informasi seperti media sosial, ponsel genggam, video kamera, dan jam pintar memungkinkan untuk memprediksi kepribadian seseorang secara objektif berdasarkan informasi yang didapatkan dari mesin (*machine-sensed information*) seperti tulisan, jejak digital, penggunaan

ponsel, perilaku non-verbal, pola bicara, dan lain sebagainya tanpa memerlukan keterlibatan aktif dari individu sehingga dapat menghasilkan performa prediksi yang tinggi serta mengurangi risiko bias subjektif (Phan & Rauthmann, 2021; Shui dkk., 2023). Meskipun penelitian mengenai asesmen kepribadian otomatis mulai populer dan telah menghasilkan akurasi prediksi yang tinggi, fokus penelitian masih terpusat pada prediksi nilai numerik model kepribadian seperti *Big Five* berupa nilai kontinu dalam rentang 0 hingga 1 (Suman dkk., 2022). Hasil prediksi berupa skor regresi yang abstrak kurang memberikan pemahaman kualitatif atau kontekstual bagi pengguna awam (Ilmini & Fernando, 2024). Oleh karena itu, diperlukan sebuah sistem asesmen kepribadian yang tidak hanya memprediksi skor kepribadian, tetapi juga dapat memberikan interpretasi deskriptif berdasarkan prediksi nilai kepribadian sehingga dapat dipahami oleh semua orang.

Perkembangan *Large Language Model* (LLM) serta arsitektur Transformer pada teknologi *deep learning* yang menjadi fundamental bagi LLM membuka peluang lebih luas untuk pengembangan metode baru dalam asesmen psikologis, terutama dalam ranah *automatic personality prediction* dengan memfasilitasi, meningkatkan, dan mengintegrasikan asesmen psikologi berbasis multimetode yang sebelumnya jarang digunakan karena sangat sulit dan memakan banyak waktu (Brickman dkk., 2025). Keunggulan LLM dalam pemahaman kontekstual dan melakukan tugas pengolahan bahasa alami/*natural language processing* (NLP) membuat LLM menjadi solusi dalam mengatasi masalah utama yang diidentifikasi pada penelitian *automatic personality prediction* sebelumnya, yaitu kurangnya interpretasi kualitatif dari hasil prediksi model yang hanya berupa nilai numerik kontinu (Feizi-Derakhshi dkk., 2022). Keterbatasan ini menyebabkan hasil prediksi kepribadian menjadi kotak hitam (*black box*) yang tidak transparan dan sulit diinterpretasi oleh pengguna akhir/*end user* (Brickman dkk., 2025; Naz dkk., 2025). Oleh karena itu, diusulkan penelitian menggunakan pendekatan hibrida untuk melakukan dua jenis tugas utama, yaitu prediksi kepribadian *Big Five* menggunakan model *deep-learning* berbasis Transformer dan melakukan interpretasi deskriptif kepribadian seseorang berdasarkan video singkat dan nilai prediksi *Big Five* yang dihasilkan dengan memanfaatkan LLM. Integrasi ini bertujuan untuk menghasilkan laporan asesmen kepribadian yang lebih transparan, komprehensif, dan mudah dipahami oleh semua orang sehingga diharapkan dapat menunjukkan kemampuan penerapan praktis model prediksi kepribadian otomatis di dunia nyata.

1.2 Rumusan Masalah

Berdasarkan hal yang telah dipaparkan di latar belakang, diperlukan sistem asesmen kepribadian otomatis yang dapat memberikan interpretasi deskriptif. Rumusan masalah dalam tugas akhir ini adalah:

1. Bagaimana cara mengimplementasikan model regresi berbasis arsitektur Transformer untuk memprediksi skor kepribadian *Big Five* secara akurat berdasarkan input dari potongan video singkat?
2. Bagaimana cara mengintegrasikan hasil prediksi model regresi ke dalam LLM melalui perancangan *prompt* yang mengolah hasil prediksi nilai numerik dan data visual dari potongan video singkat untuk menghasilkan interpretasi kepribadian deskriptif?
3. Bagaimana kinerja sistem asesmen kepribadian hibrida yang dibangun ditinjau dari tingkat akurasi prediksi model dan kualitas narasi interpretasi yang dihasilkan?

1.3 Batasan Masalah

Terdapat beberapa batasan yang ditentukan untuk membatasi ruang lingkup penelitian sehingga studi yang dilakukan menjadi lebih terarah dan sesuai dengan tujuan yang ditentukan.

Batasan masalah yang ditentukan adalah sebagai berikut:

1. Penelitian ini menggunakan dataset *ChaLearn First Impression* (Ponce-López dkk., 2016) yang terdiri dari 10000 klip video dengan durasi rata-rata 15 detik. Proses pengolahan data dilakukan dengan mengekstraksi sejumlah *frame* (sampel gambar) dari video untuk dianalisis sebagai data visual statis.
2. Penelitian ini hanya menggunakan modalitas visual (*image frame*). Data modalitas lain seperti suara dan transkripsi teks yang terdapat pada dataset asli tidak digunakan dalam proses prediksi model.
3. Pengembangan model prediksi dibatasi pada penggunaan arsitektur berbasis Transformer atau *hybrid Transformer* untuk tugas regresi nilai kepribadian *Big Five*.
4. Sistem interpretasi memanfaatkan LLM multimodal yang sudah dilatih sebelumnya (*pre-trained*) melalui *Application Programming Interface* (API) atau pustaka sumber terbuka (*open source library*). Penelitian ini berfokus pada perancangan *prompt* (*prompt engineering*) dan tidak melakukan pelatihan ulang/*fine-tuning* pada struktur internal LLM tersebut.
5. Hasil akhir sistem berupa skor prediksi kepribadian *Big Five* dan narasi interpretasi deskriptif yang berfungsi sebagai alat bantu asesmen awal (*screening*), bukan merupakan diagnosis psikologis klinis yang menggantikan peran psikolog profesional.

1.4 Tujuan

Penelitian ini bertujuan untuk mengembangkan asesmen kepribadian otomatis berdasarkan perilaku yang dapat diamati pada potongan video pendek. Adapun tujuan spesifik dari penelitian ini adalah sebagai berikut:

1. Mengimplementasikan model regresi berbasis arsitektur Transformer untuk memprediksi skor kepribadian Big Five secara akurat berdasarkan input dari potongan video singkat.
2. Mengintegrasikan hasil prediksi model regresi ke dalam LLM melalui perancangan prompt yang mengolah hasil prediksi nilai numerik dan data visual dari potongan video singkat untuk menghasilkan interpretasi kepribadian deskriptif.
3. Menilai kinerja sistem asesmen kepribadian hibrida yang dibangun ditinjau dari tingkat akurasi prediksi model dan kualitas narasi interpretasi yang dihasilkan.

1.5 Manfaat

Penelitian tugas akhir ini diharapkan dapat memberikan berbagai manfaat, baik secara teoritis maupun praktis. Manfaat dari penelitian ini adalah sebagai berikut:

1.5.1 Manfaat Teoritis

1. Penelitian ini memberikan kontribusi teoretis pada bidang *Explainable AI* (XAI) dalam psikologi dengan menawarkan solusi pendekatan hibrida untuk mengatasi keterbatasan dalam menjelaskan alasan di balik hasil prediksi kepribadian yang dihasilkan oleh model *deep learning*.
2. Studi ini memperkaya literatur mengenai efektivitas strategi integrasi antara model regresi visual dan LLM melalui teknik prompt engineering multimodal untuk memahami perilaku manusia dari data video yang terbatas.

1.5.2 Manfaat Praktis

1. Sistem yang dikembangkan dapat memberikan manfaat bagi perekrut sebagai alat bantu seleksi awal yang efisien karena mampu menyajikan profil kepribadian kandidat secara lebih cepat dan deskriptif dibandingkan metode manual.

2. Sistem ini dapat diterapkan dalam bidang pendidikan dan bimbingan karir untuk membantu konselor akademik dalam mengarahkan siswa atau pencari kerja memilih jalur studi dan profesi yang paling sesuai dengan potensi kepribadian mereka.
3. Hasil penelitian ini dapat menjadi landasan teknis bagi pengembang perangkat lunak dalam menciptakan aplikasi pelatihan wawancara atau pengembangan diri yang mampu memberikan umpan balik otomatis dan personal kepada pengguna.

1.5.3 Manfaat Sosial

1. Penelitian ini berpotensi membuka akses yang lebih luas bagi masyarakat umum untuk melakukan asesmen mandiri dan memahami karakteristik kepribadian mereka secara objektif melalui teknologi dengan biaya yang terjangkau.
2. Penerapan teknologi ini dapat membantu mengurangi dampak bias subjektif manusia pada penilaian kesan pertama (*first impression*) dengan menyediakan opini pembandingan yang konsisten dan berbasis data.

BAB II

TINJAUAN PUSTAKA

Bab ini membahas mengenai literatur dan hasil penelitian sebelumnya yang berkaitan dengan topik tugas akhir yang dikerjakan serta menjelaskan teori-teori dasar yang digunakan dalam penyusunan tugas akhir ini.

2.1 Hasil Penelitian Terdahulu

Pada subbab ini, akan dibahas mengenai hasil penelitian-penelitian terdahulu yang relevan dengan topik penelitian ini. Hasil berbagai penelitian tersebut digunakan sebagai sumber informasi dan acuan pengembangan metode. Ulasan mengenai perbandingan metode, modalitas, serta kinerja yang dihasilkan oleh studi-studi tersebut dirangkum secara ringkas dalam Tabel 2.1.

Tabel 2.1: Penelitian Terdahulu

Judul	Fokus Utama Penelitian	Modalitas	Perbedaan dengan Tugas Akhir yang Diusulkan
<i>A multi-modal personality prediction system</i> (Suman dkk., 2022)	Mengembangkan sistem prediksi kepribadian multimodal menggunakan arsitektur CNN tradisional (ResNet, MTCNN, VGGish CNN) dan teknik <i>early fusion</i> . Fusi fitur <i>concatenation</i> yang diekstrak dari berbagai modalitas menghasilkan kinerja yang sebanding dengan metode rata-rata prediksi <i>late fusion</i> .	Gambar, audio, dan teks anotasi dari dataset ChaLearn (Ponce-López dkk., 2016).	Tugas akhir ini menggunakan arsitektur Transformer untuk prediksi kepribadian dengan modalitas gambar dan fokus utama pada interpretasi deskriptif berbasis LLM.
<i>A Systematic Approach for the Prediction of Personality Based on Attention Enhanced GCNN and LSTM Approach</i> (Sharma dkk., 2023)	Mengembangkan sistem prediksi kepribadian berbasis teks menggunakan AGCNN-LSTM untuk mengatasi kekurangan dari algoritma <i>deep learning</i> yang ada seperti CNN dan LSTM dalam hal kecepatan pelatihan dan kemampuan menangkap makna semantik.	Konten tekstual dari unggahan media sosial (tf-idf).	Tugas akhir ini menggunakan arsitektur Transformer dengan modalitas gambar yang bisa menangkap konteks global yang lebih luas menggunakan mekanisme <i>self-attention</i> .

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 2.1

Judul	Fokus Utama Penelitian	Modalitas	Perbedaan dengan Tugas Akhir yang Diusulkan
<i>PersonaLLM: Investigating the Ability of Large Language Models to Express Personality Traits</i> (Jiang dkk., 2024)	Menginvestigasi kemampuan LLM (GPT-3.5 dan GPT-4) untuk secara akurat dan konsisten merefleksikan profil kepribadian <i>Big Five</i> yang ditetapkan melalui tes BFI dan penulisan cerita.	Narasi teks yang dihasilkan oleh LLM.	Tugas akhir ini menggunakan LLM sebagai alat interpretasi generatif yang menerima hasil prediksi visual sebagai input.
<i>An Effective Personality Prediction using Bidirectional Encoder Representations from Transformers with AdamW Optimizer</i> (Devi. dkk., 2024)	Mengembangkan model prediksi kepribadian MBTI berbasis teks menggunakan BERT dan AdamW Optimizer untuk ekstraksi fitur, dengan <i>Linear Regression</i> untuk prediksi akhir.	Teks, berasal dari dataset MBTI yang berisi esai yang telah dianotasi.	Tugas akhir ini berfokus pada prediksi kepribadian <i>Big Five</i> berbasis visual/gambar dan menggunakan LLM untuk interpretasi kualitatif hasil prediksi.
<i>Prediction of Personality Traits and Suitable Job through an Intelligent Interview Agent using Machine Learning</i> (Mandakini, 2023)	Memprediksi skor <i>big five personality</i> dari video wawancara menggunakan model CNN (VGG16), kemudian mengklasifikasikan peran pekerjaan yang sesuai.	Video dari wawancara.	Tugas akhir ini berfokus pada interpretasi psikologis kualitatif dari prediksi kepribadian <i>Big Five</i> menggunakan arsitektur Transformer dan LLM.

Penelitian Suman dkk. (2022) bertujuan untuk mengembangkan sistem prediksi kepribadian otomatis/*Automatic Personality Prediction* (APP) dengan memanfaatkan berbagai modalitas data, termasuk visual, audio, dan teks (transkrip) dari video. Ekstraksi fitur dilakukan menggunakan arsitektur CNN yang sudah ada seperti ResNet dan MTCNN untuk modalitas visual, VGGish CNN untuk audio, dan CNN berbasis n-gram untuk fitur teks. Fitur-fitur ini kemudian digabungkan menggunakan strategi *early fusion* (konkatensi fitur) atau *late fusion* (rata-rata prediksi). Fokus penelitian adalah mencapai akurasi prediksi yang tinggi sebagai tugas regresi. Kelemahan utamanya adalah ketergantungan pada arsitektur CNN tradisional untuk pemrosesan fitur visual. Namun, pendekatan ini masih bergantung pada CNN tradisional yang belum memanfaatkan mekanisme *self-attention* seperti Transformer yang dapat meningkatkan representasi fitur visual (El-Demerdash dkk., 2022). Selain itu, penelitian ini tidak menyentuh aspek interpretasi naratif dari skor prediksi yang dihasilkan.

Penelitian oleh Sharma dkk. (2023) berfokus pada prediksi kepribadian menggunakan kon-

ten tekstual dari media sosial dengan model hibrida AGCNN-LSTM (*Attention Enhanced Graph Convolution Neural Network dan Long Short-Term Memory*) yang dirancang untuk mengatasi keterbatasan CNN dan LSTM konvensional, seperti waktu pelatihan yang lama dan kesulitan dalam menangkap makna semantik kata. Model ini menunjukkan performa yang unggul dibandingkan model-model yang menjadi *baseline*. Meskipun menyajikan solusi hibrida yang kuat, model ini masih didasarkan pada arsitektur sekuensial LSTM yang kurang efisien dalam pemrosesan konteks global dan paralel dibandingkan Transformer (Prasad dkk., 2024). Selain itu, fokus penelitian ini hanya pada modalitas teks, sementara beberapa studi lain menunjukkan bahwa dengan menggunakan serta menggabungkan modalitas lain seperti gambar/visual, dapat meningkatkan akurasi prediksi kepribadian.

Studi oleh Jiang dkk. (2024) menyelidiki kemampuan LLM seperti GPT-3.5 dan GPT-4 untuk merefleksikan dan meniru ciri-ciri kepribadian *Big Five*. Penelitian ini menggunakan LLM sebagai persona untuk menyelesaikan tes kepribadian dan menghasilkan narasi pribadi yang kemudian dianalisis menggunakan fitur psikolinguistik LIWC. Hasil penelitian menunjukkan LLM dapat menampilkan kepribadian yang konsisten. Penelitian ini memiliki keterbatasan karena sebagian besar analisisnya terfokus pada model tertutup dan modalitas teks, sehingga konteks multimodal atau interaksi yang lebih dinamis belum terekplorasi (Tseng dkk., 2024). Studi ini juga mencatat bahwa kesadaran manusia terhadap penulis AI dapat memengaruhi persepsi terhadap kepribadian yang ditampilkan sehingga menimbulkan tantangan dalam evaluasi yang objektif.

Penelitian Devi. dkk. (2024) mengusulkan model berbasis *Bidirectional Encoder Representations from Transformers* (BERT) dengan *AdamW Optimizer* untuk ekstraksi fitur prediksi kepribadian berbasis teks. Data yang digunakan adalah dataset MBTI. Praproses data seperti *lemmatization* dan *lowercasing* dilakukan terlebih dahulu, kemudian data diproses dengan model BERT untuk ekstraksi fitur atribut yang optimal, dilanjutkan dengan prediksi menggunakan *Linear Regression*. Model ini menunjukkan akurasi yang lebih unggul dibandingkan dengan model sekuensial seperti LSTM. Meskipun menggunakan Transformer pada prosesnya, model ini hanya digunakan untuk melakukan ekstraksi fitur modalitas tekstual yang menghasilkan atribut optimal untuk dilakukan prediksi menggunakan model tradisional.

Penelitian Mandakini (2023) berfokus pada pengembangan agen wawancara cerdas yang menggunakan *machine learning* untuk memprediksi kepribadian *Big Five* dari video wawancara. Model ini menggunakan input citra wajah yang diambil dari *frame* pada video wawancara dan mengaplikasikan model CNN VGG-16 untuk prediksi kepribadian *Big Five*. Tujuan dari penelitian ini adalah untuk memprediksi kecocokan pekerjaan berdasarkan hasil prediksi kepribadian. Kekurangan penelitian ini adalah prediksi hanya berfokus pada nilai numerik serta klasifikasi pekerjaan numerik yang sesuai. Selain itu, inferensi deskriptif yang ditunjukkan dari model hanya berupa kategorisasi berdasarkan nilai luaran dari model, misal nilai (0-0,4) pada sifat *openness* dikategorikan sebagai *low* sedangkan nilai (0,5-1,0) dikategorikan sebagai *high* sehingga tidak menunjukkan interpretasi antar sifat *Big Five* yang kualitatif secara mendalam.

2.2 Dasar Teori


2.2.1 *Big Five Personality*

Kepribadian didefinisikan sebagai kumpulan perbedaan individu yang biasa disebut ciri psikologis dalam diri individu yang menjelaskan pola proses dan mental yang menentukan penyesuaian unik terhadap lingkungan, mencakup pola pikir, perasaan, dan perilaku yang relatif stabil sepanjang waktu (Phan & Rauthmann, 2021). Pada psikologi kepribadian, model *Big Five* muncul sebagai paradigma paling dominan karena sifatnya yang konsisten dan universal

(Ponce-López dkk., 2016). Model ini mendefinisikan kepribadian manusia ke dalam lima dimensi yang sering disingkat OCEAN, yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Dimensi *Openness* mencerminkan tingkat imajinasi, keingintahuan intelektual, serta kesediaan untuk menerima ide dan pengalaman baru. *Conscientiousness* menggambarkan sejauh mana seseorang dapat bertanggung jawab, menjaga disiplin diri, dan berorientasi pada pencapaian tujuan yang sering kali menjadi aspek penting bagi kinerja akademik maupun pekerjaan. *Extraversion* menunjukkan kuantitas dan intensitas interaksi sosial yang ditandai dengan sifat ramah, tegas, serta kecenderungan untuk mencari stimulasi sosial. *Agreeableness* menilai kualitas orientasi interpersonal, mulai dari sikap lembut, kooperatif, dan penuh kepercayaan hingga kecenderungan antagonistik. Dimensi terakhir, yaitu *Neuroticism* merefleksikan ketidakstabilan emosi dan kerentanan terhadap emosi negatif seperti kecemasan dan depresi (Zell & Lesick, 2022).

2.2.2 ChaLearn First Impressions

ChaLearn First Impression merupakan dataset yang digunakan untuk melakukan evaluasi otomatis terhadap ciri kepribadian tampak (*apparent personality trait*) berdasarkan penilaian manusia (Ponce-López dkk., 2016). Dataset ini dikembangkan untuk kompetisi *ChaLearn Looking at People* yang bertujuan untuk mengatasi kurangnya data yang konsisten dalam prediksi kepribadian. Dataset ini terdiri dari 10000 klip video pendek dengan durasi rata-rata 15 detik yang diekstrak dari kurang lebih 3000 video HD YouTube mengenai orang-orang dari berbagai keragaman gender, usia, etnis, dan kebangsaan.




Gambar 2.1: Cuplikan Video dengan Label pada Dataset ChaLearn

Subjek dalam video berbicara mengenai presentasi diri yang menyerupai wawancara di depan kamera seperti yang ditunjukkan pada Gambar 2.1. Setiap klip video diberi label yang didasarkan pada model kepribadian *Big Five* yang mencakup *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*, dengan tambahan satu variabel *interview* pekerjaan.

Label tersebut diperoleh melalui penilaian persepsi pengamat manusia menggunakan platform *Amazon Mechanical Turk* (AMT). Penilaian tersebut kemudian direpresentasikan dalam rentang 0 hingga 1 untuk setiap karakteristik kepribadian *Big Five*.

2.2.3 Deep Learning

Deep Learning merupakan bagian dari *machine learning* yang menggunakan jaringan saraf berlapis untuk menyimulasikan proses pembelajaran pada otak manusia dalam memodelkan pola data tingkat tinggi (Taye, 2023). Fondasi utama dari teknologi ini adalah neuron buatan (*perceptron*) yang merupakan unit pemrosesan kecil yang menerima berbagai input untuk menghasilkan sebuah *output*. Setiap input yang diterima oleh neuron diberikan bobot (*weight*) tertentu yang mencerminkan tingkat signifikansi input tersebut terhadap keputusan akhir model. Setiap neuron memiliki parameter bias yang berfungsi untuk mengatur *output* agar model dapat mencapai kecocokan data yang paling optimal (Sarker, 2021; Taye, 2023). Gambar 2.2 menggambarkan model matematika dari *perceptron*, di mana seluruh input dengan bobot dan bias dijumlahkan melalui *summation function* sebelum diproses lebih lanjut.



Gambar 2.2: Representasi Model Matematika Neuron Buatan (*Perceptron*) (Sarker, 2021)

Deep neural network atau dikenal juga dengan *feed-forward neural network* merupakan sebuah jaringan di mana data diproses dari lapisan input kemudian menuju lapisan tersembunyi (*hidden layer*) dan berakhir di lapisan *output*. Fungsi aktivasi seperti ReLU, Sigmoid, Tanh, atau Softmax berperan penting dalam proses ini dengan memberikan sifat *non-linear* sehingga *neural network* mampu mempelajari hubungan data yang sangat kompleks (Taye, 2023). Untuk mengukur kinerja model dalam melakukan prediksi dengan benar, digunakan *loss function* yang bertugas menghitung selisih atau kesalahan antara hasil prediksi model dengan label target yang sebenarnya. Beberapa jenis *loss function* yang umum digunakan meliputi *Cross-Entropy* untuk tugas klasifikasi dan *Mean Square Error* untuk tugas regresi (Alzubaidi dkk., 2021).

Salah satu proses krusial dalam *deep learning* adalah optimasi, yaitu proses memperbarui parameter internal model seperti *weight* dan bias secara iteratif untuk meminimalkan nilai *loss function* (Abdulkadrov dkk., 2023; Alzubaidi dkk., 2021). Proses ini dijalankan menggunakan algoritma *backpropagation* yang menghitung turunan parsial atau gradien untuk menentukan arah penyesuaian parameter yang paling efisien (Sarker, 2021; Taye, 2023). Algoritma Adam (*Adaptive Moment Estimation*) merupakan salah satu *optimizer* yang sering digunakan karena efisiensinya dalam menghitung laju pembelajaran adaptif menggunakan rata-rata *exponential moving* dari gradien dan kuadrat gradien (Abdulkadrov dkk., 2023; Alzubaidi dkk., 2021). Untuk meningkatkan kemampuan generalisasi model, dikembangkan varian AdamW yang secara spesifik mengintegrasikan regularisasi L2 dengan cara memisahkan mekanisme *weight decay*

dari langkah *update* gradien utama. Pendekatan ini memastikan bahwa pengurangan bobot dilakukan secara langsung pada parameter tanpa dipengaruhi oleh penskalaan gradien adaptif (Abdulkadrov dkk., 2023).

2.2.4 Deteksi dan Ekstraksi Wajah

Dalam analisis kepribadian berbasis visual, deteksi dan ekstraksi wajah pada gambar maupun video merupakan tahap praproses yang penting untuk meningkatkan kinerja model dalam melakukan prediksi agar fitur visual yang digunakan tetap relevan. Proses ekstraksi wajah dilakukan menggunakan model BlazeFace yang ringan dalam mendeteksi wajah pada gambar. Model deteksi wajah ini dibangun dengan mengadaptasi arsitektur *Single Shot MultiBox Detector* (SSD) yang dapat memprediksi skor deteksi objek serta melakukan penyesuaian pada kotak pembatas/*bounding box* secara cepat dan akurat tanpa memerlukan teknik yang menggunakan *region proposal* maupun *pooling* seperti pada model Faster R-CNN (W. Liu dkk., 2016). Selain memprediksi *bounding box* wajah, BlazeFace juga menghasilkan 6 titik koordinat kunci wajah yang dapat digunakan untuk menyelaraskan wajah untuk digunakan pada proses prediksi berikutnya (Bazarevsky dkk., 2019).

Sistem pelacakan wajah atau *face tracking* diperlukan pada tahap praproses video, mengingat terdapat kemungkinan sebuah video dapat memuat lebih dari satu wajah pada satu *frame*. Mekanisme ini digunakan untuk mempertahankan konsistensi hasil pelacakan wajah target pada *frame-frame* yang berurutan dari awal hingga akhir video. Berdasarkan kerangka kerja *Simple Online and Realtime Tracking* (SORT), pelacakan objek multi target yang efisien dan andal dapat dicapai dengan mengasosiasikan informasi geometri dari *bounding box* pada setiap *frame*. Pendekatan ini dapat diaplikasikan pada deteksi wajah dengan menggunakan titik pusat koordinat *bounding box* dan dimensi ukuran wajah dari hasil ekstraksi pada *frame* yang berurutan untuk membentuk asosiasi data tanpa perlu menambahkan fitur wajah tambahan yang tampak (*appearance features*) yang dapat menambah beban komputasi (Bewley dkk., 2017). Pendekatan pelacakan spasial antar *frame* ini menjamin bahwa hasil ekstraksi akan selalu konsisten untuk wajah yang sama dalam satu video.


Penentuan wajah utama yang akan digunakan dalam sistem pelacakan wajah pada *frame* awal perlu dilakukan dengan mempertimbangkan perhatian visual (*visual attention*) pada objek yang menonjol pada gambar (T. Liu dkk., 2011). Penentuan ini didasarkan pada titik keseimbangan antara dominasi visual dan fenomena bias pusat (*center prior*). Dominasi visual ditunjukkan oleh seberapa besar ukuran area wajah tersebut di dalam gambar beserta seberapa tinggi tingkat kepercayaan (*confidence score*) yang dihasilkan oleh detektor. Sedangkan bias pusat menunjukkan kecenderungan alami manusia untuk membidik dan memosisikan objek yang paling penting di bagian tengah gambar. Penelitian mengenai pelacakan mata menunjukkan bahwa terdapat bias yang sangat kuat pada perhatian visual manusia yang sebagian besar menunjukkan kecenderungan melihat pada area tengah suatu gambar (Judd dkk., 2009). Berdasarkan penelitian ini, wajah dengan ukuran area yang besar dan memiliki jarak titik pusat *bounding box* terdekat dengan titik pusat keseluruhan *frame* gambar dapat dievaluasi sebagai wajah utama untuk selanjutnya terus dilacak pada *frame* video berikutnya.

2.2.5 Transformer

Transformer merupakan arsitektur *deep learning* yang dikenalkan oleh Vaswani dkk. (2023) untuk menangani tugas-tugas dalam *Natural Language Processing* (NLP). Arsitektur ini menjadi standar baru karena kemampuannya menggantikan model sekuensial seperti *Recurrent Neural Networks* (RNN) melalui mekanisme *self-attention* (Vaswani dkk., 2023). Transformer memungkinkan komputasi paralel yang masif karena tidak memproses data secara langkah demi

langkah, melainkan secara simultan untuk seluruh urutan input. Hal ini memberikan keunggulan signifikan dalam menangkap *long-range dependencies* dan meningkatkan efisiensi waktu pelatihan pada dataset dengan skala besar (Z. Liu dkk., 2021).

Struktur inti Transformer terdiri dari *encoder* dan *decoder*. *Encoder* bertugas memetakan representasi simbol dari *input sequence* menjadi *continuous sequence*. Selanjutnya *decoder* menghasilkan simbol *output sequence* satu per satu secara autoregresif dengan menggunakan simbol-simbol yang dihasilkan sebelumnya sebagai *input* tambahan saat menghasilkan simbol berikutnya (Vaswani dkk., 2023).




Gambar 2.3: Arsitektur Transformer (Vaswani dkk., 2023)

Secara umum, gambaran arsitektur Transformer ditunjukkan pada Gambar 2.3. Transformer menggunakan tumpukan *layer self-attention* dan *point-wise fully connected* pada bagian *encoder* maupun *decoder*. *Encoder* terdiri dari N -layer yang identik. Setiap *layer* memiliki dua *sub-layer* utama, yaitu *multi-head attention* dan *position-wise fully connected feed-forward network*. Struktur *decoder* juga terdiri dari N -layer identik seperti *encoder* dengan tambahan *sub-layer* ketiga yaitu *multi-head attention* di atas hasil *output encoder*. Setiap *sub-layer* menerapkan koneksi residual yang diikuti oleh *layer normalization*. Mekanisme *self-attention* pada *decoder* dimodifikasi dengan *masking* untuk mencegah suatu posisi memperhatikan posisi-posisi setelahnya pada saat proses generasi. Hal ini memastikan bahwa hasil prediksi pada posisi i hanya bergantung pada *output* yang diketahui pada posisi kurang dari i sehingga mempertahankan sifat autoregresif model. Karena model ini tidak menggunakan rekurensi maupun konvolusi, maka digunakan *positional encoding* pada bagian bawah *stack encoder* dan *decoder* untuk memberikan informasi mengenai urutan posisi relatif maupun absolut dari setiap token dalam rangkaian

data. Sistem ini memungkinkan setiap posisi pada *decoder* memerhatikan seluruh posisi pada *input sequence* sekaligus mempertahankan efisiensi dengan komputasi paralel (Vaswani dkk., 2023).

2.2.6 Vision Transformer (ViT)

Vision Transformer (ViT) merupakan arsitektur yang mengadaptasi model Transformer untuk digunakan pada ranah *computer vision* dengan mengubah citra gambar menjadi urutan *patch* (Han dkk., 2023). ViT menggunakan mekanisme *self-attention* dan *multi-head self-attention* untuk memodelkan hubungan global antar bagian citra sehingga dapat menangkap dependensi jarak jauh secara eksplisit (Khan dkk., 2022; Thisanke dkk., 2023). Secara umum, ViT memperlakukan citra dua dimensi sebagai urutan token (*patch* citra) dan memprosesnya dengan *encoder* Transformer standar sehingga struktur dasarnya mirip dengan Transformer untuk NLP yang ditambahkan tahap tokenisasi citra dan penambahan *positional embedding* (Y. Wang dkk., 2025).




Gambar 2.4: Arsitektur Vision Transformer (Dosovitskiy dkk., 2021)

Proses ViT dimulai dengan membagi citra input dua dimensi menjadi urutan *patch* berukuran tetap yang tidak saling tumpang tindih. *Patch* ini diperlakukan seperti token/kata pada NLP. Setiap bagian *patch* tersebut diratakan (*flattened*) dan diproyeksikan secara linear melalui matriks *embedding* untuk menghasilkan *patch embeddings* dengan dimensi tetap (Dosovitskiy dkk., 2021). Karena urutan posisi pada mekanisme *self-attention* tidak penting, informasi spasial ditambahkan melalui *positional encoding* satu dimensi agar model dapat memahami susunan relatif dan topologi dari setiap bagian citra (Papa dkk., 2024). Sebuah vektor *embedding* khusus yang terinspirasi oleh token [class] pada model BERT (*Bidirectional Encoder Representation from Transformers*) ditambahkan di awal *sequence* yang berfungsi sebagai representasi agregat global dan akan digunakan oleh kepala MLP (*Multi Layer Perceptron*) untuk klasifikasi (Dosovitskiy dkk., 2021).


2.2.7 Swin Transformer

Swin Transformer diperkenalkan sebagai arsitektur *backbone* untuk *computer vision* dengan tujuan mengatasi perbedaan antara domain teks dan citra seperti variasi yang beragam dalam skala entitas visual dan resolusi piksel yang tinggi (Z. Liu dkk., 2021).



Gambar 2.5: Perbedaan Arsitektur Swin Transformer dengan ViT (Z. Liu dkk., 2021)

Berbeda dengan ViT yang menghasilkan pemetaan fitur dengan resolusi tunggal dan memiliki kompleksitas kuadratik seperti yang ditunjukkan pada Gambar 2.5, Swin Transformer membangun representasi hierarkis dengan kompleksitas linear terhadap ukuran gambar *input*. Karakteristik hierarkis ini dicapai dengan memulai *patch* dengan ukuran kecil yang secara bertahap digabungkan dengan *patch* tetangga pada jaringan yang lebih dalam (*patch merging*). Hal ini memungkinkan model untuk menggunakan teknik-teknik *dense prediction* seperti *Feature Pyramid Network* (FPN) atau U-Net (Z. Liu dkk., 2021).



Gambar 2.6: Arsitektur Swin Transformer (Z. Liu dkk., 2021)


Berdasarkan arsitektur Swin pada Gambar 2.6, proses dimulai dengan membagi gambar RGB *input* menjadi *patch* yang tidak tumpang tindih berukuran 4×4 piksel melalui modul *patch partition* dengan fitur yang merupakan penggabungan (*concatenation*) dari nilai RGB mentah setiap piksel. Setiap *patch* diperlakukan sebagai token dan diproyeksikan secara linear ke dimensi tertentu (C). Arsitektur ini terdiri dari empat tahapan dengan setiap tahap kecuali tahap pertama diawali dengan *patch merging layer* yang menggabungkan 2×2 *patch* tetangga untuk mengurangi jumlah token sebanyak 4 kali dan meningkatkan dimensi fitur sebanyak 2 kali (Z. Liu dkk., 2021).

Mekanisme *Shifted Window based Self-Attention* menjadi keunggulan utama dari Swin Transformer dibandingkan dengan ViT. *Attention* dihitung secara lokal di dalam *windows* beru-

ukuran $M \times M$ yang membagi gambar secara merata tanpa tumpang tindih untuk efisiensi. Untuk menambahkan koneksi antar *window* tanpa menambah beban komputasi, digunakan digunakan skema *shifted windowing* pada blok Transformer yang berurutan. Blok pertama menggunakan partisi *window* reguler, sedangkan blok berikutnya menggunakan konfigurasi partisi *shifted window* sehingga informasi dapat melewati batas-batas *window* pada *layer* sebelumnya (Z. Liu dkk., 2021).

Swin Transformer V2 dikembangkan untuk meningkatkan kapasitas model dan resolusi *window* pada model sebelumnya (Z. Liu dkk., 2022). Versi ini mengatasi masalah ketidakstabilan pelatihan pada model besar dan perbedaan resolusi antara fase *pre-training* dan *fine-tuning* melalui tiga teknik utama:

1. *Residual post-normalization*, mengganti konfigurasi *pre-norm* dengan memindahkan lapisan *Layer Normalization* (LN) ke bagian akhir setiap unit residual untuk mencegah ledakan nilai aktivasi pada lapisan yang lebih dalam.
2. *Scaled cosine attention*, mengganti *dot product attention* dengan fungsi *scaled cosine attention* agar nilai *attention* tidak didominasi oleh amplitudo input tertentu yang menyebabkan ketidakstabilan pelatihan.
3. *Log-spaced continuous position bias*, mengganti optimasi *parameterized bias* dengan jaringan meta kecil yang menggunakan koordinat *log-spaced* dibandingkan dengan koordinat linear pada model terdahulu. Teknik ini memungkinkan model untuk melakukan transfer nilai *bias* secara efektif meskipun ukuran resolusi *window* berbeda jauh dengan pelatihan awal.




Gambar 2.7: Perbedaan Swin Transformer V2 dengan V1 (Z. Liu dkk., 2022)

Penggunaan teknik-teknik tersebut membuat Swin Transformer V2 menjadi model *dense vision* terbesar yang mampu menangani resolusi gambar hingga 1.536×1.536 piksel dengan kinerja yang melampaui standar arsitektur sebelumnya.

2.2.8 Pyramid Vision Transformer (PVT)


Pyramid Vision Transformer (PVT) diperkenalkan sebagai model *backbone* Transformer serbaguna yang dapat digunakan untuk tugas-tugas pada *computer vision* tanpa bergantung pada operasi konvolusi (W. Wang dkk., 2021). PVT mengadopsi struktur piramida yang memungkinkan pembentukan *multi-scale feature maps* yang serupa dengan struktur hierarkis pada CNN.



Gambar 2.8: Arsitektur Piramida pada PVT (W. Wang dkk., 2021)


Model ini memperkenalkan strategi *progressive shrinking* untuk mengontrol *scaled feature map* melalui lapisan *patch embedding*. PVT menggunakan mekanisme *Spatial-Reduction Attention* (SRA) yang menggantikan *Multi-Head Attention* (MHA) standar. SRA bekerja dengan cara mengurangi dimensi spasial dari matriks *Key* (K) dan *Value* (V) sebelum operasi *attention* dilakukan sehingga dapat mengurangi konsumsi sumber daya komputasi dan memori secara signifikan.

PVT v2 diperkenalkan sebagai pengembangan untuk mengatasi keterbatasan pada versi sebelumnya seperti kompleksitas komputasi yang masih tinggi pada resolusi besar dan hilangnya kontinuitas lokal. Berikut adalah tiga perbedaan utama pada PVT v2 yang menyempurnakan arsitektur sebelumnya.



Gambar 2.9: Perbandingan Mekanisme SRA pada PVT v1 dan *Linear SRA* pada PVT v2 (W. Wang dkk., 2023)

1. *Linear Spatial-Reduction Attention* (LSRA), ditunjukkan pada Gambar 2.9 yang menggantikan *layer* konvolusi dengan menggunakan *average pooling* untuk mengurangi dimensi spasial menjadi ukuran tetap ($P \times P$) Hal ini memungkinkan komputasi dan memori yang linear terhadap ukuran *input* gambar yang serupa dengan efisiensi pada *layer* konvolusi.



Gambar 2.10: Mekanisme *Overlapping Patch Embedding* dan *Convolutional Feed-Forward Network* (W. Wang dkk., 2023)

2. *Overlapping Patch Embedding* (OPE), PVT v2 menggunakan konvolusi dengan *zero padding* untuk mengimplementasikan *patch embedding* yang saling tumpang tindih. Dengan memperbesar *patch window* sehingga setengah area *window* yang berdekatan saling tumpang tindih, model mampu menangkap informasi kontinuitas lokal dari gambar dan *feature map* lebih baik dibandingkan metode *non-overlapping* pada PVT v1.
3. *Convolutional Feed-Forward Network* (CFFN), PVT v2 menambahkan *depth-wise convolution layer* berukuran 3×3 dengan *zero padding* di dalam *feed-forward network* untuk meningkatkan kemampuan ekstraksi fitur lokal. Penambahan ini tidak hanya menangkap kontinuitas lokal pada *input tensor*, tetapi juga memberikan informasi posisi secara implisit sehingga penggunaan *fixed-size positional encoding* yang tidak fleksibel pada versi sebelumnya dapat dihilangkan.

Perubahan ketiga komponen ini membuat PVT v2 mampu memproses input dengan resolusi variabel secara lebih fleksibel sekaligus mencapai kinerja yang lebih unggul dibandingkan *backbone CNN* maupun *Transformer* lainnya pada berbagai tugas *computer vision*.

2.2.9 Large Language Model

Large Language Model (LLM) merupakan model bahasa berbasis arsitektur *Transformer* yang memiliki jumlah parameter yang sangat banyak, umumnya berjumlah hingga miliaran dan dilatih menggunakan korpus data tekstual yang besar. Karakteristik utama yang membedakan LLM dari model bahasa konvensional adalah munculnya *emergent abilities*, yaitu kemampuan cerdas seperti penalaran kompleks, pemecahan masalah matematika, dan pembelajaran dalam

konteks (*in-context learning*) yang muncul secara spontan setelah model mencapai skala data dan parameter tertentu (Zhao dkk., 2025).

LLM umumnya dibangun menggunakan arsitektur Transformer *decoder* yang menggunakan mekanisme *self-attention* untuk memodelkan hubungan antar elemen dalam urutan data secara paralel (Cheng dkk., 2025). Prinsip utama LLM adalah melakukan pemodelan bahasa melalui prediksi token berikutnya (*next-token prediction*). Dalam proses ini, model menghitung probabilitas generatif dari urutan kata untuk memprediksi token berikutnya berdasarkan konteks sebelumnya (Zhao dkk., 2025). LLM menggunakan tumpukan *multi-head attention layer* dan *feed-forward network* untuk belajar memadatkan pengetahuan ke dalam parameter-parameter jaringan dengan tujuan sebagai pemecah masalah generik (*general-purpose task solver*) (Cheng dkk., 2025; Zhao dkk., 2025). Seiring perkembangan teknologi, muncul varian baru LLM yaitu *Multimodal Large Language Model* (MLLM) yang mampu mengintegrasikan dan memproses berbagai modalitas informasi seperti teks, citra, dan video. Struktur umum MLLM terdiri dari tiga komponen inti, yaitu *Vision Encoder* untuk melakukan ekstraksi fitur visual, *Cross-modal Connector* untuk menyelaraskan fitur visual ke dalam ruang semantik teks, dan LLM *Backbone* sebagai unit penalaran utama (P. Wang dkk., 2024).

Untuk menyesuaikan kapabilitas umum model dengan kebutuhan spesifik, LLM menggunakan dua mekanisme adaptasi:

1. *Instruction tuning*, merupakan pendekatan *fine-tuning pre-trained* LLM menggunakan kumpulan data yang diformat dalam bentuk bahasa alami (*natural language*) (Zhao dkk., 2025). Proses ini bertujuan untuk memperbarui bobot internal model agar dapat beradaptasi untuk mengikuti perintah spesifik dan memahami logika pada deskripsi tugas sehingga meningkatkan kemampuan generalisasi pada tugas-tugas yang belum pernah ditemui sebelumnya (Brickman dkk., 2025; Cheng dkk., 2025; Zhao dkk., 2025).
2. *Prompt engineering*, strategi ini dilakukan pada saat inferensi tanpa mengubah parameter internal model (Zhao dkk., 2025). Teknik ini berfokus pada perancangan instruksi input yang optimal seperti *zero-shot prompting* tanpa menggunakan contoh atau *few-shot prompting* dengan memberikan beberapa contoh pasangan *input-output*. Hal ini bertujuan untuk mengeksplorasi pengetahuan yang sudah tersimpan di dalam model secara maksimal (Brickman dkk., 2025).

2.2.10 Prompt Engineering

Prompt engineering didefinisikan sebagai sekumpulan teknik dan metode untuk merancang, menulis, dan mengoptimalkan instruksi guna memastikan respons LLM bersifat akurat, relevan, dan bebas dari informasi yang menyesatkan. Strategi ini bekerja pada fase inferensi dengan memanfaatkan pengetahuan yang telah tersimpan di dalam parameter model tanpa melakukan *update* bobot internal (Brickman dkk., 2025). Desain *prompt* yang mencakup kejelasan instruksi, penyediaan konteks, serta kontrol terhadap format *output* yang diinginkan dapat meningkatkan akurasi interaksi LLM sesuai dengan konteks yang diharapkan (Velásquez-Henao dkk., 2023).

Salah satu teknik yang *prompting* yang umum digunakan adalah *role-play prompting*, yaitu ketika model diminta untuk memerankan suatu persona tertentu, seperti menjadi seorang guru matematika atau hakim yang adil (Kong dkk., 2024). Pemberian peran ini berfungsi untuk membatasi ruang lingkup identitas model dan membantu memberikan pengetahuan parametrik yang relevan sehingga respons yang dihasilkan lebih natural dan selaras dengan tugas spesifik (Kong dkk., 2024; Tseng dkk., 2024). Selain meningkatkan keterlibatan pengguna, penelitian menunjukkan bahwa *role-play prompting* dapat berfungsi sebagai pemicu implisit bagi mekanisme *Chain-of-Thought* (CoT) yang memperkuat kemampuan penalaran model dibandingkan

dengan instruksi standar (Kong dkk., 2024).

Teknik lain yang digunakan adalah *contextual injection*, yaitu proses mengintegrasikan data atau informasi latar belakang yang spesifik ke dalam prompt untuk memandu model dalam menghasilkan jawaban (Velásquez-Henao dkk., 2023; Zhao dkk., 2025). Penggunaan informasi kontekstual sangat penting dalam domain khusus seperti teknik atau medis ketika model membutuhkan data presisi guna menghindari fenomena halusinasi atau jawaban yang terlalu umum. Injeksi konteks dapat diimplementasikan dengan melampirkan dokumen referensi, struktur data organisasi, maupun instruksi mendetail mengenai batasan tugas yang harus diselesaikan oleh sistem (Velásquez-Henao dkk., 2023). Melalui kombinasi identitas peran dan penyediaan data kontekstual yang sesuai, LLM mampu berfungsi sebagai asisten cerdas yang memberikan solusi yang valid secara faktual dan tepat (Tseng dkk., 2024).

2.2.11 Gemma

Gemma merupakan salah satu model *open source* yang dikembangkan oleh Google DeepMind menggunakan penelitian dan teknologi yang sama dengan model Gemini. Model ini dirancang dalam berbagai ukuran untuk memfasilitasi keterbatasan sumber daya komputasi sehingga dapat dijalankan pada perangkat keras kelas konsumen seperti laptop yang hanya menggunakan CPU. Gemma dibangun di atas arsitektur Transformer *decoder* yang mendukung panjang konteks dari 8192 token hingga 256000 token pada model terbaru. Arsitektur Gemma mengintegrasikan berbagai pendekatan modern untuk menjaga efisiensi dan stabilitas pelatihan seperti penggunaan *Rotary Positional Embeddings* (RoPE), aktivasi GeGLU, serta normalisasi RMSNorm (Team dkk., 2024). Model terbaru, yaitu Gemma 4 tersedia dalam 3 varian, yaitu *Small* (2B dan 4B), *Dense* (31B), dan *Mixture-of-Experts* (26B A4B) yang memungkinkan fleksibilitas penggunaan sesuai dengan batasan daya komputasi perangkat yang digunakan (Google, 2026).

Gemma menunjukkan kinerja yang unggul pada NLP, penalaran umum, serta tugas-tugas analitis yang kompleks. Model ini mencapai kinerja *state-of-the-art* pada berbagai bidang seperti matematika, sains, dan pemrograman. Varian Gemma 3 memperkenalkan kemampuan multimodal yang memungkinkan model untuk memahami input visual secara langsung melalui integrasi SigLIP *vision encoder*. Kemampuan visual tersebut didukung oleh metode *Pan and Scan* (P&S) yang membuat model mampu menangkap gambar pada resolusi dan rasio aspek aslinya tanpa kehilangan detail penting atau teks yang berukuran kecil. Selain itu, untuk mengoptimalkan penggunaan memori saat menangani konteks data yang sangat panjang, Gemma menerapkan mekanisme *interleaving* dengan rasio 5:1 antara lapisan *self-attention* lokal dan global. Seluruh varian model Gemma juga melalui proses *instruction-tuning* dan *Reinforcement Learning from Human Feedback* (RLHF) untuk memastikan tingkat keselarasan respon yang tinggi terhadap preferensi pengguna manusia (Team dkk., 2025).

2.2.12 Qwen-VL

Qwen-VL merupakan *Large Vision-Language Model* (LVLM) yang dikembangkan oleh tim Alibaba Cloud untuk memahami informasi tekstual serta visual secara simultan. Arsitektur dasar model ini terdiri dari tiga komponen utama, yaitu LLM Qwen sebagai unit penalaran, *vision encoder* berbasis ViT-bigG, serta *Vision-Language Adapter* yang menggunakan mekanisme *cross-attention* untuk memproses fitur visual secara efisien. Model ini menggunakan pengkodean posisi absolut 2D untuk memitigasi hilangnya detail spasial selama proses kompresi fitur serta jalur pelatihan tiga tahap yang meliputi penyesuaian visi-bahasa, pelatihan multi-tugas pada korpus multibahasa, dan penyetelan instruksi visual. Kapabilitas utama Qwen-VL mencakup deskripsi citra (*image captioning*), *Visual Question Answering* (VQA), *Optical Character*

Recognition (OCR) tingkat lanjut, serta *visual grounding* (J. Bai dkk., 2023).

Model versi terbaru yaitu Qwen3-VL mempunyai kemampuan pemahaman konteks multimodal yang dapat memproses hingga 256.000 token yang mencakup teks, gambar, dan video. Model ini dikenalkan dalam beberapa varian, mulai dari arsitektur *dense* dengan 2B hingga 32B parameter, hingga arsitektur *Mixture-of-Experts*, serta menyediakan varian *thinking* yang difokuskan pada kemampuan penalaran multimodal yang kompleks. Qwen3-VL membawa tiga pembaruan arsitektur utama, yaitu penerapan *interleaved-MRoPE* yang mendistribusikan komponen spasial dan temporal secara seragam untuk memperbaiki bias spektrum frekuensi sehingga pemodelan video menjadi lebih representatif, integrasi mekanisme *DeepStack* yang mengekstrak dan menggabungkan fitur visual dari berbagai lapisan Vision Transformer secara langsung pada *layer* LLM untuk memperkuat penyelarasan visi-bahasa dengan mempertahankan kekayaan detail dari level rendah hingga tinggi, serta transisi dari metode T-RoPE ke penyelarasan *textual timestamp* secara eksplisit untuk penyelarasan waktu berbasis teks untuk video, yang memberikan pemahaman struktur waktu (*temporal grounding*) yang lebih presisi (S. Bai dkk., 2025).

2.2.13 Metrik Evaluasi

Pada bagian ini, akan dijelaskan metrik evaluasi yang digunakan untuk mengukur kinerja model dalam menghasilkan prediksi dan interpretasi. Evaluasi dilakukan untuk menilai seberapa akurat hasil prediksi model regresi dan interpretasi LLM dalam menilai kepribadian.

A. Metrik Evaluasi Model Prediksi

Kualitas model pada tugas regresi untuk memprediksi skor kepribadian *Big Five* tidak dievaluasi dengan akurasi klasifikasi, tetapi dengan seberapa dekat nilai prediksi terhadap skor kontinu *ground truth*. Oleh karena itu, digunakan kombinasi metrik *error* (MAE, RMSE), metrik varians (R^2), dan *Accuracy* ($1 - \text{MAE}$) yang memetakan *error* menjadi nilai kemiripan yang mudah ditafsirkan (Chicco dkk., 2021; Plevris dkk., 2022).

a. Mean Absolute Error (MAE)

MAE mengukur rata-rata *error* absolut antara nilai sebenarnya dan nilai prediksi yang ditunjukkan pada Persamaan 2.1.

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2.1)$$

dengan y_i merupakan skor kepribadian aktual, $\hat{y}_i$ adalah skor prediksi, dan N jumlah sampel. MAE tidak membedakan arah kesalahan (*over/under-estimate*) dan kurang sensitif terhadap *outlier* dibanding metrik berbasis kuadrat sehingga sering digunakan sebagai indikator umum *error* rata-rata model regresi (Chicco dkk., 2021). MAE yang lebih kecil berarti prediksi skor rata-rata tiap *Big Five trait* lebih dekat ke nilai sebenarnya.

b. Accuracy

Kompetisi ChaLearn menggunakan metrik *Accuracy* untuk mendapatkan nilai antara 0-1 yang interpretasinya mirip dengan metrik akurasi pada klasifikasi tetapi tetap berbasis *error* kontinu. Rumus *Accuracy* ditunjukkan pada Persamaan 2.2.

$$\text{Accuracy} = 1 - \text{MAE}_{\text{model}} \quad (2.2)$$

di mana $\text{MAE}_{\text{model}}$ adalah MAE dari hasil prediksi model. Metrik ini digunakan sebagai metrik utama yang hasilnya dapat diinterpretasikan dengan lebih mudah (Ponce-López

dkk., 2016).

c. *Root Mean Square Error* (RMSE)

RMSE mengukur rata-rata *error* dengan memberi bobot lebih besar pada error yang besar seperti ditunjukkan pada Persamaan 2.3.

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (2.3)$$

RMSE selalu lebih besar dari MAE dan sangat berguna ketika *error* besar dianggap lebih penting karena *error* dikuadratkan sebelum dirata-rata (Chai & Draxler, 2014). Dalam prediksi kepribadian *Big Five*, RMSE yang rendah menunjukkan bahwa model tidak hanya baik secara rata-rata, tetapi juga jarang menghasilkan prediksi yang sangat jauh dari nilai aktual.

d. *Coefficient of Determination* (R^2)


Coefficient of determination atau R^2 mengukur proporsi varians target yang dapat dijelaskan model dibandingkan *baseline* yang hanya memprediksi rata-rata, dihitung dengan Persamaan 2.4.

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (2.4)$$

dengan $\bar{y}$ adalah rata-rata skor kepribadian aktual. Nilai R^2 bisa negatif yang berarti model lebih buruk dari *baseline* rata-rata hingga 1 yang berarti *fit* sempurna. R^2 yang lebih tinggi berarti model menjelaskan porsi lebih besar variasi skor kepribadian antar individu. Dalam prediksi kepribadian *Big Five*, R^2 sering dipakai berdampingan dengan RMSE. RMSE menyatakan besarnya *error* dalam satuan skor, sedangkan R^2 menyatakan seberapa baik model menjelaskan struktur varians data (Chicco dkk., 2021; Habib dkk., 2024).

B. G-Eval

G-Eval merupakan kerangka kerja evaluasi berbasis LLM yang dirancang untuk menilai kualitas teks hasil generasi menggunakan mekanisme *Chain-of-Thought* (CoT) dan paradigma *form-filling* (Y. Liu dkk., 2023). Pada ekosistem pengembangan kecerdasan buatan, G-Eval menjadi representasi dari paradigma *LLM-as-a-judge* yang memanfaatkan LLM seperti GPT-4 sebagai otoritas penilai untuk memberikan skor, peringkat, atau seleksi terhadap *output* model lain (Li dkk., 2025). Keunggulan utama G-Eval dibandingkan metrik tradisional seperti BLEU atau ROUGE adalah kemampuannya untuk menangkap atribut semantik yang kompleks dan nuansa konteks yang sering kali lolos dari pengukuran berbasis *lexical overlap* (Pereira dkk., 2024).



Gambar 2.11: Kerangka Kerja G-Eval (Confident AI, 2025)


Kerangka kerja G-Eval diimplementasikan secara sistematis melalui integrasi tiga komponen utama yang ditunjukkan pada Gambar 2.11. Proses ini diawali dengan penyusunan *prompt* yang berisi pengenalan tugas serta definisi kriteria evaluasi spesifik untuk memberikan batasan parameter bagi LLM yang bertindak sebagai otoritas penilai (Y. Liu dkk., 2023). Selanjutnya, model menjalankan mekanisme *Auto Chain-of-Thought* (Auto-CoT) untuk menghasilkan rangkaian langkah evaluasi internal secara otomatis yang berfungsi memberikan panduan penalaran secara detail bagi model sebelum memberikan skor akhir (Chiang & Lee, 2023). Berdasarkan panduan langkah tersebut, model kemudian memproses teks target melalui paradigma *form-filling* untuk menghasilkan prediksi kualitas *output*. G-Eval tidak hanya mengambil skor integer mentah, melainkan menggunakan fungsi penilaian berbobot yang memanfaatkan probabilitas dari token *output* model untuk melakukan normalisasi sehingga menghasilkan skor kontinu yang mampu menangkap nuansa perbedaan kualitas dengan lebih halus (Y. Liu dkk., 2023). Pada tahap akhir untuk menjamin reliabilitas hasil, kerangka kerja ini menerapkan strategi *self-consistency* dengan melakukan pengambilan sampel berulang dan menghitung rata-rata skor untuk memitigasi bias distribusi dan memastikan keselarasan yang tinggi dengan penilaian manusia (Pereira dkk., 2024).

Halaman ini sengaja dikosongkan

BAB III METODOLOGI

3.1 Metode yang digunakan


Bagian ini membahas mengenai metode-metode yang digunakan dalam melakukan interpretasi kepribadian *Big Five* dari gambar yang diekstraksi pada video. Berdasarkan Gambar 3.1, alur penelitian meliputi praproses dataset video menjadi gambar, prediksi dan evaluasi nilai kepribadian, perancangan *prompt* interpretasi kepribadian, interpretasi kepribadian dengan LLM dan evaluasi hasil interpretasi.



Gambar 3.1: Diagram Alir Penelitian

3.1.1 Praproses Dataset Video menjadi Gambar

Dataset ChaLearn yang digunakan merupakan dataset dengan modalitas video. Oleh karena itu, diperlukan konversi data menjadi gambar statis. Setiap *frame* yang diekstraksi dari video diperlakukan sebagai satu sampel data tunggal yang independen.




Gambar 3.2: Diagram Alir Praproses Dataset

Seperti yang ditunjukkan pada Gambar 3.2, tahapan praproses meliputi ekstraksi *frame*, deteksi wajah utama dan *cropping*, pengubahan ukuran gambar, augmentasi, dan normalisasi.

1. Ekstraksi *frame* dan pelabelan gambar dilakukan untuk mengubah data video menjadi gambar statis. Dilakukan pengambilan sampel *frame* sebanyak 15 dengan interval tetap dari setiap video dalam dataset untuk mewakili setiap detik dalam video yang rata-rata berdurasi 15 detik. Setiap *frame* yang diekstraksi diberi label yang sama dengan video induknya. Sebagai contoh, jika sebuah video memiliki nilai *Openness* 0.8, maka seluruh gambar yang diekstraksi dari video tersebut akan dilabeli dengan nilai *Openness* 0.8. Hal ini memungkinkan model untuk belajar mengasosiasikan fitur visual statis sesaat dengan label kepribadian secara keseluruhan.
2. Deteksi wajah utama dan *cropping* dilakukan karena fokus penelitian adalah *apparent personality* dari wajah manusia, maka tampilan latar belakang yang tidak relevan dihilangkan. MediaPipe *Face Detection* digunakan untuk mendeteksi wajah, kemudian dilakukan *cropping* pada gambar berdasarkan *bounding box* wajah yang terdeteksi dengan penambahan sedikit margin untuk memastikan seluruh fitur wajah seperti rambut tetap terlihat.
3. Pengubahan ukuran dilakukan agar dimensi gambar sesuai dengan spesifikasi *input* model prediksi, yaitu 224×224 untuk model ViT dan PvT, serta 256×256 untuk model Swin Transformer.
4. Augmentasi dilakukan untuk memperkaya variasi gambar pada dataset, mengingat terdapat beberapa *frame* yang memiliki kemiripan karena hasil ekstraksi 15 *frame* pada satu video. Augmentasi yang dilakukan meliputi *Random Horizontal Flip* dengan probabilitas 0.5, *Random Rotation* sebesar 10 derajat, dan mengubah kecerahan dan kontras gambar secara acak dengan faktor maksimal sebesar 0.2.
5. Normalisasi dilakukan nilai piksel menggunakan normalisasi *Z-score* dengan rata-rata untuk setiap *channel* warna pada gambar $R = 0.485$, $G = 0.456$, dan $B = 0.406$ serta standar deviasi untuk setiap *channel* secara berurutan 0,229, 0,224, dan 0,225. Nilai ini didapatkan dari perhitungan dataset ImageNet yang digunakan untuk pelatihan awal model *pretrained* Transformer yang selanjutnya dilatih menggunakan dataset ChaLearn untuk menyesuaikan kebutuhan prediksi kepribadian.

3.1.2 Arsitektur Model Regresi Transformer

Penelitian ini memanfaatkan arsitektur Transformer sebagai (*backbone*) untuk ekstraksi fitur visual dari citra wajah. Tiga varian model digunakan untuk dibandingkan kinerjanya, yaitu ViT, Swin Transformer V2, dan PvT V2. Ketiga model ini merupakan model yang telah dilatih sebelumnya (*pretrained*) pada dataset ImageNet untuk tugas klasifikasi gambar.



Gambar 3.3: Arsitektur Model Transformer untuk Regresi *Multi Target*


Adaptasi utama yang dilakukan dalam penelitian ini adalah mengubah fungsi model dari klasifikasi menjadi regresi multi-target (multi-target regression). Umumnya model-model tersebut memiliki lapisan akhir (*head*) berupa lapisan linier (*fully connected layer*) dengan ribuan

neuron *output* sesuai dengan jumlah kelas klasifikasi yang diikuti oleh fungsi aktivasi *softmax*. Struktur ini tidak relevan untuk prediksi nilai kepribadian yang bersifat kontinu. Arsitektur model dirancang menggunakan dua komponen utama, yaitu *backbone* dan *regression head*. Visualisasi arsitektur ini dapat dilihat pada Gambar 3.3. Berikut adalah penjelasan bagian dari arsitektur.

1. *Backbone Transformer*, bagian ini menggunakan *pre-trained Transformer ViT, Swin V2, dan PvT V2*. *Backbone* ini bertugas mengubah citra *input* menjadi representasi vektor global dengan dimensi D , di mana D bergantung pada varian model yang digunakan.
2. *Custom regression head*, bagian ini berfungsi untuk mengadaptasi model Transformer yang umumnya digunakan untuk klasifikasi. Berbeda dengan *head* klasifikasi standar, *head* ini dirancang khusus untuk tugas regresi *multi-output*. Komponen ini terdiri dari lapisan linear *fully connected* dengan matriks *weight* $W \in \mathbb{R}^{D \times 512}$, yang memetakan vektor fitur D ke 512 neuron *output* untuk memadatkan vektor fitur *backbone Transformer*. *Output* ini kemudian melewati *hidden layer Gaussian Error Linear Units (GELU)* untuk memetakan fitur non linear pada *regression head*. Dibandingkan dengan ReLU, GELU bersifat *smooth* dan probabilistik yang mengakomodasi nilai yang lebih kecil atau negatif sehingga menciptakan gradien yang lebih halus dan kontinu tanpa menghilangkan input sepenuhnya. Selanjutnya dilakukan regularisasi dengan menambahkan *layer Dropout* sebesar 30% dari total 512 input untuk mengurangi bias dan *overfitting*. 512 input ini kemudian dipetakan menjadi 5 nilai yang merepresentasikan nilai kepribadian *Big Five* menggunakan lapisan linear. Terakhir, *layer Sigmoid* digunakan untuk membatasi nilai *output* prediksi kepribadian yang valid dalam rentang 0 hingga 1.

3.1.3 Mekanisme Prediksi dan Pelatihan Model Kepribadian *Big Five*

Setelah fitur visual diekstraksi oleh *backbone Transformer*, model melakukan proses pelatihan model dengan melakukan prediksi nilai kepribadian yang dilanjutkan dengan *backpropagation* untuk memperbarui bobot model. Alur mekanisme ini diilustrasikan pada Gambar 3.4.



Gambar 3.4: Proses Prediksi dan Pelatihan Model Prediksi Kepribadian *Big Five*

Alur kerja model dibagi menjadi dua bagian, yaitu fase prediksi dan fase pelatihan untuk memperbarui bobot model.

1. Fase prediksi, vektor fitur yang dihasilkan oleh *backbone* dipetakan menjadi lima nilai kepribadian. Proses ini dilakukan pada *Custom Regression Head* yang dijelaskan pada subbab sebelumnya dengan label nilai kepribadian ChaLearn berada pada interval 0 hingga 1.
2. Fase pelatihan, untuk memastikan model mampu menghasilkan prediksi yang akurat, dilakukan proses pelatihan yang bertujuan meminimalkan kesalahan prediksi. *Loss function* yang digunakan adalah L1 Loss atau MAE. MAE mengukur rata-rata absolut selisih antara nilai prediksi dan nilai label sebenarnya untuk kelima dimensi kepribadian *Big Five*.

Nilai *loss* yang dihasilkan oleh MAE menjadi dasar bagi algoritma *backpropagation* untuk menghitung gradien kesalahan terhadap parameter model. Berdasarkan gradien tersebut, *optimizer* AdamW memperbarui bobot model secara iteratif. Penggunaan AdamW dipilih karena kemampuannya dalam menangani *weight decay* yang lebih efektif dibandingkan Adam standar sehingga membantu mencegah *overfitting* pada model berbasis Transformer.

3.1.4 Perancangan *Prompt* Interpretasi Kepribadian

Output dari model regresi berupa lima nilai numerik *Big Five*, misalnya *Openness* 0.85 dan *Neuroticism* 0.20 memberikan representasi kuantitatif namun sulit dipahami secara intuitif oleh pengguna awam. Oleh karena itu, diperlukan jembatan linguistik untuk menerjemahkan angka-angka tersebut menjadi narasi profil kepribadian yang deskriptif. Bagian ini membahas perancangan *prompt* yang berfungsi memandu LLM dalam menyusun interpretasi tersebut. Perancangan *prompt* dalam tugas akhir ini menerapkan dua strategi utama, yaitu *role-play prompting* yang bertujuan menetapkan persona spesifik kepada LLM untuk memastikan *tone* dan gaya bahasa yang dihasilkan bersifat profesional dan psikologis, serta penggunaan *contextual injection* untuk menyematkan data hasil prediksi yang berupa skor numerik dan data visual, yaitu citra wajah secara dinamis ke dalam struktur *prompt* sebagai konteks penalaran utama.

[SYSTEM INSTRUCTION]

Anda adalah seorang psikolog ahli dalam menganalisis kepribadian tampak. Berikan wawasan mendalam dengan cara yang empatik, ramah, konstruktif, seolah-olah Anda sedang memberikan konseling kepada pengguna, tetapi JANGAN sebutkan diri Anda sebagai psikolog kepada pengguna secara langsung."

[VISUAL CONTEXT]

<image_token>

[NUMERICAL CONTEXT]

Berdasarkan prediksi kepribadian Big Five berikut yang diekstraksi dari wajah pengguna:

- Openness (Keterbukaan): {val_0}
- Conscientiousness (Kehati-hatian): {val_C}
- Extraversion (Ekstraversi): {val_E}
- Agreeableness (Keramahan): {val_A}
- Neuroticism (Neurotisisme): {val_N}

[TASK INSTRUCTION]

Berikan asesmen kepribadian yang mendetail dan komprehensif. Analisis fitur visual dari gambar yang mungkin berkorelasi dengan sifat-sifat psikologis ini. Fokus hanya kepada asesmen kepribadian. Gunakan bahasa Indonesia yang baik dan benar.

CATATAN : berikan respon maksimal 1500 token

Gambar 3.5: Rancangan Struktur Prompt dengan Injeksi Konteks Multimodal


Struktur prompt disusun secara sistematis menjadi empat segmen blok informasi yang diilustrasikan pada Gambar 3.5.

1. **System Instruction:** Blok ini mendefinisikan peran LLM sebagai seorang ahli psikologi dan perilaku manusia. Instruksi ini bertujuan membatasi ruang pencarian model agar fokus pada terminologi psikologi kepribadian dan menghindari penggunaan bahasa yang terlalu teknis atau tidak relevan.
2. **Visual Context:** Blok ini menyertakan token khusus untuk memuat citra wajah subjek yang sudah diubah dalam bentuk Base64.
3. **Numerical Context:** Blok ini berisi variabel yang diisi dengan nilai prediksi dari model regresi. Format penyajian data dibuat terstruktur sebagai pasangan *key-value* agar mudah dibaca oleh LLM.

4. **Task Instruction:** Bagian ini berisi perintah spesifik mengenai format *output* yang diinginkan seperti batasan jumlah kata, penggunaan paragraf naratif, serta larangan untuk membuat asumsi di luar data yang diberikan.

3.1.5 Integrasi LLM untuk Interpretasi Kepribadian

Tahap selanjutnya dari arsitektur sistem adalah interpretasi kepribadian menggunakan LLM. Pada tahap ini, sistem mengintegrasikan data prediksi nilai kepribadian *Big Five* dengan inferensi LLM menggunakan layanan OpenRouter API. Alur integrasi sistem dirancang secara linear mulai dari akuisisi data, konstruksi *payload*, hingga hasil interpretasi diilustrasikan pada Gambar 3.6.




Gambar 3.6: Diagram Alir Proses Interpretasi Kepribadian dengan LLM

Proses integrasi ini terdiri dari lima tahapan utama:

1. **Praproses Input**, sistem mengambil dua jenis data input, yaitu citra wajah dan data skor *Big Five* yang merupakan nilai numerik hasil prediksi model regresi untuk dimasukkan ke dalam *prompt*. Data citra dikonversi menjadi Base64 untuk mengubah data biner menjadi *string* teks ASCII agar dapat ditransmisikan melalui protokol HTTP sebagai bagian dari objek JSON.
2. **Konstruksi Payload**, data citra yang berupa *string* Base64 dan skor *Big Five* digabungkan dan disusun ke dalam *message structure* yang berisi instruksi sistem dan konteks visual.
3. **Pemilihan Model**, disediakan dua model LLM untuk inferensi, yaitu Gemma 4 dan Qwen3-VL. Pemilihan ini menentukan parameter ID model yang akan dikirimkan ke server.
4. **API Request**, setelah *payload* siap, sistem mengirimkan HTTP POST Request melalui jaringan internet menuju OpenRouter API Gateway. Di sisi server, permintaan diteruskan ke mesin Inferensi LLM sesuai model yang dipilih untuk diproses.
5. **Penyajian Hasil**, setelah proses inferensi selesai, sistem akan menerima JSON Response dari server. Respons ini kemudian dilakukan *parsing* untuk diambil konten teks utama yang kemudian ditampilkan sebagai hasil interpretasi kepribadian.

3.1.6 Perancangan Sistem Asesmen Interpretasi Kepribadian

Sistem asesmen interpretasi kepribadian disusun sebagai sarana untuk mengakses model prediksi dan interpretasi kepribadian secara terintegrasi menggunakan *Application Programming Interface* API agar dapat digunakan dengan mudah oleh pengguna.



Gambar 3.7: Diagram Alir Sistem Interpretasi Kepribadian

Sistem ini terdiri dari tiga komponen, yaitu API Inferensi, API Interpretasi, dan antarmuka pengguna. Mekanisme komunikasi antara ketiga komponen ditunjukkan oleh gambar 3.7.

A. API Inferensi

API inferensi menyediakan akses bagi pengguna untuk melakukan prediksi nilai kepribadian *Big Five*. Tugas dari API inferensi meliputi praproses gambar yang diterima dari pengguna dan inferensi menggunakan model prediksi yang menghasilkan nilai kepribadian *Big Five* untuk digunakan pada tahap interpretasi selanjutnya.

B. API Interpretasi

API interpretasi merupakan sistem yang mengintegrasikan API inferensi dengan layanan OpenRouter API untuk menghasilkan deskripsi interpretasi kepribadian yang dapat dipahami oleh pengguna. API interpretasi memiliki beberapa tugas untuk menghasilkan hasil interpretasi kepribadian dari input berupa gambar yang dikirim oleh pengguna, yaitu:


1. Menerima *request* dari pengguna untuk melakukan interpretasi berdasarkan konfigurasi yang diberikan.
2. Mengirim gambar dan konfigurasi model ke API inferensi untuk mendapatkan hasil prediksi kepribadian *Big Five*.
3. Melakukan konversi gambar menjadi *string* Base64 agar dapat dipahami oleh LLM, menyusun *prompt* yang meliputi instruksi sistem, token gambar Base64, hasil prediksi kepribadian *Big Five*, serta instruksi tugas untuk menghasilkan interpretasi kepribadian pengguna.
4. Mengirimkan *request prompt* ke LLM melalui OpenRouter API dan menerima respons

hasil.

5. Mengirimkan hasil interpretasi kepribadian kepada pengguna.


C. Antarmuka Pengguna

Untuk menjembatani interaksi antara pengguna dengan sistem, diperlukan tampilan antarmuka grafis yang dapat diakses dengan mudah dan intuitif. Antarmuka ini dirancang untuk menguji sistem inferensi dan interpretasi kepribadian menggunakan aplikasi berbasis web. Tahap pertama yang dilakukan adalah proses *wireframing*, yaitu perancangan kerangka *website* yang meliputi struktur dan tata letak komponen dasar. Terdapat dua tampilan antarmuka yang disusun, yaitu tampilan inferensi yang digunakan untuk menguji sistem API Inferensi dan tampilan interpretasi yang digunakan untuk menguji sistem API Interpretasi.



Gambar 3.8: *Wireframe* Tampilan Inferensi

Alur penggunaan antarmuka inferensi dimulai dari pengguna mengunggah gambar wajah pada bagian *upload image* dan memilih model inferensi yang diinginkan pada bagian *inference model*. Pengguna kemudian menekan tombol *predict personality* untuk mengirim *request* menuju server. Hasil yang didapatkan berupa nilai kepribadian *Big Five* dan gambar hasil praproses yang digunakan model prediksi kepribadian untuk melakukan inferensi. Prototipe tampilan antarmuka inferensi dapat dilihat pada Gambar 3.8.



Gambar 3.9: *Wireframe* Tampilan Interpretasi

Selanjutnya untuk antarmuka interpretasi digunakan untuk menguji integrasi antara API Interpretasi, API Inferensi, dan layanan LLM melalui OpenRouter API. Prototipe tampilan antarmuka interpretasi ditunjukkan oleh Gambar 3.9. Pengguna mengunggah gambar wajah, kemudian memilih model inferensi yang tersedia pada API Inferensi, selanjutnya pengguna memilih LLM dan gaya respons yang digunakan. *Output* yang dihasilkan setelah pengguna menekan tombol *interpret personality* adalah hasil prediksi *Big Five* dan deskripsi interpretasi kepribadian yang dihasilkan dari LLM. Pengguna juga dapat menyimpan hasil interpretasi dalam bentuk JSON yang dapat digunakan untuk evaluasi hasil interpretasi kepribadian.

3.1.7 Skenario Evaluasi

Evaluasi sistem dilakukan secara menyeluruh yang mencakup dua aspek utama, yaitu kinerja model regresi dalam memprediksi nilai kepribadian *Big Five* dan kualitas teks interpretasi kepribadian yang dihasilkan oleh LLM.

A. Evaluasi Model Prediksi Kepribadian *Big Five*

Evaluasi model prediksi dilakukan dengan mengukur akurasi prediksi nilai numerik kepribadian terhadap nilai ground truth. Tugas akhir ini menggunakan metrik evaluasi regresi standar yang meliputi MAE untuk mengukur rata-rata kesalahan absolut prediksi, Accuracy untuk merepresentasikan tingkat ketepatan model dalam skala 0 hingga 1, RMSE untuk mendeteksi kesalahan prediksi yang bernilai besar, serta *Coefficient of Determination* (R^2) untuk melihat seberapa baik model dapat menjelaskan variabilitas data. Metrik utama yang digunakan untuk menentukan model terbaik adalah Accuracy Terdapat 6 model *pretrained* yang diujikan. Model-model yang diujikan ditunjukkan oleh Tabel 3.1.

Tabel 3.1: Daftar Model Transformer *Pretrained* yang Diujikan

Model	Deskripsi
ViT-B/16 AugReg (IN21k)	Model <i>backbone</i> klasifikasi ViT yang dilatih dengan dataset ImageNet-21k dengan tambahan augmentasi dan regularisasi.
ViT-B/16 AugReg (IN21k+1k)	Model <i>backbone</i> klasifikasi ViT yang dilatih dengan dataset ImageNet-21k dan dilakukan <i>fine-tuning</i> pada ImageNet-1k dengan tambahan augmentasi dan regularisasi.
ViT-B/16 AugReg2 (IN21k+1k)	Model <i>backbone</i> klasifikasi ViT yang dilatih dengan dataset ImageNet-21k dan dilakukan <i>fine-tuning</i> ulang pada ImageNet-1k dengan tambahan augmentasi yang lebih kompleks dan regularisasi.
SwinV2-B w16 (IN1k)	Model <i>backbone</i> klasifikasi Swin Transformer v2 dengan ukuran <i>window</i> 16×16 yang dilatih dengan dataset ImageNet-1k.
SwinV2-B w12-16 (IN22k+1k)	Model <i>backbone</i> klasifikasi Swin Transformer v2 dengan ukuran <i>window</i> 12×12 yang dapat diperbesar menjadi 16×16 , dilatih dengan dataset ImageNet-22k dan dilakukan <i>fine-tuning</i> menggunakan dataset ImageNet-1k.
PVTv2-B5 (IN1k)	Model <i>backbone</i> klasifikasi PVT-v2 yang dilatih dengan dataset ImageNet-1k.

Setiap model dilatih menggunakan *hyperparameter* yang dijelaskan pada Tabel 3.2. Proses pelatihan menggunakan *early stopping* dengan *patience* = 5 untuk mencegah *overfitting*. Pelatihan model menggunakan strategi *differential learning rate* dimana bagian *backbone* dilatih dengan *learning rate* yang lebih kecil dari *regression head* untuk melindungi generalisasi fitur yang telah dipelajari pada *backbone* model *pretrained* dan mempercepat konvergensi pada *regression head*. *Learning rate* pada pelatihan model untuk setiap *epoch* disesuaikan secara dinamis menggunakan *cosine annealing scheduler*, dimana *learning rate* diturunkan secara bertahap mengikuti kurva kosinus hingga maksimal parameter yang ditentukan. Hal ini dilakukan agar model dapat mencapai titik konvergensi yang lebih presisi. Penurunan nilai *learning rate* yang semakin melandai di akhir proses pelatihan memungkinkan *weight update* yang lebih halus sehingga mencegah model mengalami osilasi saat sudah berada di dekat titik minimum *loss* global. Teknik *gradient clipping* juga digunakan dengan *L2Norm* untuk mencegah gradien yang terlalu besar (*exploding gradient*) yang menyebabkan perubahan *weight* secara drastis.

Tabel 3.2: Konfigurasi *Hyperparameter* Pelatihan Model Prediksi Kepribadian

<i>Hyperparameter</i>	Nilai
<i>Batch Size</i>	32
<i>Epochs</i>	100
<i>Early Stopping Patience</i>	5

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 3.2

<i>Hyperparameter</i>	Nilai
<i>Loss Function</i>	L1Loss (MAE)
<i>Gradient Clipping</i>	1,0 (L2 Norm)
<i>Regression Head Learning Rate</i>	1×10^{-4}
<i>Backbone Learning Rate</i>	1×10^{-5}
<i>Weight Decay</i>	0,01
<i>Learning Rate Scheduler</i>	Cosine Annealing
<i>Minimum Learning Rate Scheduler</i>	1×10^{-6}

Selain itu, dilakukan uji ablasi dengan 4 jenis skenario yang dibuat untuk setiap model dengan tujuan mengetahui pengaruh skenario yang diujikan terhadap kinerja model. Detail mengenai skenario yang diujikan dapat dilihat pada Tabel 3.3.

Tabel 3.3: Daftar Skenario Model Prediksi yang Diujikan

No	Skenario	Penjelasan
1	<i>Baseline</i>	Skenario ini menggunakan model <i>pretrained</i> dengan adaptasi <i>regression head</i> menggunakan <i>linear layer</i> dengan 5 neuron dan <i>hidden layer</i> sigmoid sebagai pembanding dasar model prediksi untuk 5 sifat kepribadian <i>Big Five</i> tanpa augmentasi gambar pada tahap praproses dataset latih.
2	<i>Arch Tuning</i>	Skenario ini menggunakan model <i>pretrained</i> dengan <i>custom regression head</i> yang dijelaskan pada Subbab 3.1.2 tanpa augmentasi gambar pada tahap praproses dataset latih.
3	Augmentasi	Skenario ini menggunakan model <i>pretrained</i> yang sama seperti skenario <i>baseline</i> , dengan menggunakan proses augmentasi gambar pada tahap praproses dataset latih seperti yang dijelaskan pada Subbab 3.1.1.
4	<i>Arch Tuning</i> + Augmentasi	Skenario ini merupakan gabungan dari skenario 2 dan 3 yang menggunakan model <i>pretrained</i> dengan <i>custom regression head</i> yang dijelaskan pada Subbab 3.1.2 dan menggunakan alur praproses dataset yang dijelaskan pada Subbab 3.1.1.

B. Evaluasi Kualitas Interpretasi Kepribadian

Evaluasi kualitas teks interpretasi dilakukan menggunakan G-Eval dengan GPT-5.1 sebagai evaluator. Pendekatan ini dipilih karena GPT-5.1 memiliki korelasi tinggi dengan penilaian manusia dan mampu melakukan penalaran bertahap (*Chain-of-Thought*) dalam memberikan skor. Terdapat tiga jenis kriteria yang digunakan dalam mengevaluasi teks hasil generasi interpretasi kepribadian yang ditunjukkan oleh Tabel 3.4. Tiga kriteria ini ditujukan untuk menilai kualitas

hasil generasi teks layaknya seorang psikolog profesional yang melakukan asesmen kepribadian sesuai dengan gambar yang diberikan. G-Eval memberikan nilai antara 0 hingga 1 untuk setiap kriteria yang diberikan. Terdapat dua jenis skenario yang dibuat untuk menguji pengaruh *role-play prompt* terhadap kualitas narasi interpretasi kepribadian yang dihasilkan. Skenario 1 adalah skenario menggunakan rancangan *prompt* yang dijelaskan pada Subbab 3.1.4 dan skenario 2 adalah skenario 1 tanpa menggunakan strategi *role-play prompting* sehingga *prompt* yang disusun terdiri dari tiga segmen blok informasi tanpa *System Instruction*.

Tabel 3.4: Kriteria Evaluasi Teks Interpretasi Kepribadian dengan G-Eval

No	Jenis Kriteria	Deskripsi
1	Koherensi Gambar	Menilai kesesuaian dan konsistensi fitur fisik atau kesan visual dalam teks intepretasi kepribadian dengan gambar yang diberikan.
2	Akurasi Penilaian Psikologis	Mengevaluasi akurasi dan kesesuaian interpretasi kepribadian terhadap nilai kepribadian <i>Big Five</i> yang diberikan. <i>Openness</i> tinggi harus berkaitan dengan deskripsi kreativitas/rasa ingin tahu. <i>Conscientiousness</i> tinggi harus menyebutkan kedisiplinan/keteraturan. <i>Extraversion</i> tinggi harus menggambarkan keramahan sosial. <i>Agreeableness</i> tinggi harus merujuk pada kerja sama/empati. <i>Neuroticism</i> tinggi harus sesuai dengan sensitivitas emosional. Skor rendah jika teks bertentangan atau mengabaikan skor kepribadian.
3	Persona Psikolog	Mengevaluasi persona/gaya teks generasi interpretasi kepribadian layaknya seorang psikolog yang memberikan asesmen kepribadian dengan nada empatik, hangat, dan profesional yang terwujud secara natural tanpa menyebutkan diri sebagai seorang psikolog. Skor rendah jika kesan respons terlalu kaku, dingin, atau santai.

3.2 Bahan dan Peralatan yang Digunakan

Tugas akhir ini dilaksanakan menggunakan peralatan pendukung yang terdiri dari perangkat keras dan perangkat lunak. Perangkat keras yang digunakan adalah laptop HP Victus 15 dengan prosesor AMD Ryzen 5 240, RAM 16GB, dan GPU NVIDIA RTX 5050 yang digunakan untuk pengembangan kode dan praproses data, serta sumber daya *cloud computing* menggunakan platform runpod yang menyediakan GPU NVIDIA RTX 5090 untuk akselerasi proses pelatihan model. Selain itu, Huggingface Spaces dan Azure VM digunakan untuk proses *deployment* sistem asesmen kepribadian yang meliputi tahap inferensi dan interpretasi. Adapun perangkat lunak yang digunakan adalah Jupyter Notebook yang menyediakan lingkungan pelatihan model. Implementasi sistem dibangun menggunakan bahasa pemrograman Python dengan dukungan *library* PyTorch Image Models (timm) untuk *deep learning*, MediaPipe dan OpenCV untuk pengolahan visual, serta penggunaan OpenRouter API untuk mengakses LLM yang digunakan dalam tahap interpretasi.

3.3 Urutan Pelaksanaan Penelitian

Bagian ini membahas mengenai langkah-langkah penelitian secara detail, meliputi proses dan kode semu yang digunakan pada penelitian.

3.3.1 Implementasi Praproses Dataset

Implementasi tahapan praproses dataset pada bagian ini meliputi ekstraksi *frame* dari video, pemberian label, *upload* dataset ke HuggingFace, dan pengubahan ukuran, augmentasi, serta normalisasi gambar. Input awal berupa folder berisi dataset Chalearn yang telah dilakukan pemisahan menjadi *train*, *val*, dan *test*. Selanjutnya untuk setiap video pada folder dilakukan ekstraksi *frame* sebanyak 1 gambar per detik video. Kemudian dilakukan deteksi wajah menggunakan model BlazeFace pada MediaPipe. Jika terdapat lebih dari satu wajah, maka akan dilakukan seleksi untuk menentukan wajah utama berdasarkan ukuran dan posisi wajah relatif terhadap bagian tengah *frame*. Proses ini dilakukan pada setiap *frame* untuk melacak pergerakan wajah agar hasil yang didapatkan konsisten antar satu *frame* dengan yang lain. Implementasi secara detail dapat dilihat pada Kode Semu 3.1.

Input: Folder dataset Chalearn

Output: Direktori berisi gambar yang telah dilakukan praproses

```
1: FaceDetector  $\leftarrow$  Inisialisasi model pretrained deteksi wajah
2: OffsetPercentage  $\leftarrow$  0.30  $\triangleright$  Parameter penambahan padding untuk cropping gambar
3: for each Video  $\in$  Dataset do
4:   Frames  $\leftarrow$  Ekstrak 1 frame dari Video per 1 detik
5:   Tracks  $\leftarrow \emptyset$   $\triangleright$  Deteksi wajah & tracking
6:   for each Frame  $\in$  Frames do
7:     Faces  $\leftarrow$  FaceDetector(Frame)
8:     for each Face  $\in$  Faces do
9:       Area  $\leftarrow$  Width  $\times$  Height
10:      Dist  $\leftarrow \sqrt{(Frame_{cx} - Face_{cx})^2 + (Frame_{cy} - Face_{cy})^2}$ 
11:      Score  $\leftarrow (Area \times Confidence) - (Dist \times 50)$ 
12:      Cari BestTrack  $\in$  Tracks dengan jarak paling kecil dari Face.Center
13:      if BestTrack and Dist  $< \frac{Frame_{width}}{3}$  then
14:        BestTrack.TotalScore  $\leftarrow$  BestTrack.TotalScore + Score
15:        BestTrack.BoundingBoxes[Frame]  $\leftarrow$  Face.BoundingBox
16:        BestTrack.LastCenter  $\leftarrow$  Face.Center
17:      else
18:        NewTrack  $\leftarrow$  Buat Track yang diinisialisasi dengan Score, Face.BoundingBox
19:        Tracks  $\leftarrow$  Tracks  $\cup$  {NewTrack}
20:      end if
21:    end for
22:  end for
23:  if Tracks  $\neq \emptyset$  then  $\triangleright$  Seleksi subjek & Cropping
24:    ChosenTrack  $\leftarrow$   $\arg \max_{t \in Tracks} (t.TotalScore)$ 
25:    for each Frame  $\in$  Frames do
26:      if Frame  $\in$  ChosenTrack.BoundingBoxes then
27:        Terapkan OffsetPercentage padding ke ChosenTrack.BoundingBoxes[Frame]
28:        Crop Frame dan simpan ke direktori output
29:      end if
```

```

30:         end for
31:     end if
32: end for

```

Kode Semu 3.1: Implementasi Praproses Dataset dari Video menjadi Gambar

Tahap selanjutnya adalah pembuatan label untuk setiap gambar dan *upload* dataset ke HuggingFace. Hal ini dilakukan untuk memudahkan akses dataset bersih yang digunakan pada alur pelatihan model. Daftar label pada dataset dibuat dalam bentuk CSV yang diekstrak dari label asli yang berbentuk pickle. Hapus kolom 'interview' karena tidak diperlukan untuk prediksi. Kemudian untuk setiap label dengan nama video, dilakukan pemberian label untuk setiap *frame* yang berasal dari video tersebut. Proses ini dilakukan untuk setiap dataset *split train*, *val*, dan *test*. Implementasi secara detail dapat dilihat pada Kode Semu 3.2.

Input:

- *DatasetRoot*: Direktori lokal berisi folder *split* dan label asli *annotation.pkl* berbentuk pickle
- *RepoID*: Nama repositori target Huggingface

Output: Dataset bersih yang dapat diakses secara *remote* pada HuggingFace

```

1: for each Split ∈ {train, val, test} do
2:     Labels ← Ekstrak annotation.pkl menjadi annotation.csv dan muat data.
3:     Hapus kolom 'interview' dari Labels
4:     Metadata ← ∅
5:     Frames ← Dapatkan semua frame pada DatasetRoot/Split/
6:     for each Frame ∈ Frames do
7:         VideoID ← Ekstrak video identifier dari nama file Frame
8:         Row ← Cari VideoID di dalam Labels
9:         if Row then
10:            Entry ← Row
11:            Entry['file_name'] ← Base nama file dari Frame
12:            Metadata ← Metadata ∪ {Entry}
13:         end if
14:     end for
15:     Simpan Metadata sebagai metadata.csv di dalam direktori DatasetRoot/Split/
16: end for
17: Autentikasi koneksi ke repositori remote
18: Dataset ← Kompilasi dataset menjadi format Huggingface menggunakan load_dataset
    pada DatasetRoot
19: Push Dataset ke repositori remote RepoID

```

Kode Semu 3.2: Pemberian Label dan Upload Dataset ke HuggingFace

Tahap terakhir yang dilakukan adalah pengubahan ukuran gambar, augmentasi untuk skenario dengan augmentasi, dan normalisasi gambar. Pada tahap ini, untuk setiap gambar pada dataset, dilakukan pengubahan ukuran gambar sesuai dengan input arsitektur model, kemudian apabila diperlukan augmentasi, dilakukan *horizontal flip* secara acak dengan kemungkinan 0.5, rotasi acak dengan sudut maksimal 10°, dan pengubahan kecerahan serta kontras secara acak dengan intensitas 0.2. Selanjutnya dilakukan konversi gambar menjadi unit tensor yang dapat

diproses oleh model serta penerapan normalisasi *Z-score* dengan nilai standar yang didapatkan dari dataset ImageNet. Implementasi secara detail dapat dilihat pada Kode Semu 3.3.

Input:

- *Images*: *batch* gambar input
- *ImageSize*: Resolusi target gambar untuk input arsitektur
- *ApplyAugmentation*: variabel *boolean* untuk penerapan augmentasi data

Output: *ProcessedImages*: *Batch* Tensor yang telah dinormalisasi

```

1: ProcessedImages  $\leftarrow \emptyset$ 
2: for each Img  $\in$  Images do
3:   Img  $\leftarrow$  Resize(Img, ImageSize  $\times$  ImageSize)
4:   if ApplyAugmentation is True then
5:     Img  $\leftarrow$  RandomHorizontalFlip(Img, p = 0.5)
6:     Img  $\leftarrow$  RandomRotation(Img, limit =  $\pm 10^\circ$ )
7:     Img  $\leftarrow$  ColorJitter(Img, brightness = 0.2, contrast = 0.2)
8:   end if
9:   Tensor  $\leftarrow$  ConvertToTensor(Img)
10:  Normalized  $\leftarrow$  Normalize(Tensor,  $\mu = [0.485, 0.456, 0.406]$ ,  $\sigma = [0.229, 0.224, 0.225]$ )
11:  ProcessedImages  $\leftarrow$  ProcessedImages  $\cup \{Normalized\}$ 
12: end for
13: return ProcessedImages

```

Kode Semu 3.3: Implementasi Pengubahan Ukuran Gambar, Augmentasi, dan Normalisasi

3.3.2 Implementasi Alur Pelatihan Model

Pengujian skenario dan model prediksi dilakukan pada tahap ini. Model yang digunakan terdiri dari enam model *pretrained* yang disebutkan pada Tabel 3.1 dan setiap model diujikan menggunakan empat skenario yang dijelaskan pada Tabel 3.3 sehingga terdapat total 24 kali pelatihan model dalam tahap ini. Input yang diberikan berupa dataset mentah yang sebelumnya telah di *upload* ke HuggingFace, daftar model *pretrained* yang digunakan, dan konfigurasi skenario. Pada proses pelatihan digunakan dataset *split train* untuk melatih model dan *val* untuk validasi model pada setiap *epoch*. Setiap model menggunakan *hyperparameter* yang sama yang dijelaskan pada Tabel 3.2. Proses *checkpointing* pada setiap *epoch* dilakukan untuk menyimpan parameter dan *weight* model terbaik sehingga proses pelatihan dapat dilanjutkan jika terdapat kesalahan tanpa harus mengulang dari awal. Setiap model terbaik pada setiap perulangan disimpan dan diupload ke repositori HuggingFace untuk selanjutnya digunakan pada tahap evaluasi untuk mencari model terbaik. Detail implementasi alur pelatihan model dapat dilihat pada Kode Semu 3.4.

Input:

- *RawTrainData*, *RawValData*: *batch* dataset *split* yang terdiri dari (*Image*, *Targets*)
- *ModelList*: Daftar model *backbone* Transformer yang digunakan
- *Scenarios*: Konfigurasi skenario (*AugmentData*, *RegressionHead*)

Output: Model terbaik dan histori pelatihan untuk seluruh skenario

```

1: for each Architecture  $\in$  ModelList do
2:   ImageSize  $\leftarrow$  256 if Architecture is SwinV2 else 224
3:   for each Scenario  $\in$  Scenarios do

```

```

4:   Model  $\leftarrow$  Inisialisasi BigFiveRegressor(Architecture, Scenario.ReggressionHead)
5:   Optimizer  $\leftarrow$  Inisialisasi AdamW
6:   Scheduler  $\leftarrow$  CosineAnnealingLR
7:   BestValLoss  $\leftarrow \infty$ , PatienceCounter  $\leftarrow 0$ 
8:   for epoch = 1 to Epochs do
9:     Model.train()
10:    TrainLoss  $\leftarrow 0$ 
11:    for each batch (RawImages, Targets)  $\in$  RawTrainData do
12:       $\triangleright$  Panggil Kode Semu 3.3 untuk praproses gambar
13:      Images  $\leftarrow$  Preprocess(RawImages, ImageSize, Scenario.AugmentData)
14:      Predictions  $\leftarrow$  Model(Images)
15:      Loss  $\leftarrow$  L1Loss(Predictions, Targets)
16:      Hitung gradien dengan backpropagation
17:      Gradient clipping ke max norm 1.0
18:      Perbarui weights dengan Optimizer
19:      TrainLoss  $\leftarrow$  TrainLoss + Loss
20:    end for
21:    Scheduler.step()
22:    ValMetrics  $\leftarrow$  Evaluasi(Model, RawValData, ImageSize)
23:    if ValMetrics.Loss < BestValLoss then
24:      BestValLoss  $\leftarrow$  ValMetrics.Loss
25:      PatienceCounter  $\leftarrow 0$ 
26:      Simpan Model weights sebagai checkpoint terbaik.
27:    else
28:      PatienceCounter  $\leftarrow$  PatienceCounter + 1
29:      if PatienceCounter  $\geq$  PatienceLimit then
30:        break  $\triangleright$  Mekanisme Early Stopping
31:      end if
32:    end if
33:  end for
34:  Push Model terbaik ke repositori Huggingface
35:  Hapus cache pada memori GPU
36: end for
37: end for

```

Kode Semu 3.4: Proses Pelatihan Model Prediksi Kepribadian dengan Berbagai Skenario

3.3.3 Implementasi Sistem Asesmen Kepribadian

Sistem asesmen kepribadian terdiri dari API Inferensi dan API Interpretasi untuk menghasilkan hasil interpretasi kepribadian dari gambar. API Inferensi menerima input berupa gambar yang telah diubah dalam bentuk Base64. Selanjutnya dilakukan proses *decoding* untuk mengubah *string* Base64 menjadi format gambar yang dapat dibaca oleh model inferensi. Kemudian dilakukan praproses dan pengubahan ukuran sesuai dengan input model yang dipilih. Hasil *output* berupa nilai prediksi kepribadian *Big Five* dan gambar hasil praproses dari *cropping* dan pemilihan wajah yang juga merupakan input model. Implementasi API Inferensi dapat dilihat pada Kode Semu 3.5.

Input:

- *ImageBase64*: String Base64 gambar input dari pengguna
- *ModelType*: Jenis arsitektur model (ViT, SwinV2, PVTv2)

Output:

- *BigFiveTraits*: Objek berisi 5 nilai prediksi kepribadian *Big Five*
- *CroppedFaceBase64*: Gambar wajah hasil deteksi dalam format Base64

```

1: procedure PREDICTPERSONALITY(ImageBase64, ModelType)
2:   ImgRaw  $\leftarrow$  DecodeBase64(ImageBase64)
3:   Img  $\leftarrow$  LoadRGBImage(ImgRaw)
4:   CroppedFace  $\leftarrow$  ExtractMainFace(Img) ▷ Penentuan wajah utama
5:   if CroppedFace is None then
6:     return Error: "No face detected in the image"
7:   end if
8:   CroppedFaceBase64  $\leftarrow$  EncodeBase64(CroppedFace)
9:   ImageSize  $\leftarrow$  GetTargetResolution(ModelType)
10:  ImgResized  $\leftarrow$  Resize(CroppedFace, ImageSize  $\times$  ImageSize)
11:  Tensor  $\leftarrow$  ConvertToTensor(ImgResized)
12:  Normalized  $\leftarrow$  Normalize(Tensor,  $\mu = [0.485, 0.456, 0.406]$ ,  $\sigma = [0.229, 0.224, 0.225]$ )
  ▷ Normalisasi gambar
13:  InputBatch  $\leftarrow$  AddBatchDimension(Normalized)
14:  Model  $\leftarrow$  LoadPretrainedModel(ModelType) ▷ Muat model prediksi ke memori
15:  Model.eval() ▷ Atur model dalam mode inferensi
16:  RawScores  $\leftarrow$  Model(InputBatch) ▷ Proses inferensi model
17:  BigFiveTraits  $\leftarrow$   $\emptyset$  ▷ Standarisasi prediksi ke format Big Five
18:  BigFiveTraits.Extraversion  $\leftarrow$  RawScores[0]
19:  BigFiveTraits.Neuroticism  $\leftarrow$  RawScores[1]
20:  BigFiveTraits.Agreeableness  $\leftarrow$  RawScores[2]
21:  BigFiveTraits.Conscientiousness  $\leftarrow$  RawScores[3]
22:  BigFiveTraits.Openness  $\leftarrow$  RawScores[4]
23:  return BigFiveTraits, CroppedFaceBase64
24: end procedure

```

Kode Semu 3.5: Alur Utama API Inferensi Prediksi Kepribadian *Big Five*

API interpretasi menerima input dari pengguna berupa gambar, konfigurasi model yang digunakan untuk inferensi, jenis LLM, dan gaya respons. Selanjutnya, gambar dan konfigurasi model inferensi dikirimkan menuju API inferensi untuk mendapatkan hasil prediksi kepribadian *Big Five*. Setelah hasil didapatkan, API Interepretasi membuat *request* ke LLM melalui OpenRouter dengan gambar, hasil inferensi API inferensi, dan *prompt* yang telah dibuat pada direktori lokal dan mendapatkan hasil berupa teks hasil interpretasi kepribadian berdasarkan gambar dan nilai kepribadian *Big Five*. Implementasi API Interpretasi dapat dilihat pada Kode Semu 3.6.

Input:

- *ImageBase64*: String Base64 gambar input dari pengguna
- *InferenceModel*: Arsitektur model prediksi kepribadian *Big Five*
- *LLMModel*: ID LLM (Gemma, Qwen-VL)
- *StyleID*: Identifikasi gaya bahasa dan format respons

Output:

- *BigFiveTraits*: Objek berisi 5 nilai prediksi kepribadian *Big Five*
- *Interpretation*: Teks hasil interpretasi kepribadian dari LLM

```

1: procedure INTERPRETPERSONALITY(ImageBase64, InferenceModel, LLMModel, StyleID)
2:   IsAllowed  $\leftarrow$  CheckAllowedLLMModel(LLMModel)
3:   if IsAllowed is False then
4:     return Error: "LLM model is not allowed"
5:   end if
6:   InferenceResponse  $\leftarrow$  CallInferenceAPI(InferenceModel, ImageBase64)  $\triangleright$ 
   Prediksi Nilai Big Five dengan API Inferensi
7:   BigFiveTraits  $\leftarrow$  InferenceResponse.Predictions
8:   MatchedStyle  $\leftarrow$  GetStyleConfig(StyleID)
9:   if MatchedStyle is None then
10:    MatchedStyle  $\leftarrow$  GetDefaultStyleConfig("comprehensive_id")
11:  end if
12:  PromptTemplate  $\leftarrow$  LoadTextFile(MatchedStyle.TemplateFile)
13:  Prompt  $\leftarrow$  FormatString(PromptTemplate, BigFiveTraits)  $\triangleright$  Substitusi nilai Big
   Five ke template prompt
14:  Messages  $\leftarrow$   $\emptyset$ 
15:  if MatchedStyle.SystemTemplateFile exists then
16:    SystemPrompt  $\leftarrow$  LoadTextFile(MatchedStyle.SystemTemplateFile)
17:    Messages  $\leftarrow$  Messages  $\cup$  {SystemMessage(SystemPrompt)}
18:  end if
19:  ImageURI  $\leftarrow$  AddDataURIPrefixIfNeeded(ImageBase64)
20:  Messages  $\leftarrow$  Messages  $\cup$  {UserMessageWithImage(Prompt, ImageURI)}
21:  LLMResponse  $\leftarrow$  CallOpenRouterAPI(LLMModel, Messages, MaxTokens =
   2500)  $\triangleright$  Proses interpretasi teks oleh LLM
22:  Interpretation  $\leftarrow$  LLMResponse.Choices[0].Message.Text
23:  return BigFiveTraits, Interpretation
24: end procedure

```

Kode Semu 3.6: Alur Utama API Interpretasi Kepribadian

3.3.4 Implementasi Alur Evaluasi Sistem Asesmen

Bagian ini membahas mengenai implementasi alur evaluasi sistem asesmen yang terdiri dari model prediksi regresi *Big Five* dan interpretasi kepribadian.

A. Implementasi Evaluasi Model Prediksi Regresi Kepribadian *Big Five*

Evaluasi model prediksi regresi kepribadian *Big Five* dilakukan menggunakan dataset *split test* untuk menentukan model terbaik. Metrik yang digunakan untuk memilih model terbaik adalah akurasi yang dinormalisasi, yang merupakan metrik standar dalam dataset Chalearn. Model terbaik yang dipilih adalah model prediksi terbaik secara keseluruhan dan model terbaik untuk setiap *trait Big Five*. Implementasi alur evaluasi model prediksi regresi kepribadian dapat dilihat pada Kode Semu 3.7.

Input:

- *TestDataset*: Dataset uji (*Test Set*)
- *ModelsList*: Daftar model prediksi yang telah dilatih

Output:

- *EvaluationMetrics*: Metrik kinerja setiap model (MAE, Akurasi)
- *BestOverallModel*: Model terbaik secara keseluruhan
- *BestPerTraitModels*: Daftar model terbaik untuk setiap *trait* kepribadian *Big Five*

```

1: procedure EVALUATEMODELS(TestDataset, ModelsList)
2:   DummyMeans  $\leftarrow$  CalculateMeanTraits(TestDataset)           ▷ Hitung baseline dari
   rata-rata label
3:   Results  $\leftarrow \emptyset$ 
4:   for each Model  $\in$  ModelsList do
5:     Model.eval()
6:     AllPredictions  $\leftarrow \emptyset$ , AllLabels  $\leftarrow \emptyset$ 
7:     for each Batch  $\in$  TestDataset do
8:       Inputs, Labels  $\leftarrow$  Batch.images, Batch.traits
9:       with torch.no_grad() :
10:        Predictions  $\leftarrow$  Model(Inputs)           ▷ Lakukan prediksi pada data tes
11:        AllPredictions  $\leftarrow$  AllPredictions  $\cup$  Predictions
12:        AllLabels  $\leftarrow$  AllLabels  $\cup$  Labels
13:     end for
14:     Perhitungan Metrik Evaluasi
15:     ModelMAE  $\leftarrow$  MeanAbsoluteError(AllLabels, AllPredictions)
16:     DummyMAE  $\leftarrow$  MeanAbsoluteError(AllLabels, DummyMeans)
17:     RMSE  $\leftarrow$  RootMeanSquaredError(AllLabels, AllPredictions)
18:     R2Score  $\leftarrow$  R2Score(AllLabels, AllPredictions)
19:     Accuracy  $\leftarrow$   $1 - \text{ModelMAE}$            ▷ Hitung akurasi absolut (1 - MAE)
20:     NormalizedAccuracy  $\leftarrow$   $1 - \frac{\text{ModelMAE}}{\text{DummyMAE}}$            ▷ Akurasi yang dinormalisasi
21:     ModelResults  $\leftarrow$  {Model, ModelMAE, DummyMAE, RMSE, R2Score, Accuracy, NormalizedAccuracy}
22:     Results  $\leftarrow$  Results  $\cup$  ModelResults
23:   end for
24:   Seleksi Model Terbaik
25:   BestOverallModel  $\leftarrow$  ArgMax(Results, key = Mean(NormalizedAccuracy))   ▷
   Terbaik rata-rata
26:   BestPerTraitModels  $\leftarrow \emptyset$ 
27:   for each Trait  $\in$  {O, C, E, A, N} do
28:     BestModel  $\leftarrow$  ArgMax(Results, key = NormalizedAccuracyTrait) ▷ Pemilihan
   model terbaik per trait
29:     BestPerTraitModels  $\leftarrow$  BestPerTraitModels  $\cup$  {Trait : BestModel}
30:   end for
31:   return Results, BestOverallModel, BestPerTraitModels
32: end procedure

```

Kode Semu 3.7: Alur Evaluasi dan Pemilihan Model Prediksi Regresi *Big Five* Terbaik

B. Implementasi Evaluasi Kualitas Interpretasi Kepribadian

Evaluasi kualitas interpretasi kepribadian dilakukan menggunakan G-Eval dengan LLM penilai independen yang berbeda dengan model yang digunakan dalam proses interpretasi. Input yang diberikan berupa kumpulan *file* JSON berisi konfigurasi model, gambar, nilai prediksi *Big Five*, dan hasil interpretasi. Hasil interpretasi ini kemudian dievaluasi dengan G-Eval berdasarkan kriteria yang diberikan. G-Eval memberikan skor beserta alasan (*reasoning*) untuk setiap

kriteria dan hasil interpretasi yang diberikan. Untuk mencegah pengulangan evaluasi hasil interpretasi yang sudah diproses, dilakukan sistem *checkpoint* untuk mencatat hasil interpretasi kepribadian yang telah dievaluasi. Implementasi alur evaluasi hasil interpretasi kepribadian dijelaskan pada Kode Semu 3.8.

Input:

- *EvaluatorModel*: LLM penilai independen (gpt-5.1)
- *MetricsConfig*: Daftar kriteria penilaian (Koherensi, Akurasi, Persona)
- *GeneratedSamples*: Kumpulan file JSON berisi input gambar, nilai *traits Big Five*, dan hasil teks interpretasi

Output:

- *Checkpoint*: File hasil berisi skor dan (*reasoning*) G-Eval untuk semua sampel

```

1: procedure GEVALPIPELINE(EvaluatorModel, MetricsConfig, GeneratedSamples)
2:   Checkpoint  $\leftarrow$  LoadExistingResults()  $\triangleright$  Muat riwayat evaluasi untuk resume otomatis
3:   for each Sample  $\in$  GeneratedSamples do
4:     InputData  $\leftarrow$  {Sample.Traits, Sample.ImageBase64}
5:     ActualOutput  $\leftarrow$  Sample.Interpretation
6:     if Sample is fully valid in Checkpoint then
7:       Continue  $\triangleright$  Lewati sampel jika sudah pernah dievaluasi dengan sukses
8:     end if
9:     TestCase  $\leftarrow$  LLMTestCase(Input = InputData, ActualOutput = ActualOutput)
10:    SampleMetrics  $\leftarrow$   $\emptyset$ 
11:    for each Metric  $\in$  MetricsConfig do
12:      GEval  $\leftarrow$  DynamicMultimodalMetric(Metric.Name, Metric.Criteria, EvaluatorModel)
13:      try:
14:        Score  $\leftarrow$  GEval.Measure(TestCase)  $\triangleright$  LLM penilai memberikan skor
numerik
15:        Reason  $\leftarrow$  GEval.GetReasoning()  $\triangleright$  LLM memberikan justifikasi tekstual
16:        Passed  $\leftarrow$  (Score  $\geq$  Metric.Threshold)
17:      except APIError:
18:        Abort dan simpan status (menghindari kerusakan checkpoint)
19:        SampleMetrics  $\leftarrow$  SampleMetrics  $\cup$  {Metric.Name, Score, Reason, Passed}
20:      end for
21:      Checkpoint[Sample.ID]  $\leftarrow$  SampleMetrics
22:      SaveToDisk(Checkpoint)  $\triangleright$  Simpan skor setiap satu iterasi selesai
23:    end for
24:    return Checkpoint
25: end procedure

```

Kode Semu 3.8: Alur Evaluasi Hasil Interpretasi Kepribadian Menggunakan G-Eval

Halaman ini sengaja dikosongkan

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Penelitian

Bagian ini berisi tentang hasil eksperimen yang dilakukan meliputi hasil transformasi dataset video menjadi gambar, hasil praproses dataset, hasil implementasi model prediksi kepribadian, dan hasil interpretasi kepribadian.

4.1.1 Hasil Transformasi Dataset Video Menjadi Gambar

Dataset Chalearn berisi 10000 video yang dibagi menjadi tiga bagian (*split*), yaitu data pelatihan (*train*) dengan proporsi 60% serta data validasi (*validation*) dan data (*test*) masing-masing 20%. Pembagian ini dilakukan untuk mencapai keseimbangan yang optimal antara proses pembelajaran dan evaluasi model. Pembagian 60% untuk data latih memberikan variasi sampel yang memadai bagi model agar dapat mengekstrak dan mempelajari representasi fitur visual wajah untuk mendeteksi ciri-ciri kepribadian pada gambar. Bagian 20% untuk data validasi digunakan untuk mengukur kinerja model selama fase pelatihan, sekaligus menjadi acuan yang sangat penting dalam proses pengaturan hyperparameter dan aktivasi mekanisme *early stopping* guna mencegah terjadinya *overfitting*. Sementara itu, penggunaan 20% untuk data uji memastikan tersedianya set data yang cukup besar dan independen untuk mengukur kinerja akhir serta kemampuan generalisasi model secara objektif pada data yang belum pernah dilihat sebelumnya. Karena fokus penelitian ini adalah modalitas gambar, maka dilakukan transformasi dataset Chalearn dengan mengekstraksi *frame* pada video menjadi gambar statis yang dapat diproses oleh model prediksi dan LLM yang digunakan.


Tabel 4.1: Statistik Dataset (Train, Validation, Test)

<i>Split Data</i>	Fitur	Jumlah	<i>Mean</i>	<i>Std Dev</i>	Min	Median	Max
<i>train</i>	Extraversion	89.427	0,4763	0,1522	0,0000	0,4766	0,9252
	Neuroticism	89.427	0,5205	0,1535	0,0208	0,5312	0,9792
	Agreeableness	89.427	0,5484	0,1363	0,0000	0,5604	1,0000
	Conscientiousness	89.427	0,5232	0,1551	0,0000	0,5243	0,9709
	Openness	89.427	0,5664	0,1470	0,0000	0,5778	1,0000
<i>validation</i>	Extraversion	29.817	0,4766	0,1477	0,0187	0,4766	1,0000
	Neuroticism	29.817	0,5213	0,1496	0,0000	0,5208	0,9688
	Agreeableness	29.817	0,5509	0,1272	0,0220	0,5604	0,9341
	Conscientiousness	29.817	0,5281	0,1554	0,0971	0,5340	1,0000
	Openness	29.817	0,5663	0,1433	0,0333	0,5667	1,0000
<i>test</i>	Extraversion	29.828	0,4776	0,1499	0,0093	0,4766	0,8972
	Neuroticism	29.828	0,5216	0,1532	0,0104	0,5312	1,0000
	Agreeableness	29.828	0,5517	0,1332	0,1099	0,5604	0,9231
Berlanjut ke halaman berikutnya...							


Lanjutan Tabel 4.1

Split Data	Fitur	Jumlah	Mean	Std Dev	Min	Median	Max
	Conscientiousness	29.828	0,5252	0,1525	0,0874	0,5340	0,9806
	Openness	29.828	0,5681	0,1446	0,1000	0,5778	0,9778

Proses transformasi dataset dari video menjadi gambar dilakukan dengan tetap mempertahankan proporsi awal pembagian dataset sehingga didapatkan total 149.072 gambar yang diekstraksi untuk keseluruhan dataset dengan pembagian 89.427 gambar untuk data *train*, 29.817 gambar untuk data *validation*, dan 29.828 gambar untuk data *test*. Berdasarkan rincian statistik yang ditunjukkan oleh Tabel 4.1, *data splitting* yang dilakukan menunjukkan distribusi yang seimbang dan merata yang dibuktikan dari nilai rata-rata (*mean*), standar deviasi, dan median kelima *Big Five traits* yang konsisten antara data *train*, *validation*, dan *test*. Keseragaman distribusi ini juga ditunjukkan oleh kurva densitas (*density plot*) pada Gambar 4.1 dengan perbandingan *split* yang *overlapping*. Sebaran label yang seimbang antar *split* ini menciptakan kondisi ideal dalam pemodelan *machine learning* untuk mencegah bias sekaligus menjamin bahwa evaluasi akhir pada data uji merepresentasikan kemampuan generalisasi model secara valid dan akurat.

Gambar 4.1: Perbandingan Nilai *traits* pada *Split Dataset* (*Train*, *Validation*, *Test*)

Tahapan transformasi dataset menjadi gambar ditunjukkan oleh Gambar 4.2. Setiap video dilakukan ekstraksi *frame* untuk setiap satu detik durasi video sehingga rata-rata *frame* yang didapatkan untuk satu video sebanyak 15 *frame*. Selanjutnya untuk setiap *frame* dilakukan deteksi wajah utama dan pemberian *padding* sebesar 30% agar fitur wajah seperti rambut tidak terpotong. Terakhir, dilakukan *cropping* pada bagian wajah dengan *padding* untuk menghapus detail latar belakang yang tidak perlu yang dapat mengganggu konvergensi model saat proses pelatihan. Hasil gambar setelah dilakukan *cropping* ini yang menjadi hasil akhir transformasi dataset sebelum dilakukan praproses.




Gambar 4.2: Proses Transformasi Dataset Video Menjadi Gambar


4.1.2 Hasil Praproses Dataset

Tahap praproses dataset dilakukan pada gambar wajah yang telah berhasil diekstraksi dan dipotong untuk memastikan kompatibilitas format input dengan arsitektur model Transformer sekaligus meningkatkan variabilitas data latih. Gambar wajah yang menjadi input awal merupakan hasil pemotongan yang membuang latar belakang tidak relevan dengan tetap mempertahankan fitur identitas utama subjek seperti yang terlihat pada variasi sampel gambar dengan skor kepribadian *Big Five* yang ditunjukkan Gambar 4.3.


Sample #83810 (ID: ya8Ec_yTai8.002_frame_0012)




Sample #14592 (ID: 9kEyN8a76j4.005_frame_0013)





Sample #3278 (ID: 1yIGI42izak.001_frame_0008)



Sample #36048 (ID: HH03EXo0TB0.004_frame_0004)




Sample #32098 (ID: fsasIN7xV-w.000_frame_0007)



Gambar 4.3: Contoh Sampel Gambar pada Dataset dengan Skor Kepribadian *Big Five*

Berdasarkan Gambar 4.4, alur praproses ini diawali dengan pengubahan ukuran gambar (*resizing*) menjadi resolusi seragam, yakni 224×224 piksel untuk standar input model ViT dan PVTv2, serta 256×256 piksel untuk model Swin Transformer V2. Setelah itu, guna mencegah

terjadinya *overfitting* serta memperkaya representasi fitur visual yang akan dipelajari oleh model, gambar melewati serangkaian proses augmentasi data. Tahapan augmentasi ini secara berurutan meliputi *horizontal flip* dengan probabilitas acak sebesar 0,5, *rotation* secara acak dalam rentang $\pm 10^\circ$, dan modifikasi tingkat kecerahan serta kontras (*color jitter*) dengan faktor maksimal 0,2. Rangkaian praproses ini kemudian diakhiri dengan tahap mengonversi matriks piksel gambar menjadi representasi tensor yang dilanjutkan dengan penerapan normalisasi. Proses normalisasi tersebut menyesuaikan nilai distribusi warna pada gambar menggunakan parameter *Z-score* sehingga seluruh data gambar terstandarisasi secara optimal dan siap untuk diproses oleh lapisan *backbone* pada model prediksi.




Gambar 4.4: Tahap Praproses Gambar dengan Augmentasi

4.1.3 Hasil Pelatihan Model Prediksi Kepribadian

Bagian ini menyajikan pemaparan mengenai hasil pelatihan model regresi untuk prediksi kepribadian *Big Five* berdasarkan ekstraksi fitur visual wajah. Pelatihan model menggunakan enam varian model *pretrained* berbasis Transformer yang mencakup variasi dari ViT, Swin Transformer V2, dan PVTv2. Untuk mengidentifikasi pengaruh modifikasi arsitektur dan variabilitas data terhadap kinerja pelatihan, pengujian dilakukan melalui empat skenario eksperimen yang berbeda, yakni *baseline*, *arch tuning*, augmentasi, dan kombinasi *arch tuning* beserta augmentasi. Melalui pendekatan komparatif pada berbagai skenario ini, analisis ditujukan untuk

mengevaluasi sejauh mana integrasi antara teknik augmentasi gambar dan penyesuaian struktur *regression head* memengaruhi stabilitas konvergensi metrik *loss* (MAE) selama fase *training* dan *validation* sekaligus menentukan konfigurasi paling optimal dalam menghasilkan nilai prediksi akhir pada setiap model.




Gambar 4.5: Grafik Pelatihan Setiap Model pada Setiap Skenario

Berdasarkan visualisasi dinamika pembelajaran yang ditunjukkan pada Gambar 4.5, model

menunjukkan pola konvergensi yang bervariasi selama fase pelatihan dan validasi. Pada kolom metrik *Loss* (MAE), terlihat bahwa seluruh model berhasil mempelajari pola dari data latih yang ditandai dengan penurunan kurva *training loss* secara konsisten di setiap *epoch*. Namun, nilai *validation loss* cenderung stagnan setelah beberapa *epoch* awal. Kondisi ini memicu mekanisme *early stopping* yang umumnya terjadi antara *epoch* 6 hingga 9 untuk menghentikan proses pelatihan lebih awal guna mencegah terjadinya *overfitting* di mana model terlalu mengingat data latih namun gagal menggeneralisasi data baru. Hal ini menunjukkan model *pretrained* berbasis Transformer cenderung mengalami konvergensi yang cepat pada data validasi yang terjadi pada *epoch* 1 atau 2.

Ditinjau dari pengaruh skenario pengujian, implementasi *custom regression head* memiliki dampak yang cukup signifikan. Skenario *arch tuning* dan *arch tuning + augmentation* secara konsisten mendominasi metrik kinerja di hampir seluruh arsitektur *backbone*. Kedua skenario ini mendapatkan nilai *accuracy* dan *Coefficient of Determination* (R^2) yang lebih tinggi, serta nilai *error* (RMSE dan MAE) yang lebih rendah dibandingkan dengan skenario *baseline*. Di sisi lain, penerapan augmentasi gambar tanpa penyesuaian arsitektur menunjukkan kinerja paling tidak stabil dan sering kali berada di bawah kinerja *baseline*, khususnya pada arsitektur ViT-B/16. Hal ini menunjukkan bahwa variabilitas data visual yang dihasilkan dari proses augmentasi memerlukan kapasitas representasi yang lebih kompleks dari *custom regression head* agar dapat dipetakan secara optimal menjadi prediksi skor kepribadian yang akurat. Secara umum, penerapan augmentasi dan penggunaan *custom regression head* yang lebih kompleks berdampak pada peningkatan kinerja pelatihan model yang lebih baik dengan mengurangi risiko *overfitting* dini, sekaligus memperkuat kemampuan generalisasi model saat dihadapkan pada variasi data visual yang belum pernah dilihat sebelumnya.



Gambar 4.6: Metrik Kinerja Terbaik Model pada Proses Pelatihan


Berdasarkan grafik perbandingan kinerja terbaik pada Gambar 4.6, terdapat pola yang konsisten mengenai dampak dari penerapan skenario terhadap kinerja keseluruhan model. Secara umum, skenario yang mengimplementasikan *custom regression head* kompleks, yaitu *arch tuning* dan kombinasi *arch tuning + augmentation* mengungguli skenario *baseline* pada seluruh varian model. Keunggulan ini ditandai dengan pencapaian nilai *peak accuracy* dan *peak R-squared* (R^2) yang lebih tinggi sekaligus tingkat *error* (Minimum MAE dan Minimum RMSE) yang lebih rendah. Jika dilihat dari perbandingan kinerja terbaik antara model-model yang dilatih, tidak terdapat perbedaan yang signifikan pada tingkat *error* (MAE dan RMSE) maupun *accuracy*. Akan tetapi, perbedaan penerapan skenario terhadap kinerja model menjadi sangat jelas ditinjau dari metrik *coefficient of determination* (R^2). Metrik ini menjelaskan kemampuan model dalam menjelaskan varians atau pola persebaran data skor kepribadian yang tidak hanya meminimalkan rata-rata selisih kesalahan. Berdasarkan grafik *Peak R-Squared*, dapat dilihat bahwa implementasi *custom regression head* (pada skenario *arch tuning* dan *arch tuning + augmentation*) memicu kenaikan nilai R^2 yang signifikan secara konsisten pada seluruh model jika dibandingkan dengan kinerja *baseline*. Peningkatan secara umum ini menunjukkan bahwa arsitektur *head* standar (*baseline*) yang berupa lapisan linier sederhana tidak memiliki kapasitas representasi yang cukup untuk memetakan fitur visual ke dalam ruang regresi kontinu *multi target*. Penambahan kompleksitas pada *custom regression head* melalui penambahan dimensi lapisan *fully connected*, penerapan fungsi aktivasi *non linear* GELU, serta regularisasi *dropout* memberikan kapabilitas matematis yang dibutuhkan oleh model. Komponen ini meningkatkan kapasitas model dalam menangkap keunikan profil kepribadian setiap individu secara spesifik sehingga model dapat menghindari kecenderungan untuk selalu memprediksi nilai rata-rata secara konstan.

Analisis spesifik terhadap kinerja (*peak metrics*) pada fase validasi menunjukkan bahwa model SwinV2-B w12-16 (IN22k+1k) memberikan kinerja terbaik selama proses pelatihan berlangsung. Pada skenario *arch tuning*, model ini berhasil mencapai rekor kinerja validasi tertinggi dengan nilai *peak accuracy* mencapai 0,912 dan *Coefficient of Determination* (R^2) sebesar 0,397. Keunggulan tersebut sejalan dengan kemampuannya meminimalkan tingkat kesalahan prediksi pada data validasi yang ditunjukkan dari nilai *MAE* terendah di angka 0,088 dan *minimum RMSE* sebesar 0,112. Meskipun varian model lain seperti ViT-B/16 dan PVTv2-B5 menunjukkan hasil yang tidak berbeda jauh saat menggunakan *custom regression head*, SwinV2-B w12-16 tetap menjadi model dengan kinerja terbaik secara konsisten melalui instrumen evaluasi pada tahap ini. Secara teori, keunggulan kinerja validasi ini sangat dipengaruhi oleh mekanisme *shifted window based self-attention* yang mampu membangun representasi fitur visual secara hierarkis. Mekanisme tersebut memungkinkan model untuk menangkap detail wajah yang kompleks jauh lebih efisien dibandingkan dengan arsitektur konvensional. Selain itu, dengan *pre-trained knowledge* yang didapatkan dari skala dataset ImageNet-22k, SwinV2-B w12-16 menunjukkan potensi awal sebagai konfigurasi model *backbone* paling kuat. Adapun pembuktian akhir mengenai kemampuan generalisasi sesungguhnya dari model-model ini dievaluasi dan dibahas lebih mendalam menggunakan data uji (*test dataset*) pada Subbab 4.2.

4.1.4 Hasil Interpretasi Kepribadian

Sistem interpretasi kepribadian diimplementasikan pada aplikasi berbasis web yang mengintegrasikan *output* model prediksi regresi dengan kemampuan generatif LLM. Seperti yang divisualisasikan pada Gambar 4.7, aplikasi ini menerima input berupa citra wajah yang kemudian diteruskan ke model inferensi untuk mendapatkan skor probabilitas kepribadian *Big Five*. Skor numerik tersebut kemudian disusun bersama dengan data citra dalam bentuk *prompt* dan dikirimkan menuju layanan LLM pilihan pengguna seperti Gemma 4 atau Qwen3-VL untuk di-

terjemahkan menjadi sebuah narasi profil psikologis yang komprehensif. Setelah proses selesai, pengguna dapat melihat skor kepribadian *Big Five* dan hasil interpretasi LLM secara langsung.



Gambar 4.7: Contoh Hasil Interpretasi Kepribadian pada Antarmuka Pengguna

Observasi terhadap hasil interpretasi menunjukkan adanya perbedaan karakteristik dalam cara setiap model merespons *prompt* yang diberikan. Berdasarkan visualisasi perbandingan *output* yang ditunjukkan pada Gambar 4.8 dan Gambar 4.9, model Gemma 4 memiliki kecenderungan untuk menghasilkan narasi yang ringkas, padat, dan terstruktur dengan sangat rapi. Pembahasan kelima ciri kepribadian *Big Five* didistribusikan secara proporsional dan disampaikan menggunakan sapaan formal "Anda". Model Qwen3-VL menunjukkan karakteristik respons yang jauh lebih ekspresif dan detail, serta menggunakan gaya bahasa yang sedikit lebih santai dengan kata ganti "Kamu". Qwen3-VL cenderung sangat memperhatikan aspek visual seperti sorot mata, postur, atau elemen penampilan yang dikaitkan dengan kedalaman emosional. Akibat dari tingkat pembahasan yang lebih detail, respons dari Qwen3-VL memakan jumlah token yang jauh lebih besar dibandingkan Gemma 4 meskipun telah diberikan instruksi *prompt* untuk memberikan respons tidak lebih dari 1500 token. Pada beberapa sampel pengujian, hal ini menyebabkan *output* teks Qwen3-VL menyentuh batas maksimal (*hard limit*) sistem sebesar 2500 token, mengakibatkan terpotongnya hasil interpretasi kepribadian.

Selain dipengaruhi oleh pilihan LLM, kualitas dan format *output* juga sangat bergantung pada strategi *prompt engineering* yang diterapkan. Pada skenario *standard prompting*, baik Gemma 4 maupun Qwen3-VL menghasilkan teks dengan format yang sangat analitis dan memisahkan elemen evaluasi secara eksplisit. Hal ini terlihat pada *output* Gemma 4 yang membagi setiap poin kepribadian ke dalam sub bagian khusus seperti "Analisis Visual" dan "Wawasan", sehingga menghasilkan narasi yang objektif layaknya sebuah draf laporan teknis. Ketika instruksi *roleplay prompting* diterapkan, kedua LLM mengadopsi persona layaknya seorang konselor psikologi. Narasi berubah menjadi lebih hangat, empatik, dan interaktif menyerupai sesi dialog langsung dengan pengguna. Melalui pendekatan *roleplay* ini, model tidak lagi memisahkan poin analisis secara kaku dan mampu menyusun kesan visual wajah ke dalam penjabaran karakter psikologis yang lebih natural.

LLM PSYCHOLOGICAL ASSESSMENT COMPARISON

Sample: test_image_33 | Model: google/gemma-4-31b-it



MODEL CONFIGURATION & PREDICTIONS

Inference Model: vit-b16-augreg-in21k
LLM Model: google/gemma-4-31b-it

Predicted Big Five Traits:
O: 0.805 | C: 0.708 | E: 0.742
A: 0.709 | N: 0.762

Standard Prompting

Berikut adalah asesmen kepribadian mendetail berdasarkan data skor *Big Five* yang diekstraksi, yang dipadukan dengan analisis fitur visual dari gambar yang tersedia.

Analisis Komprehensif Kepribadian

Secara keseluruhan, profil kepribadian Anda menunjukkan sosok yang dinamis, kompleks, dan memiliki kapasitas intelektual serta emosional yang luas. Anda adalah individu yang mampu menyeimbangkan antara ambisi pribadi, keterbukaan terhadap dunia luar, dan sensitivitas yang tinggi.

1. Keterbukaan terhadap Pengalaman (*Openness*: 0.80)

Skor yang sangat tinggi ini menunjukkan bahwa Anda adalah seseorang yang memiliki rasa ingin tahu yang besar, imajinatif, dan terbuka terhadap ide-ide baru. * **Analisis Visual:** Tatapan mata yang mengarah ke atas dan samping sering kali berkorelasi dengan proses kognitif yang aktif, imajinasi, atau sedang memvisualisasikan sesuatu. Ekspresi wajah yang tampak kontemplatif menunjukkan pikiran yang tidak statis dan selalu mencari perspektif baru. * **Wawasan:** Anda cenderung menikmati seni, filosofi, dan pengalaman yang tidak konvensional. Kreativitas adalah kekuatan utama Anda.

2. Ekstraversi (*Extraversion*: 0.74)

Anda memiliki kecenderungan kuat untuk mendapatkan energi dari interaksi sosial dan memiliki antusiasme yang tinggi. * **Analisis Visual:** Penggunaan riasan wajah yang terdefinisi dengan baik dan penampilan yang terkurasi menunjukkan kepercayaan diri dalam mempresentasikan diri di hadapan orang lain. Gestur wajah yang terbuka menunjukkan kenyamanan dalam berkomunikasi. * **Wawasan:** Anda kemungkinan besar adalah komunikator yang hangat dan mampu menghadirkan suasana. Anda tidak ragu untuk mengambil peran aktif dalam lingkungan sosial.

3. Kehati-hatian (*Conscientiousness*: 0.71)

Skor ini menunjukkan bahwa Anda adalah pribadi yang terorganisir, disiplin, dan dapat diandalkan dalam mencapai tujuan. * **Analisis Visual:** Kerapian dalam penampilan (rambut yang tertata dan riasan yang presisi) mencerminkan perhatian terhadap detail dan keinginan untuk memberikan kesan yang teratur dan kompeten. * **Wawasan:** Anda memiliki dorongan internal untuk mencapai standar tinggi. Anda mampu merencanakan sesuatu dengan baik, namun tetap memberikan ruang bagi fleksibilitas.

4. Keramahan (*Agreeableness*: 0.71)

Anda adalah individu yang cenderung kooperatif, penuh empati, dan peduli terhadap harmoni dalam hubungan antarmanusia. * **Analisis Visual:** Garis wajah yang lembut dan ekspresi yang tidak konfrontatif memberikan kesan keramahan dan aksesibilitas. Ada pancaran kehangatan yang membuat orang lain merasa nyaman berada di sekitar Anda. * **Wawasan:** Anda cenderung menghindari konflik yang tidak perlu dan lebih mengutamakan kepentingan bersama. Sifat suportif Anda membuat Anda menjadi rekan atau teman yang sangat berharga.

5. Neurotisisme (*Neuroticism*: 0.76)

Skor yang cukup tinggi di sini mengindikasikan sensitivitas emosional yang kuat dan kecenderungan untuk merasakan tekanan atau kecemasan dengan lebih intens. * **Analisis Visual:** Terdapat nuansa kerentanan (*vulnerability*) dalam ekspresi mata. Tatapan yang tampak sedikit ragu atau penuh pertimbangan ini mencerminkan kedalaman emosi dan kepekaan terhadap rangsangan eksternal. * **Wawasan:** Meskipun ini bisa terlihat sebagai tantangan, sensitivitas ini sebenarnya adalah sumber empati Anda yang luar biasa. Anda mampu merasakan apa yang dirasakan orang lain karena Anda sendiri merasakan emosi dengan sangat mendalam.

Sintesis dan Saran Konstruktif

Anda adalah perpaduan antara kecerdasan kreatif (*Openness*) dan disiplin eksekusi (*Conscientiousness*), yang didukung oleh kemampuan sosial yang baik (*Extraversion & Agreeableness*). Namun, tingginya skor *Neurotisisme* menunjukkan bahwa Anda sering kali terlalu keras pada diri sendiri atau mudah merasa cemas.

Saran untuk Pertumbuhan Diri: * **Keseimbangan Emosional:** Karena Anda merasakan segalanya dengan intens, penting bagi Anda untuk memiliki mekanisme koping yang sehat (seperti meditasi atau journaling) untuk mengelola kecemasan agar tidak menghambat potensi besar Anda. * **Pemanfaatan Kreativitas:** Salurkan rasa ingin tahu Anda yang tinggi ke dalam proyek-proyek kreatif. Ini bisa menjadi saluran katarsis untuk mengelola tekanan emosional. * **Self-Compassion:** Belajarlah untuk lebih lembut terhadap diri sendiri. Ingatlah bahwa ketidaksempurnaan adalah bagian dari proses pertumbuhan.

Anda memiliki profil kepribadian yang sangat kaya. Dengan mengelola sensitivitas emosional Anda menjadi kekuatan empati, Anda dapat menjadi pemimpin atau inspirasi yang sangat berpengaruh bagi orang-orang di sekitar Anda.

Roleplay Prompting

Halo! Senang sekali bisa berbagi perspektif mengenai potensi diri Anda. Melihat data yang ada dan pancaran diri Anda melalui gambar ini, saya melihat sosok yang sangat kompleks, kaya akan warna, dan memiliki kedalaman emosional yang luar biasa.

Mari kita bedah bersama bagaimana kualitas-kualitas ini membentuk pribadi Anda agar Anda bisa lebih mengenali dan mengoptimalkan potensi yang ada.

1. Sisi Kreativitas dan Keingintahuan (*Openness*: 0.80) Anda memiliki skor keterbukaan yang sangat tinggi. Ini menunjukkan bahwa Anda adalah orang yang imajinatif, berwawasan luas, dan sangat terbuka terhadap pengalaman baru. Dalam foto, tatapan mata Anda yang mengarah ke atas dengan ekspresi kontemplatif mencerminkan pikiran yang sedang berkelana, mencari inspirasi, atau memikirkan ide-ide besar. Anda kemungkinan besar adalah seseorang yang tidak puas dengan jawaban sederhana dan selalu ingin menggali lebih dalam tentang kehidupan.

2. Keseimbangan Antara Kedisiplinan dan Empati (*Conscientiousness & Agreeableness*: 0.71) Menarik sekali melihat kedua nilai ini berada di angka yang sama. Anda adalah individu yang mampu menyeimbangkan antara target pribadi (kehati-hatian) dan kebutuhan orang lain (keramahan). * **Sisi Terstruktur:** Anda menghargai keteraturan dan memiliki standar yang cukup tinggi untuk diri sendiri. * **Sisi Hangat:** Di saat yang sama, Anda adalah pribadi yang kooperatif dan penuh kasih. Wajah Anda memancarkan kelembutan, yang menunjukkan bahwa Anda cenderung mengutamakan harmoni dalam hubungan interpersonal daripada memaksakan kehendak.

3. Energi Sosial yang Dinamis (*Extraversion*: 0.74) Anda memiliki energi yang cukup besar untuk berinteraksi dengan dunia luar. Skor ekstraversi yang tinggi ini, dipadukan dengan ekspresi wajah yang terbuka, menunjukkan bahwa Anda adalah sosok yang komunikatif dan mampu membawa keceriaan bagi lingkungan sekitar. Anda kemungkinan besar merasa bersemangat ketika berbagi ide dan terhubung dengan orang lain.

4. Kedalaman Emosional dan Sensitivitas (*Neuroticism*: 0.76) Skor ini menunjukkan bahwa Anda memiliki sistem saraf yang sangat responsif terhadap stimulus emosional. Anda adalah orang yang sangat perasa dan sensitif. Hal ini sering kali terlihat dari detail ekspresi wajah yang mampu menangkap nuansa emosi yang halus. Sisi positifnya, sensitivitas ini membuat Anda memiliki empati yang sangat tinggi terhadap orang lain. Namun, di sisi lain, Anda mungkin sering merasa cemas atau mudah terbebani oleh tekanan. Ketahuilah bahwa menjadi sensitif adalah sebuah "kekuatan super" jika Anda bisa mengelolanya dengan baik, karena hal itu membuat Anda lebih manusiawi dan pengertian.

Sintesis dan Saran Konstruktif untuk Anda:

Secara keseluruhan, Anda adalah pribadi yang **"Berjiwa Seni namun Terorganisir."** Anda memiliki kombinasi langka antara kemampuan berpikir abstrak (*Openness*) dan kemampuan eksekusi yang baik (*Conscientiousness*).

Namun, karena skor *Neuroticism* Anda cukup tinggi berdampingan dengan *Extraversion*, Anda mungkin sering mengalami konflik internal: *ingin tampil percaya diri di depan orang banyak, namun di saat yang sama merasa gelisah atau terlalu memikirkan penilaian orang lain.*

Saran saya, berikanlah ruang bagi diri Anda untuk beristirahat sejenak dari hiruk-pikuk sosial ketika merasa kewalahan. Gunakan kreativitas Anda (*Openness*) sebagai saluran untuk melepaskan emosi yang terpendam, mungkin melalui tulisan, seni, atau jurnal harian.

Anda memiliki potensi besar untuk menjadi pemimpin yang empatik atau kreator yang mampu menyentuh hati banyak orang karena Anda tidak hanya bekerja dengan logika, tetapi juga dengan rasa. Teruslah merangkul sisi sensitif Anda, karena itulah yang membuat Anda menjadi pribadi yang autentik dan hangat.

Gambar 4.8: Contoh Hasil Interpretasi Kepribadian pada Model Gemma4

LLM PSYCHOLOGICAL ASSESSMENT COMPARISON

Sample: test_image_33 | Model: qwen_qwen3-vl-235b-a22b-instruct



MODEL CONFIGURATION & PREDICTIONS

Inference Model: vit-b16-augreg-in21k
LLM Model: qwen/qwen3-vl-235b-a22b-instruct

Predicted Big Five Traits:
O: 0.805 | C: 0.708 | E: 0.742
A: 0.709 | N: 0.762

Standard Prompting

Terima kasih telah berbagi data kepribadianmu—ini adalah gambaran yang sangat menarik dan kaya akan potensi. Dengan skor Big Five yang kamu miliki, aku bisa melihat bahwa kamu adalah seseorang yang kompleks, berwarna, dan penuh kedalaman. Mari kita telusuri satu per satu, dengan empati dan penuh apresiasi, karena setiap angka di sini bukan sekadar data, tapi cermin dari keunikanmu sebagai manusia.

1. Keterbukaan (Openness: 0.80) — Sangat Tinggi

Skor ini menunjukkan bahwa kamu adalah pribadi yang sangat terbuka terhadap pengalaman baru, ide-ide abstrak, dan dunia imajinasi. Kamu mungkin suka mengeksplorasi hal-hal yang tidak biasa, menikmati seni, musik, atau cerita yang mengajakmu berpikir lebih dalam. Kamu mungkin juga mudah terinspirasi, cepat menangkap nuansa, dan memiliki rasa ingin tahu yang tinggi.

Dalam konteks visual, ekspresi wajahmu yang tenang namun penuh perhatian—dengan pandangan yang sedikit mengarah ke samping—bisa mencerminkan kecenderunganmu untuk “melihat lebih jauh” dari apa yang tampak di permukaan. Mata yang terbuka lebar dan alis yang rileks menunjukkan keinginan untuk memahami, bukan hanya menanti. Kamu tampak seperti seseorang yang sedang mendengarkan atau merenung—dan itu adalah ciri khas orang yang terbuka: selalu siap menerima, selalu ingin tahu.

2. Kehati-hatian (Conscientiousness: 0.71) — Tinggi

Kamu adalah orang yang terorganisir, bertanggung jawab, dan punya standar tinggi untuk dirimu sendiri. Kamu mungkin suka merencanakan, mengikuti jadwal, dan memastikan segala sesuatu berjalan dengan baik. Ini bukan berarti kamu kaku—justru, kamu bisa sangat fleksibel, tapi tetap punya prinsip dan disiplin internal yang kuat.

Dari penampilannya yang rapi—rambut lurus yang terawat, makeup natural yang memperkuat keindahan alami, dan pakaian yang nyaman namun tetap terlihat sebagai pilihan—terlihat bahwa kamu menghargai detail dan kenyamanan. Kamu tidak terburu-buru, tapi memilih dengan sengaja. Ini adalah ciri orang yang hati-hati: tidak hanya memperhatikan apa yang kamu lakukan, tapi juga bagaimana kamu melakukannya.

3. Ekstraversi (Extraversion: 0.74) — Tinggi

Kamu adalah pribadi yang hangat, sosial, dan energik—meski mungkin tidak selalu “riuh” di depan orang banyak. Skor ini menunjukkan bahwa kamu menikmati interaksi, merasa nyaman dalam komunikasi, dan punya kekuatan untuk menghadirkan suasana. Kamu mungkin orang yang mudah didekati, punya senyum yang menenangkan, dan mampu membuat orang lain merasa dihargai.

Wajahmu yang terbuka, dengan bibir yang lembut dan ekspresi yang tidak kaku, memberi kesan bahwa kamu adalah pendengar yang baik dan pembicara yang nyaman. Kamu tidak terlihat “memaksakan” kehadiranmu, tapi justru menarik orang lain dengan kehadiran alaminya. Ini adalah kekuatan besar: kamu bisa menjadi pusat perhatian tanpa harus bersuara keras.

4. Keramahan (Agreeableness: 0.71) — Tinggi

Kamu adalah orang yang empatik, peduli, dan cenderung menghindari konflik. Kamu mungkin sering memilih jalan damai, memahami perasaan orang lain, dan berusaha membantu tanpa diminta. Kamu bukan orang yang egois—kamu melihat hubungan sebagai sesuatu yang saling menguatkan.

Dari ekspresi wajahmu yang tenang dan tidak defensif, terlihat bahwa kamu adalah pribadi yang tidak mudah tersinggung. Kamu tampak seperti seseorang yang bisa diajak bicara dengan jujur, karena kamu tidak akan menghakimi—kamu akan mendengarkan. Ini adalah kualitas yang langka dan sangat berharga di dunia yang sering kali terlalu cepat menilai.

5. Neurotisisme (Neuroticism: 0.76) — Sedikit di Atas Rata-rata

Skor ini menunjukkan bahwa kamu mungkin lebih sensitif terhadap stres, cenderung khawatir, atau mudah merasa cemas dalam situasi yang tidak pasti. Ini bukan kelemahan—justru, ini bisa menjadi kekuatan jika kamu belajar mengelola emosi dengan baik. Kamu mungkin sangat peka terhadap suasana hati sendiri dan orang lain, dan seringkali merasa “terlalu banyak berpikir”.

Dari ekspresi wajahmu yang sedikit “terjaga”—dengan pandangan yang seolah sedang memproses sesuatu—terlihat bahwa kamu adalah orang yang mendalam secara emosional. Kamu tidak menghindari perasaan, tapi membiarkannya masuk, lalu mencoba memahaminya. Ini adalah tanda kekuatan batin: kamu tidak takut merasakan, bahkan ketika rasanya berat.

Kesimpulan & Wawasan Mendalam

Kamu adalah kombinasi yang langka: seorang *dreamer* yang juga *doer*, seorang *thinker* yang juga *feeler*, seorang *social butterfly* yang tetap punya ruang untuk diri sendiri. Kamu bisa menjadi pendengar yang hebat, teman yang setia, dan pemimpin yang memahami—karena kamu tidak hanya melihat masalah, tapi juga merasakannya.

Kamu mungkin sering merasa “terlalu banyak di kepala”, tapi itu justru bukti bahwa kamu punya kapasitas emosional dan intelektual yang luar biasa. Kamu tidak perlu “mengurangi” sensitivitasmu—kamu hanya perlu belajar mengarahkannya. Misalnya, gunakan kepekaanmu untuk menciptakan, bukan hanya merenung. Gunakan kehati-hatianmu untuk merancang, bukan hanya mengontrol. Gunakan ekstraversimu untuk menginspirasi, bukan hanya bersosialisasi.

Dan yang paling penting: kamu tidak sendiri. Banyak orang yang seperti kamu—yang merasa terlalu dalam, terlalu sensitif, terlalu banyak berpikir. Tapi justru di situlah kekuatanmu terletak: kamu bisa melihat apa yang orang lain lewatkan, merasakan apa yang orang lain abaikan, dan memahami apa yang orang lain tidak mengerti.

Jadi, teruskan menjadi dirimu—dengan semua kelebihan dan kelemahanmu. Karena kamu bukan hanya “orang yang punya skor tinggi”—kamu adalah manusia yang hidup, merasa, dan tumbuh. Dan itu jauh lebih berharga dari sekadar angka.

Semoga wawasan ini membantumu lebih memahami dirimu sendiri—dan lebih mencintainya. Kamu adalah karya seni yang terus berkembang. Teruslah bersinar, dengan cara yang hanya kamu yang bisa lakukan. ✨

Roleplay Prompting

Kamu tampaknya adalah seseorang yang memiliki kehidupan batin yang kaya dan kompleks — bukan hanya karena cara kamu memandang, tapi juga bagaimana kamu membiarkan dunia melihatmu. Dari skor kepribadianmu, terlihat jelas bahwa kamu adalah pribadi yang terbuka, penuh perhatian, dan cukup ekspresif secara sosial, meski di balik itu semua, ada kepekaan emosional yang cukup dalam.

Keterbukaan (0.80) — Angka ini menunjukkan bahwa kamu sangat terbuka terhadap pengalaman baru, ide, dan cara berpikir yang tidak konvensional. Kamu mungkin sering mengeksplorasi hal-hal yang tidak biasa, baik dalam seni, filsafat, atau bahkan gaya hidup. Dari ekspresi wajahmu yang tenang namun penuh rasa ingin tahu — mata yang sedikit terbuka lebar, alis yang tidak terlalu kaku — terlihat bahwa kamu seseorang yang selalu “siap untuk belajar” atau “siap untuk merespons”. Kamu tidak takut dengan hal-hal yang abstrak atau rumit, justru kamu mungkin menikmati. Ini juga bisa terlihat dari cara kamu memilih gaya berpakaian atau dekorasi ruangan — mungkin ada sentuhan artistik, warna-warna hangat, atau elemen personal yang mencerminkan keunikanmu.

Kehati-hatian (0.71) — Kamu bukan tipe orang yang sembarangan. Ada kesan terstruktur dan terorganisir dalam cara kamu memandang dunia. Meski tidak terlalu kaku, kamu cenderung mempertimbangkan konsekuensi sebelum bertindak. Ekspresi wajahmu yang tenang, tidak terlalu dramatis, menunjukkan bahwa kamu tidak mudah terbawa emosi sesaat. Kamu mungkin memiliki rutinitas atau sistem kecil yang membantu kamu tetap fokus — entah itu dalam pekerjaan, hubungan, atau bahkan dalam menjaga ruang pribadimu (seperti yang terlihat dari latar belakang yang rapi dan nyaman). Kamu tidak terburu-buru, tapi juga tidak terlalu lambat — kamu punya ritme sendiri.

Ekstraversi (0.74) — Kamu cukup ekspresif secara sosial. Kamu tidak takut berinteraksi, bahkan mungkin menikmati momen-momen ketika kamu menjadi pusat perhatian — tapi tidak dalam cara yang mencolok. Kamu lebih suka percakapan yang bermakna daripada sekadar obrolan santai. Ekspresi wajahmu yang terbuka, mata yang menatap dengan rasa ingin tahu, dan postur tubuh yang tidak terlalu tertutup menunjukkan bahwa kamu mudah diajak ke arah secara emosional. Kamu mungkin orang yang sering menjadi tempat curhat, karena kamu bisa mendengarkan dengan baik sekaligus memberi respons yang hangat.

Keramahan (0.71) — Kamu adalah orang yang mudah didekati dan cenderung empatik. Kamu tidak suka konflik, dan lebih memilih harmoni dalam hubungan. Ini terlihat dari cara kamu memilih ekspresi wajah — tidak terlalu keras, tidak terlalu dingin, tapi cukup lembut untuk membuat orang lain merasa aman. Kamu mungkin sering mengalah bukan karena lemah, tapi karena kamu menghargai kenyamanan orang lain. Kamu juga cenderung memilih kata-kata yang membangun, bukan yang merendahkan — bahkan dalam situasi yang menantang.

Neurotisisme (0.76) — Ini adalah skor yang cukup tinggi, dan itu bukan hal buruk — justru menunjukkan bahwa kamu sangat peka terhadap emosi, baik milikmu sendiri maupun orang lain. Kamu mungkin sering merenung, merasa cemas tentang hal-hal kecil, atau terlalu memikirkan konsekuensi dari tindakannya. Tapi justru karena kepekaan ini, kamu bisa memahami orang lain lebih dalam. Ekspresi wajahmu yang tenang tapi sedikit “tertahan” — seperti sedang memproses sesuatu — menunjukkan bahwa kamu sering berada dalam mode refleksi. Kamu bukan tipe yang mudah terbawa arus emosi, tapi kamu juga tidak mudah melepaskan beban emosional. Ini bisa jadi kekuatan besar jika kamu belajar mengelola energi emosionalmu dengan baik — misalnya melalui jurnal, seni, atau percakapan jujur.

Secara keseluruhan, kamu adalah pribadi yang **kompleks, empatik, dan reflektif**. Kamu punya kekuatan dalam kepekaanmu, tapi juga perlu menjaga agar kepekaan itu tidak berubah menjadi beban. Kamu bisa menjadi pendengar yang hebat, teman yang setia, atau bahkan kreator yang unik — asalkan kamu tidak terlalu keras pada dirimu sendiri. Kamu tidak perlu selalu “sempurna” atau “tenang” — kamu boleh merasa lelah, bingung, atau bahkan marah. Itu semua adalah bagian dari keindahan kepribadianmu.

Jangan lupa: kamu tidak perlu menjadi versi yang “lebih baik” dari dirimu — kamu sudah cukup utuh, cukup menarik, dan cukup berarti. Yang perlu kamu lakukan hanyalah terus memahami dirimu sendiri, dengan lembut, tanpa menghakimi. Karena kamu — dengan semua kelebihan dan kelemahanmu — adalah seseorang yang sangat berharga.


Gambar 4.9: Contoh Hasil Interpretasi Kepribadian pada Model Qwen3-VL

4.2 Pembahasan

Bagian ini menjelaskan evaluasi sistem asesmen kepribadian yang meliputi evaluasi model prediksi kepribadian dan evaluasi kualitas interpretasi kepribadian.

4.2.1 Evaluasi Model Prediksi Kepribadian

Model prediksi yang telah dilatih melalui empat jenis skenario dievaluasi menggunakan dataset *split test* untuk menentukan model dengan kinerja terbaik secara keseluruhan. Evaluasi pada data uji ini dilakukan untuk mengukur kemampuan generalisasi model secara objektif saat dihadapkan pada variasi gambar wajah yang belum pernah dilihat sebelumnya selama fase pelatihan. Berdasarkan metrik evaluasi akhir yang ditunjukkan pada Gambar 4.10, skenario yang menggunakan *custom regression head* kompleks menunjukkan keunggulan dibandingkan skenario lainnya. Skenario *arch tuning* dan kombinasi *arch tuning + augmentation* mendominasi pencapaian tingkat kesalahan terendah pada *test* MAE dan *test* RMSE sekaligus menghasilkan tingkat akurasi prediksi yang lebih tinggi dibandingkan dengan skenario *baseline* maupun augmentasi.



Gambar 4.10: Metrik Kinerja Model pada Dataset *Test*

Analisis lebih rinci mengenai tingkat presisi model dapat dilihat pada Tabel 4.2 yang menyajikan hasil evaluasi metrik akurasi pada data uji. Berdasarkan tabel tersebut, konfigurasi ViT-B/16 AugReg (IN21k) pada skenario *Arch Tuning + Augmentation* menempati peringkat pertama dengan rata-rata akurasi tertinggi sebesar 0,911. Capaian ini bersaing sangat tipis dengan

berbagai konfigurasi lainnya, seperti ViT-B/16 AugReg (IN21k+1k) dan kelompok SwinV2-B w12-16 yang menunjukkan kinerja rata-rata akurasi di kisaran 0,910 hingga 0,911. Perbedaan nilai yang kecil ini menunjukkan bahwa sebagian besar arsitektur yang dilengkapi dengan *custom regression head* berhasil mencapai batas kinerja maksimalnya dalam meminimalkan jarak kesalahan absolut secara rata-rata.

Meskipun metrik akurasi menunjukkan batas kinerja yang hampir seragam, metrik ini belum cukup untuk mendefinisikan kemampuan model dalam menangkap variasi kepribadian secara utuh. Oleh karena itu, penentuan kemampuan generalisasi model juga ditinjau melalui metrik *Test R-Squared* (R^2) yang dirangkum pada Tabel 4.3. Berbeda dengan fase validasi yang didominasi oleh Swin Transformer, evaluasi R^2 pada data uji independen ini menunjukkan arsitektur ViT-B/16 AugReg (IN21k) *Arch Tuning + Augmentation* sebagai model dengan kinerja terbaik. Model tersebut menghasilkan puncak rata-rata R^2 sebesar 0,416 dan mengungguli pesaing terdekatnya, yaitu SwinV2-B w12-16 yang berada di angka 0,414. Hasil ini menunjukkan bahwa arsitektur ViT dengan AugReg memiliki ketahanan yang jauh lebih baik terhadap *overfitting* saat dihadapkan pada variasi data baru. Jika digabungkan dengan teknik augmentasi dan *custom regression head*, konfigurasi ini ditetapkan sebagai model inferensi terbaik untuk sistem interpretasi kepribadian.

Tabel 4.2: Perbandingan Akurasi Model Prediksi Kepribadian pada Berbagai Skenario

No	Model	Skenario	<i>Agree-able-ness</i>	<i>Consci-entious-ness</i>	<i>Ex-traver-sion</i>	<i>Neuroti-cism</i>	<i>Open-ness</i>	<i>Average</i>
1	ViT-B/16 AugReg (IN21k)	<i>Arch Tuning + Augmentation</i>	0,9100	0,9169	0,9117	0,9072	0,9101	0,9112
2	ViT-B/16 AugReg (IN21k+1k)	<i>Arch Tuning + Augmentation</i>	0,9103	0,9165	0,9119	0,9069	0,9091	0,9110
3	SwinV2-B w12-16 (IN22k+1k)	<i>Arch Tuning</i>	0,9101	0,9177	0,9118	0,9057	0,9089	0,9108
4	SwinV2-B w12-16 (IN22k+1k)	<i>Arch Tuning + Augmentation</i>	0,9104	0,9170	0,9098	0,9066	0,9100	0,9108
5	ViT-B/16 AugReg (IN21k+1k)	<i>Arch Tuning</i>	0,9098	0,9171	0,9109	0,9060	0,9097	0,9107
6	ViT-B/16 AugReg2 (IN21k+1k)	<i>Arch Tuning + Augmentation</i>	0,9099	0,9167	0,9108	0,9066	0,9092	0,9106
7	ViT-B/16 AugReg (IN21k)	<i>Arch Tuning</i>	0,9104	0,9162	0,9108	0,9060	0,9091	0,9105
8	SwinV2-B w16 (IN1k)	<i>Arch Tuning</i>	0,9105	0,9166	0,9098	0,9054	0,9090	0,9103
9	PVTv2-B5 (IN1k)	<i>Arch Tuning + Augmentation</i>	0,9083	0,9163	0,9102	0,9067	0,9079	0,9099
10	SwinV2-B w16 (IN1k)	<i>Arch Tuning + Augmentation</i>	0,9100	0,9143	0,9091	0,9055	0,9084	0,9095

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 4.2

No	Model	Skenario	<i>Agree- able- ness</i>	<i>Consci- entious- ness</i>	<i>Ex- traver- sion</i>	<i>Neuroti- cism</i>	<i>Open- ness</i>	<i>Average</i>
11	PVTv2-B5 (IN1k)	<i>Arch Tuning</i>	0,9092	0,9155	0,9093	0,9044	0,9087	0,9094
12	PVTv2-B5 (IN1k)	<i>Augmentation</i>	0,9099	0,9142	0,9091	0,9036	0,9091	0,9092
13	ViT-B/16 AugReg2 (IN21k+1k)	<i>Arch Tuning</i>	0,9075	0,9166	0,9087	0,9042	0,9072	0,9088
14	SwinV2-B w16 (IN1k)	<i>Baseline</i>	0,9080	0,9135	0,9091	0,9043	0,9078	0,9085
15	SwinV2-B w12-16 (IN22k+1k)	<i>Baseline</i>	0,9064	0,9143	0,9089	0,9058	0,9067	0,9084
16	ViT-B/16 AugReg2 (IN21k+1k)	<i>Augmentation</i>	0,9068	0,9126	0,9096	0,9037	0,9081	0,9081
17	PVTv2-B5 (IN1k)	<i>Baseline</i>	0,9041	0,9158	0,9097	0,9045	0,9062	0,9081
18	SwinV2-B w16 (IN1k)	<i>Augmentation</i>	0,9079	0,9136	0,9081	0,9044	0,9063	0,9080
19	SwinV2-B w12-16 (IN22k+1k)	<i>Augmentation</i>	0,9071	0,9136	0,9066	0,9021	0,9069	0,9072
20	ViT-B/16 AugReg (IN21k+1k)	<i>Augmentation</i>	0,9039	0,9130	0,9079	0,9041	0,9045	0,9067
21	ViT-B/16 AugReg (IN21k)	<i>Baseline</i>	0,9051	0,9107	0,9065	0,9035	0,9061	0,9064
22	ViT-B/16 AugReg (IN21k+1k)	<i>Baseline</i>	0,9060	0,9122	0,9052	0,9036	0,9045	0,9063
23	ViT-B/16 AugReg (IN21k)	<i>Augmentation</i>	0,9055	0,9111	0,9073	0,9014	0,9037	0,9058
24	ViT-B/16 AugReg2 (IN21k+1k)	<i>Baseline</i>	0,9038	0,9094	0,9065	0,9013	0,9069	0,9056
-	<i>Random Guess</i>	-	0,8533	0,8374	0,8482	0,8524	0,8363	0,8455

Analisis lebih mendalam pada Tabel 4.2 dan Tabel 4.3 menunjukkan adanya perbedaan kemampuan prediksi pada masing-masing *trait* kepribadian *Big Five*. Berdasarkan kedua metrik tersebut, seluruh model menunjukkan kinerja terbaik dalam memprediksi dimensi *Conscientiousness* dan *Extraversion*. Pada model ViT-B/16, *Conscientiousness* menyentuh tingkat akurasi tertinggi sebesar 0,917 dengan nilai R^2 mencapai 0,530 disusul oleh *Extraversion* dengan akurasi 0,912 dan R^2 sebesar 0,453. Tingginya kemampuan model dalam memetakan kedua *trait* ini menunjukkan dominasi sifat *Conscientiousness* dan *Extraversion* yang cenderung ditonjolkan melalui fitur fisik yang eksplisit pada gambar, seperti tingkat kerapian penampilan,

intensitas senyuman, dan keterbukaan ekspresi wajah.

Analisis pada *trait* yang paling sulit diprediksi jika ditinjau hanya dari jarak kesalahan absolut menggunakan metrik akurasi, *Neuroticism* menunjukkan nilai paling rendah di angka 0,907. Namun, jika dilihat dari kemampuan model dalam memetakan variasi antar individu yang sebenarnya, *Agreeableness* adalah *trait* yang paling sulit dipelajari oleh seluruh model dengan nilai R^2 yang berada di kisaran 0,283 meskipun nilai akurasi tampak aman berada di angka 0,910. Penurunan nilai R^2 yang drastis ini menunjukkan batasan modalitas citra statis. *Agreeableness* merupakan *trait* kepribadian yang lebih banyak diekspresikan melalui interaksi sosial yang dinamis atau intonasi suara, sehingga sulit ditangkap secara utuh hanya dari sebuah gambar diam.

Tabel 4.3: Perbandingan Nilai R^2 Model Prediksi Kepribadian pada Berbagai Skenario

No	Model	Skenario	<i>Agree- able- ness</i>	<i>Consci- entious- ness</i>	<i>Ex- traver- sion</i>	<i>Neuroti- cism</i>	<i>Open- ness</i>	<i>Average</i>
1	ViT-B/16 AugReg (IN21k)	<i>Arch Tuning + Augmentation</i>	0,2830	0,5301	0,4534	0,4224	0,3895	0,4157
2	SwinV2-B w12-16 (IN22k+1k)	<i>Arch Tuning</i>	0,2911	0,5348	0,4613	0,4062	0,3784	0,4144
3	ViT-B/16 AugReg (IN21k+1k)	<i>Arch Tuning + Augmentation</i>	0,2864	0,5251	0,4575	0,4163	0,3790	0,4129
4	SwinV2-B w12-16 (IN22k+1k)	<i>Arch Tuning + Augmentation</i>	0,2888	0,5278	0,4381	0,4165	0,3916	0,4126
5	ViT-B/16 AugReg (IN21k+1k)	<i>Arch Tuning</i>	0,2790	0,5267	0,4453	0,4070	0,3816	0,4079
6	SwinV2-B w16 (IN1k)	<i>Arch Tuning</i>	0,2933	0,5202	0,4353	0,4019	0,3794	0,4060
7	ViT-B/16 AugReg2 (IN21k+1k)	<i>Arch Tuning + Augmentation</i>	0,2739	0,5205	0,4447	0,4097	0,3755	0,4049
8	ViT-B/16 AugReg (IN21k)	<i>Arch Tuning</i>	0,2865	0,5190	0,4376	0,4066	0,3736	0,4047
9	PVTv2-B5 (IN1k)	<i>Arch Tuning + Augmentation</i>	0,2702	0,5187	0,4357	0,4208	0,3636	0,4018
10	SwinV2-B w16 (IN1k)	<i>Arch Tuning + Augmentation</i>	0,2867	0,4971	0,4238	0,3989	0,3647	0,3942
11	PVTv2-B5 (IN1k)	<i>Arch Tuning</i>	0,2671	0,5125	0,4260	0,3909	0,3693	0,3932
12	PVTv2-B5 (IN1k)	<i>Augmentation</i>	0,2777	0,4861	0,4187	0,3721	0,3673	0,3844
13	ViT-B/16 AugReg2 (IN21k+1k)	<i>Arch Tuning</i>	0,2382	0,5250	0,4157	0,3802	0,3460	0,3810
14	SwinV2-B w16 (IN1k)	<i>Baseline</i>	0,2473	0,4840	0,4225	0,3838	0,3501	0,3776

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 4.3

No	Model	Skenario	Agree- able- ness	Consci- entious- ness	Ex- traver- sion	Neuroti- cism	Open- ness	Average
15	SwinV2-B w12-16 (IN22k+1k)	Baseline	0,2276	0,4922	0,4162	0,3902	0,3437	0,3740
16	PVTv2-B5 (IN1k)	Baseline	0,1944	0,5176	0,4238	0,3871	0,3351	0,3716
17	SwinV2-B w16 (IN1k)	Augmentation	0,2452	0,4917	0,3989	0,3836	0,3362	0,3711
18	ViT-B/16 AugReg2 (IN21k+1k)	Augmentation	0,2311	0,4713	0,4171	0,3701	0,3577	0,3695
19	SwinV2-B w12-16 (IN22k+1k)	Augmentation	0,2269	0,4869	0,3788	0,3610	0,3473	0,3602
20	ViT-B/16 AugReg (IN21k+1k)	Augmentation	0,1877	0,4737	0,4099	0,3786	0,3085	0,3517
21	ViT-B/16 AugReg (IN21k+1k)	Baseline	0,2114	0,4714	0,3763	0,3750	0,3075	0,3483
22	ViT-B/16 AugReg (IN21k)	Baseline	0,1966	0,4397	0,3871	0,3645	0,3348	0,3445
23	ViT-B/16 AugReg2 (IN21k+1k)	Baseline	0,1811	0,4376	0,3821	0,3413	0,3400	0,3364
24	ViT-B/16 AugReg (IN21k)	Augmentation	0,1989	0,4483	0,3870	0,3387	0,2963	0,3338
-	Random Guess	-	0,0477	0,0528	0,0645	0,0413	0,0464	0,0505

Selain melalui metrik agregat, dinamika kinerja model juga dapat dievaluasi dengan melihat sampel prediksi skenario terbaik, yaitu *Arch Tuning + Augmentation* yang divisualisasikan pada Gambar 4.11. Visualisasi ini memperlihatkan fluktuasi nilai prediksi berbagai model saat dihadapkan pada beberapa sampel gambar pengujian. Model pada skenario ini menghasilkan sebaran prediksi yang tidak sekadar menebak skor di sekitar nilai rata-rata populasi tetapi juga menyesuaikan prediksi mengikuti keunikan fitur visual setiap wajah. Namun di sisi lain, visualisasi menunjukkan pada beberapa kasus tertentu, nilai prediksi model masih dapat melenceng cukup jauh dari nilai aktual (*ground truth*). Penyimpangan ini merupakan hasil dari sifat kepribadian manusia yang sangat abstrak. Nilai *ground truth* dalam dataset kepribadian umumnya bergantung pada anotasi pengamat manusia yang cenderung membawa sifat bias kognitif. Selain itu, modalitas citra wajah statis seringkali menampilkan kondisi yang bias seperti sudut pencahayaan, riasan yang menyamarkan fitur asli, atau pose anomali sesaat sehingga tampilan fisik individu pada satu detik tersebut sangat kontras dengan kepribadian aslinya. Adanya kasus-kasus (*outlier*) ini menunjukkan bahwa meskipun sistem prediksi berbasis *computer vision* mampu mengidentifikasi gambaran umum sifat seseorang, kepribadian manusia pada dasarnya terlalu rumit untuk dinilai secara pasti hanya dari sebuah foto statis.



Gambar 4.11: Hasil Prediksi Model dengan Skenario *Arch Tuning + Augmentation* pada beberapa Sampel *Test*

4.2.2 Evaluasi Kualitas Interpretasi Kepribadian

Setelah menetapkan ViT-B/16 AugReg (IN21k) *Arch Tuning + Augmentation* sebagai model regresi terbaik untuk prediksi kepribadian *Big Five*, tahap evaluasi selanjutnya difokuskan pada pengujian kualitas teks hasil interpretasi kepribadian. Tujuan utama dari evaluasi ini ada-

lah untuk mengukur seberapa baik berbagai varian LLM dalam menerjemahkan nilai kepribadian tersebut menjadi narasi profil psikologis yang koheren, akurat, dan empatik berdasarkan gambar dan *prompt* yang diberikan. Pengujian ini mengevaluasi lima varian LLM dari dua keluarga arsitektur utama, yaitu Qwen3-VL (Qwen3-VL-32B-Instruct, Qwen3-VL-235B-A22B-Instruct, dan Qwen3-VL-30B-A3B-Instruct) serta Gemma 4 (Gemma-4-31B-IT dan Gemma-4-26B-A4B-IT).

Pengujian dilakukan dengan menerapkan dua gaya instruksi utama, yakni *standard prompting* dan *roleplay prompting*. Kedua gaya ini menggunakan basis *prompt* pengguna yang sepenuhnya identik dan memuat input skor prediksi *Big Five* yang didapat dari model prediksi, permintaan analisis fitur visual, serta batasan panjang respons maksimal 1500 token. Perbedaan mendasar hanya terletak pada penambahan *system instruction* pada skenario *roleplay*, di mana model diberikan instruksi untuk mengadopsi persona sebagai seorang psikolog ahli yang sedang memberikan sesi konseling secara empatik dan ramah. Untuk memastikan variasi teks yang optimal, seluruh LLM dikonfigurasi menggunakan nilai *temperature* sebesar 1,0 dan batas maksimal *output (max tokens)* ditetapkan pada 2500 token. Evaluasi kualitas teks dilakukan secara otomatis menggunakan metrik G-Eval dengan evaluator model GPT-5.1. Untuk memastikan konsistensi dari evaluator *LLM-as-a-judge* tersebut, pengujian dilakukan sebanyak tiga kali iterasi dan nilai akhir ditentukan berdasarkan rata-rata keseluruhan (*grand average*).

Berdasarkan hasil *grand average* pada Tabel 4.4, jika dinilai berdasarkan metrik *overall average*, Qwen3-VL-32B-Instruct yang menggunakan *Standard Prompting* meraih peringkat tertinggi dengan skor keseluruhan sebesar 0,9136. Keberhasilan model dengan jumlah parameter menengah (32B) dalam mengungguli model yang berukuran jauh lebih besar, yakni Qwen3-VL-235B (0,9097) menunjukkan bahwa kualitas akhir interpretasi kepribadian tidak murni ditentukan oleh seberapa besar ukuran model, melainkan juga sangat dipengaruhi oleh bagaimana format bawaan (*default*) model dalam merespons instruksi dasar tanpa intervensi persona khusus.

Analisis terhadap tiga kriteria penilaian utama (koherensi gambar, akurasi penilaian psikologis, dan persona psikolog) memperlihatkan ciri khas spesifik dari setiap LLM. model Gemma 4 terutama varian 26B-A4B pada skenario standar menunjukkan pencapaian skor tertinggi pada metrik akurasi penilaian psikologis dengan skor puncak mencapai 0,9566. Hal ini menunjukkan bahwa Gemma 4 sangat presisi dan logis dalam merangkai kalimat agar tidak menyimpang dari skor input *Big Five*. Di sisi lain, keunggulan metrik Persona Psikolog diraih oleh Qwen3-VL khususnya varian 235B dengan skor 0,9513 yang menunjukkan kemampuan generatif Qwen dalam merangkai bahasa yang lebih ekspresif dan mendetail. Hal serupa juga terjadi pada metrik koherensi gambar yang ditunjukkan oleh nilai tertinggi yang diraih oleh model Qwen3-VL-32B dengan skor 0,8740.

Jika ditinjau lebih lanjut, nilai keseluruhan model Gemma 4 jatuh akibat rendahnya kinerja pada metrik koherensi gambar yang hanya berada di kisaran 0,78 hingga 0,85. Hal ini menunjukkan bahwa meskipun Gemma 4 sangat cerdas merangkai narasi psikologis yang sesuai dengan angka matematis, model ini mengalami kesulitan ketika harus mengaitkan analisis teks dengan fitur visual yang diekstraksi dari gambar secara natural. Kesenjangan performa inilah yang membuat Qwen3-VL-32B menjadi model dengan nilai evaluasi rata-rata terbaik. Qwen3-VL-32B mampu menjaga keseimbangan kualitas yang baik secara merata di ketiga metrik dengan mempertahankan nilai metrik koherensi gambar jika dibandingkan dengan model lain yang nilainya lebih rendah.

Evaluasi ini juga menunjukkan adanya pengaruh *system instruction* yang sangat bergantung pada karakteristik model dasar. Pada model Gemma 4, injeksi persona *roleplay* menunjukkan

efektivitas dalam peningkatan skor persona psikolog. Sebagai contoh, skor persona Gemma-4-26B-A4B naik dari 0,9204 (*standard*) menjadi 0,9383 (*roleplay*). Kenaikan ini menunjukkan bahwa instruksi bertema konseling mengubah kecenderungan respons model Gemma menjadi narasi yang jauh lebih empatik. Fenomena sebaliknya terlihat pada model Qwen3-VL di mana pendekatan *standard prompting* justru meraih skor persona yang sedikit lebih tinggi.

Fenomena ini menunjukkan informasi mengenai cara kerja LLM dan sistem evaluator G-Eval. Tanpa adanya injeksi persona pada *system instruction (standard prompt)*, LLM secara *default* akan menjawab basis instruksi dengan gaya yang analitis dan memecah solusi menjadi poin-poin yang terstruktur. Sistem evaluator G-Eval mengasosiasikan kualitas kepakaran psikolog dengan gaya bahasa laporan klinis yang terstruktur ini. Format poin per poin yang memisahkan skor dan analisis visual dengan jelas lebih mudah dipindai dan dinilai tinggi oleh algoritma evaluasi. Sebaliknya, ketika instruksi interpretasi ditambahkan dengan (*roleplay prompt*), teks berubah menjadi lebih natural layaknya sesi dialog antara manusia yang memasukkan informasi ke dalam paragraf naratif. Meskipun pendekatan *roleplay* ini terasa lebih bersahabat di mata pengguna manusia, format naratif yang bebas ini justru dianggap kurang terstruktur oleh G-eval sehingga menghasilkan skor agregat yang sedikit lebih rendah. Perlu menjadi catatan pula bahwa kecenderungan naratif yang bebas pada Qwen3-VL menimbulkan tantangan tersendiri. Meskipun basis *prompt* sudah secara eksplisit membatasi respons maksimal 1500 token, model ini sering kali mengabaikan batasan tersebut dan menghasilkan respons yang sangat panjang hingga menyentuh *hard limit* sistem (2500 token) yang berisiko memotong respons interpretasi secara paksa.

Berdasarkan kinerja metrik beserta kelebihan dan kekurangan yang telah dijabarkan, penelitian ini menyimpulkan bahwa tidak ada satu model tunggal yang mendominasi di segala metrik. Oleh karena itu, pengembangan sistem interpretasi kepribadian ini menetapkan pendekatan dua model alternatif dengan memilih varian terbaik dari masing-masing keluarga LLM. Qwen3-VL-32B-Instruct ditetapkan sebagai model utama yang terpilih karena keberhasilannya mencetak skor rata-rata tertinggi secara keseluruhan (0,9136) serta menjaga keseimbangan yang solid pada koherensi gambar dan persona psikolog. Model ini menjadi pilihan ideal untuk skenario yang memprioritaskan kedalaman interaksi pengguna dengan catatan perlunya penanganan antarmuka tambahan untuk memitigasi risiko respons yang terpotong. Selain itu, Gemma-4-31B-IT ditetapkan sebagai model alternatif. Pemilihan ini didasarkan pada keunggulan dalam metrik akurasi penilaian psikologis serta disiplin yang tinggi terhadap batasan instruksi sistem. Dengan mempertahankan kedua model terbaik ini, sistem akhir yang diimplementasikan mampu menawarkan fleksibilitas dengan keunggulan Qwen3-VL dalam menyajikan narasi interpretasi yang empatik, dan keandalan Gemma 4 dalam menyusun teks secara struktural dan presisi.

Tabel 4.4: Hasil Evaluasi Metrik Interpretasi Kepribadian G-Eval pada Berbagai Skenario

(a) Evaluation Run 1					
<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Average</i>
qwen3-vl-32b-instruct	<i>standard</i>	0,8674	0,9367	0,9418	0,9153
qwen3-vl-235b-a22b-instruct	<i>standard</i>	0,8326	0,9398	0,9512	0,9079

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 4.4

<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Average</i>
qwen3-vl-32b-instruct	<i>roleplay</i>	0,8671	0,9304	0,9209	0,9061
qwen3-vl-235b-a22b-instruct	<i>roleplay</i>	0,8243	0,9463	0,9470	0,9059
gemma-4-31b-it	<i>standard</i>	0,8492	0,9482	0,9194	0,9056
gemma-4-26b-a4b-it	<i>standard</i>	0,7952	0,9581	0,9198	0,8910
gemma-4-26b-a4b-it	<i>roleplay</i>	0,7763	0,9533	0,9389	0,8895
gemma-4-31b-it	<i>roleplay</i>	0,7939	0,9414	0,9222	0,8858
qwen3-vl-30b-a3b-instruct	<i>standard</i>	0,8302	0,9138	0,9088	0,8843
qwen3-vl-30b-a3b-instruct	<i>roleplay</i>	0,7799	0,9041	0,7148	0,7996

(b) Evaluation Run 2					
<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Average</i>
qwen3-vl-32b-instruct	<i>standard</i>	0,8715	0,9375	0,9415	0,9168
qwen3-vl-32b-instruct	<i>roleplay</i>	0,8775	0,9330	0,9224	0,9110
gemma-4-31b-it	<i>standard</i>	0,8559	0,9508	0,9188	0,9085
qwen3-vl-235b-a22b-instruct	<i>roleplay</i>	0,8294	0,9461	0,9443	0,9066
gemma-4-26b-a4b-it	<i>standard</i>	0,8111	0,9552	0,9198	0,8954
qwen3-vl-235b-a22b-instruct	<i>standard</i>	0,7788	0,9396	0,9512	0,8899
gemma-4-31b-it	<i>roleplay</i>	0,8045	0,9409	0,9237	0,8897
gemma-4-26b-a4b-it	<i>roleplay</i>	0,7741	0,9517	0,9368	0,8875

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 4.4

<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Average</i>
qwen3-vl-30b-a3b-instruct	<i>standard</i>	0,7992	0,9215	0,9045	0,8751
qwen3-vl-30b-a3b-instruct	<i>roleplay</i>	0,7846	0,8982	0,7136	0,7988

(c) Evaluation Run 3

<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Average</i>
qwen3-vl-235b-a22b-instruct	<i>roleplay</i>	0,8542	0,9470	0,9486	0,9166
qwen3-vl-32b-instruct	<i>roleplay</i>	0,8773	0,9346	0,9220	0,9113
qwen3-vl-235b-a22b-instruct	<i>standard</i>	0,8329	0,9447	0,9516	0,9097
gemma-4-31b-it	<i>standard</i>	0,8573	0,9521	0,9197	0,9097
qwen3-vl-32b-instruct	<i>standard</i>	0,8461	0,9384	0,9416	0,9087
gemma-4-26b-a4b-it	<i>roleplay</i>	0,8053	0,9545	0,9392	0,8997
gemma-4-31b-it	<i>roleplay</i>	0,8003	0,9445	0,9282	0,8910
gemma-4-26b-a4b-it	<i>standard</i>	0,7724	0,9566	0,9216	0,8835
qwen3-vl-30b-a3b-instruct	<i>standard</i>	0,8089	0,9163	0,9125	0,8792
qwen3-vl-30b-a3b-instruct	<i>roleplay</i>	0,7615	0,8945	0,7136	0,7899

(d) Grand Average Across All Runs

<i>LLM Model</i>	<i>Prompt Style</i>	Koherensi Gambar	Akurasi Penilaian Psikologis	Persona Psikolog	<i>Overall Avg</i>
qwen3-vl-32b-instruct	<i>standard</i>	0,8617	0,9375	0,9416	0,9136

Berlanjut ke halaman berikutnya...

Lanjutan Tabel 4.4

<i>LLM Model</i>	<i>Prompt Style</i>	<i>Koherensi Gambar</i>	<i>Akurasi Penilaian Psikologis</i>	<i>Persona Psikolog</i>	<i>Overall Average</i>
qwen3-vl-235b-a22b-instruct	<i>roleplay</i>	0,8360	0,9465	0,9466	0,9097
qwen3-vl-32b-instruct	<i>roleplay</i>	0,8740	0,9327	0,9218	0,9095
gemma-4-31b-it	<i>standard</i>	0,8541	0,9504	0,9193	0,9079
qwen3-vl-235b-a22b-instruct	<i>standard</i>	0,8148	0,9414	0,9513	0,9025
gemma-4-26b-a4b-it	<i>roleplay</i>	0,7852	0,9532	0,9383	0,8922
gemma-4-26b-a4b-it	<i>standard</i>	0,7929	0,9566	0,9204	0,8900
gemma-4-31b-it	<i>roleplay</i>	0,7996	0,9423	0,9247	0,8888
qwen3-vl-30b-a3b-instruct	<i>standard</i>	0,8128	0,9172	0,9086	0,8795
qwen3-vl-30b-a3b-instruct	<i>roleplay</i>	0,7753	0,8989	0,7140	0,7961

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil eksperimen penelitian dan analisis yang dilakukan, berikut adalah kesimpulan yang didapatkan:

1. Implementasi model regresi berbasis arsitektur Transformer untuk memprediksi skor kepribadian Big Five dilakukan melalui modifikasi komponen *custom regression head*. Komponen ini menggunakan kombinasi lapisan linear berdimensi 512 neuron, fungsi aktivasi *non linear* GELU, dropout sebesar 30%, dan fungsi sigmoid untuk memetakan ekstraksi fitur visual menjadi rentang probabilitas regresi yang valid. Berdasarkan evaluasi terhadap enam varian model, konfigurasi ViT-B/16 AugReg (IN21k) yang dioptimalkan dengan skenario *arch tuning* beserta augmentasi menjadi model dengan kinerja terbaik. Model ini tidak hanya mampu mencapai tingkat presisi tertinggi dengan rata-rata akurasi puncak sebesar 0,911, tetapi juga mencapai nilai *coefficient of determination* (R^2) sebesar 0,416 pada data uji independen. Pencapaian metrik R^2 ini menunjukkan bahwa penambahan kompleksitas arsitektur dan variabilitas data berhasil mencegah *overfitting* sekaligus memungkinkan model menangkap keunikan representasi kepribadian individu.
2. Integrasi hasil prediksi regresi ke dalam LLM untuk menghasilkan interpretasi deskriptif dilakukan melalui sistem *prompt engineering* multimodal. *Prompt* dirancang menggunakan empat blok informasi utama: *system instruction* untuk menentukan batasan persona, *visual context* berupa citra dengan *encoding* Base64, *numerical context* (skor kepribadian Big Five), dan *task instruction*. Pengujian memberikan hasil bahwa penerapan gaya *roleplay prompting* sangat efektif dalam mentransformasi narasi LLM khususnya pada keluarga model Gemma 4 yang kaku dan analitis menjadi teks profil psikologis yang jauh lebih hangat, empatik, dan interaktif layaknya sebuah sesi konseling. Meskipun demikian, evaluasi *LLM-as-a-judge* menunjukkan bahwa instruksi *standard prompting* cenderung menghasilkan struktur laporan klinis yang lebih terstruktur poin per poin, yang membuat penilaian metrik evaluator G-Eval lebih tinggi dibandingkan *roleplay prompting*.
3. Kinerja sistem asesmen kepribadian hibrida secara keseluruhan menunjukkan kemampuan analisis yang menyeluruh dari tahap awal hingga akhir terlepas dari adanya keterbatasan pada modalitas visual. Pada tahap prediksi visual menggunakan model prediksi Transformer, sistem menunjukkan kinerja tertinggi dalam mengenali sifat *conscientiousness* dan *extraversion* yang terlihat kuat pada fitur fisik, namun mengalami tantangan pada sifat *agreeableness* yang bergantung pada interaksi sosial. Selanjutnya pada tahap interpretasi akhir (generasi teks), hasil G-Eval menunjukkan tidak adanya LLM yang mendominasi seluruh metrik penilaian. Oleh karena itu, sistem ini mengimplementasikan pendekatan dua model alternatif dengan menetapkan Qwen3-VL-32B-Instruct sebagai model utama karena meraih rata-rata keseluruhan tertinggi (0,9136) dengan narasi persona psikolog yang kaya dan Gemma-4-31B-IT sebagai alternatif dengan keunggulan model tersebut pada akurasi psikologis (0,9566) dan kepatuhan terhadap batasan token *output*.

5.2 Saran

Berdasarkan penelitian yang dilakukan, terdapat kekurangan atau potensi yang dapat dieksplorasi lebih lanjut untuk pengembangan selanjutnya antara lain:

1. Penelitian selanjutnya disarankan untuk mengadopsi modalitas data lain secara penuh, seperti integrasi analisis gerak spasio-temporal dari video dan analisis fitur suara. Penambahan modalitas ini diharapkan mampu mengatasi keterbatasan penggunaan gambar statis, khususnya dalam memprediksi sifat kepribadian yang sangat berkaitan dengan cara manusia berinteraksi dan berempati seperti *agreeableness*.
2. Diperlukan eksplorasi terkait *parameter tuning* tingkat lanjut pada fase inferensi LLM seperti penyesuaian *temperature*, *top-p*, atau *frequency penalty* untuk mengontrol panjang respons teks dengan lebih presisi. Hal ini diperlukan untuk mengatasi perilaku beberapa LLM yang terlalu elaboratif seperti Qwen3-VL sehingga rentan melanggar instruksi batasan kata dan menyebabkan hasil interpretasi terpotong secara paksa karena menyentuh batas maksimum token sistem.
3. Sistem evaluasi pada penelitian ini masih mengandalkan penilaian *LLM-as-a-judge* (G-Eval). Pada pengembangan berikutnya disarankan untuk melibatkan validasi kualitatif secara langsung dari psikolog profesional. Keterlibatan pakar psikologi akan sangat berguna untuk memverifikasi hasil interpretasi serta memastikan bahasa yang dihasilkan oleh sistem benar-benar selaras dengan kode etik pemberian hasil tes kepribadian.

DAFTAR PUSTAKA

- Abdulkadirov, R., Lyakhov, P., & Nagornov, N. (2023). Survey of Optimization Algorithms in Modern Neural Networks. *Mathematics*, 11, 2466. <https://doi.org/10.3390/math11112466>
- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M., & Farhan, L. (2021). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*, 8. <https://doi.org/10.1186/s40537-021-00444-8>
- American Psychological Association. (2018). Personality. Di dalam *APA Dictionary of Psychology*. Diakses November 15, 2025, dari <https://dictionary.apa.org/personality>
- Bai, J., Bai, S., Yang, S., Wang, S., Tan, S., Wang, P., Lin, J., Zhou, C., & Zhou, J. (2023). Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond. <http://arxiv.org/abs/2308.12966>
- Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., Ge, W., Guo, Z., Huang, Q., Huang, J., Huang, F., Hui, B., Jiang, S., Li, Z., Li, M., ... Zhu, K. (2025). Qwen3-VL Technical Report. <http://arxiv.org/abs/2511.21631>
- Bazarevsky, V., Kartynnik, Y., Vakunov, A., Raveendran, K., & Grundmann, M. (2019). BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs. <http://arxiv.org/abs/1907.05047>
- Bewley, A., Ge, Z., Ott, L., Ramos, F., & Upcroft, B. (2017). Simple Online and Realtime Tracking. <https://doi.org/10.1109/ICIP.2016.7533003>
- Bose, M., Aich, M., & Verma, V. (2023). An Investigation of Impact of Personality Traits using OCEAN as a Personality Test and Crypto Market Participation in Kolkata. *International Journal of Research Publication and Reviews*, 4, 2348–2354. <https://doi.org/10.55248/gengpi.4.923.92465>
- Brickman, J., Gupta, M., & Olthmanns, J. R. (2025). Large Language Models for Psychological Assessment: A Comprehensive Overview. *Advances in Methods and Practices in Psychological Science*, 8. <https://doi.org/10.1177/25152459251343582>
- Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? -Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7, 1247–1250. <https://doi.org/10.5194/gmd-7-1247-2014>
- Cheng, J., Kang, H., Shao, Y., Li, N., Chen, P., Wang, R., Long, S., Yang, X., & Ma, L. (2025). Survey on Efficient Large Language Models: Principles, Algorithms, Applications, and Open Issues. *IEEE Transactions on Neural Networks and Learning Systems*, 1–21. <https://doi.org/10.1109/TNNLS.2025.3628671>
- Chiang, C.-H., & Lee, H.-y. (2023). A Closer Look into Automatic Evaluation Using Large Language Models. <http://arxiv.org/abs/2310.05657>
- Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science*, 7, 1–24. <https://doi.org/10.7717/PEERJ-CS.623>
- Confident AI. (2025). *LLM Evaluation Metrics - DeepEval*. DeepEval. Diakses Januari 15, 2025, dari <https://deepeval.com/docs/metrics-llm-evals>

- Devi., T., Hameed Shnain, A., Alabdeli, H., Geetha Ramani, G., & Subhashini, K. (2024). An Effective Personality Prediction Using Bidirectional Encoder Representations from Transformers with AdamW Optimizer. *2024 International Conference on Integrated Intelligence and Communication Systems (ICIICS)*, 1–5. <https://doi.org/10.1109/ICIICS63763.2024.10859743>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. <http://arxiv.org/abs/2010.11929>
- El-Demerdash, K., El-Khoribi, R. A., Shoman, M. A. I., & Abdou, S. (2022, Maret). Deep learning based fusion strategies for personality prediction. <https://doi.org/10.1016/j.eij.2021.05.004>
- Feizi-Derakhshi, A.-R., Feizi-Derakhshi, M.-R., Ramezani, M., Nikzad-Khasmakhi, N., Asgari-Chenaghlu, M., Akan, T., Ranjbar-Khadivi, M., Zafarni-Moattar, E., & Jahanbakhsh-Naghadeh, Z. (2022). Text-based automatic personality prediction: A bibliographic review. <https://doi.org/10.1007/s42001-022-00178-4>
- Google. (2026). *Gemma 4 model overview*. Diakses Mei 18, 2026, dari <https://ai.google.dev/gemma/docs/core>
- Habib, F., Ali, Z., Azam, A., Kamran, K., & Pasha, F. M. (2024). Navigating pathways to automated personality prediction: a comparative study of small and medium language models. *Frontiers in Big Data*, 7. <https://doi.org/10.3389/fdata.2024.1387325>
- Han, K., Wang, Y., Chen, H., Chen, X., Guo, J., Liu, Z., Tang, Y., Xiao, A., Xu, C., Xu, Y., Yang, Z., Zhang, Y., & Tao, D. (2023). A Survey on Vision Transformer. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45, 87–110. <https://doi.org/10.1109/TPAMI.2022.3152247>
- Hilliard, A., Kazim, E., Bitsakis, T., & Leutner, F. (2022). Measuring Personality through Images: Validating a Forced-Choice Image-Based Assessment of the Big Five Personality Traits. *Journal of Intelligence*, 10. <https://doi.org/10.3390/jintelligence10010012>
- Ilmini, W., & Fernando, T. (2024). Detection and explanation of apparent personality using deep learning: a short review of current approaches and future directions. *Computing*, 106, 275–294. <https://doi.org/10.1007/s00607-023-01221-6>
- Jiang, H., Zhang, X., Cao, X., Breazeal, C., Roy, D., & Kabbara, J. (2024). PersonaLLM: Investigating the Ability of Large Language Models to Express Personality Traits. Di dalam K. Duh, H. Gomez, & S. Bethard (Tim penyunting), *Findings of the Association for Computational Linguistics: NAACL 2024* (hlm. 3605–3627). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.findings-naacl.229>
- Judd, T., Ehinger, K., Durand, F., & Torralba, A. (2009). Learning to predict where humans look. *2009 IEEE 12th International Conference on Computer Vision*, 2106–2113. <https://doi.org/10.1109/ICCV.2009.5459462>
- Khan, S., Naseer, M., Hayat, M., Zamir, S. W., Khan, F. S., & Shah, M. (2022). Transformers in Vision: A Survey. *ACM Computing Surveys*, 54. <https://doi.org/10.1145/3505244>
- Kong, A., Zhao, S., Chen, H., Li, Q., Qin, Y., Sun, R., Zhou, X., Wang, E., & Dong, X. (2024). Better Zero-Shot Reasoning with Role-Play Prompting. <http://arxiv.org/abs/2308.07702>
- Krishnamurthy, R., Hass, G. A., Natoli, A. P., Smith, B. L., Arbisi, P. A., & Gottfried, E. D. (2022). Professional Practice Guidelines for Personality Assessment. <https://doi.org/10.1080/00223891.2021.1942020>

- Li, D., Jiang, B., Huang, L., Beigi, A., Zhao, C., Tan, Z., Bhattacharjee, A., Jiang, Y., Chen, C., Wu, T., Shu, K., Cheng, L., & Liu, H. (2025). From Generation to Judgment: Opportunities and Challenges of LLM-as-a-judge. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, 2757–2791. <https://doi.org/10.18653/v1/2025.emnlp-main.138>
- Liu, T., Yuan, Z., Sun, J., Wang, J., Zheng, N., Tang, X., & Shum, H. Y. (2011). Learning to detect a salient object. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33, 353–367. <https://doi.org/10.1109/TPAMI.2010.70>
- Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C.-Y., & Berg, A. C. (2016). SSD: Single Shot MultiBox Detector. https://doi.org/10.1007/978-3-319-46448-0_2
- Liu, Y., Iter, D., Xu, Y., Wang, S., Xu, R., & Zhu, C. (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. <http://arxiv.org/abs/2303.16634>
- Liu, Z., Hu, H., Lin, Y., Yao, Z., Xie, Z., Wei, Y., Ning, J., Cao, Y., Zhang, Z., Dong, L., Wei, F., & Guo, B. (2022). Swin Transformer V2: Scaling Up Capacity and Resolution. <http://arxiv.org/abs/2111.09883>
- Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. <http://arxiv.org/abs/2103.14030>
- Mandakini, C. (2023). Prediction of Personality Traits and Suitable Job through an Intelligent Interview Agent using Machine Learning. *Journal of Computer Science and Applications*, 15, 21–31. <https://doi.org/10.37624/jcsa/15.1.2023.21-31>
- Naz, A., Khan, H. U., Bukhari, A., Alshemaimri, B., Daud, A., & Ramzan, M. (2025). Machine and deep learning for personality traits detection: a comprehensive survey and open research challenges. *Artificial Intelligence Review*, 58. <https://doi.org/10.1007/s10462-025-11245-3>
- Papa, L., Russo, P., Amerini, I., & Zhou, L. (2024). A Survey on Efficient Vision Transformers: Algorithms, Techniques, and Performance Benchmarking. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46, 7682–7700. <https://doi.org/10.1109/TPAMI.2024.3392941>
- Pereira, J., Assumpcao, A., & Lotufo, R. (2024). Check-Eval: A Checklist-based Approach for Evaluating Text Quality. <http://arxiv.org/abs/2407.14467>
- Phan, L. V., & Rauthmann, J. F. (2021). Personality computing: New frontiers in personality assessment. *Social and Personality Psychology Compass*, 15. <https://doi.org/10.1111/spc3.12624>
- Plevris, V., Solorzano, G., Bakas, N. P., Amine, M. E., & Seghier, B. (2022). *INVESTIGATION OF PERFORMANCE METRICS IN REGRESSION ANALYSIS AND MACHINE LEARNING-BASED PREDICTION MODELS* (lap. teknis).
- Ponce-López, V., Chen, B., Oliu, M., Corneanu, C., Clapés, A., Guyon, I., Baró, X., Escalante, H. J., & Escalera, S. (2016). ChaLearn LAP 2016: First Round Challenge on First Impressions - Dataset and Results. Di dalam G. Hua & H. Jégou (Tim penyunting). Springer International Publishing. https://doi.org/10.1007/978-3-319-49409-8_32
- Prasad, P. K., Abburi, N. S. A. K., Cherukuri, P. S. G., Bhattu, D. K., & Gadde, J. (2024). Unveiling Personality Traits through Social Media Language Analysis: A Novel Approach using Language Models. *IJARCCCE*, 13. <https://doi.org/10.17148/ijarccce.2024.13326>
- Sarker, I. H. (2021). Deep Learning: A Comprehensive Overview on Techniques, Taxonomy, Applications and Research Directions. *SN Computer Science*, 2, 420. <https://doi.org/10.1007/s42979-021-00815-1>

- Sharma, P., Sagvekar, V., Alone, V. N., Krishna, P. V., Thulasimani, T., & Sethumadhavan, R. (2023). A Systematic Approach for the Prediction of Personality Based on Attention Enhanced GCNN and LSTM Approach. *Proceedings of the 2nd International Conference on Edge Computing and Applications, ICECAA 2023*, 544–549. <https://doi.org/10.1109/ICECAA58104.2023.10212146>
- Shui, X., Chen, Y., Hu, X., Wang, F., & Zhang, D. (2023). Personality in Daily Life: Multi-Situational Physiological Signals Reflect Big-Five Personality Traits. *IEEE Journal of Biomedical and Health Informatics*, 27, 2853–2863. <https://doi.org/10.1109/JBHI.2023.3253820>
- Suman, C., Saha, S., Gupta, A., Pandey, S. K., & Bhattacharyya, P. (2022). A multi-modal personality prediction system. *Knowledge-Based Systems*, 236. <https://doi.org/10.1016/j.knosys.2021.107715>
- Tavakol, M., & Dennick, R. (2021). What Does Different Personality Test and Behavioral Test Measure? and Do We Overuse Them? *Journal of Psychology and Neuroscience*, 2, 53–55. <https://doi.org/10.47485/2693-2490.1047>
- Taye, M. M. (2023). Understanding of Machine Learning with Deep Learning: Architectures, Workflow, Applications and Future Directions. *Computers*, 12, 91. <https://doi.org/10.3390/computers12050091>
- Team, G., Kamath, A., Ferret, J., Pathak, S., Vieillard, N., Merhej, R., Perrin, S., Matejovicova, T., Ramé, A., Rivière, M., Rouillard, L., Mesnard, T., Cideron, G., Grill, J.-b., Ramos, S., Yvinec, E., Casbon, M., Pot, E., Penchev, I., ... Hussenot, L. (2025). Gemma 3 Technical Report. <http://arxiv.org/abs/2503.19786>
- Team, G., Mesnard, T., Hardin, C., Dadashi, R., Bhupatiraju, S., Pathak, S., Sifre, L., Rivière, M., Kale, M. S., Love, J., Tafti, P., Hussenot, L., Sessa, P. G., Chowdhery, A., Roberts, A., Barua, A., Botev, A., Castro-Ros, A., Slone, A., ... Kenealy, K. (2024). Gemma: Open Models Based on Gemini Research and Technology. <http://arxiv.org/abs/2403.08295>
- Thisanke, H., Deshan, C., Chamith, K., Seneviratne, S., Vidanaarachchi, R., & Herath, D. (2023). Semantic Segmentation using Vision Transformers: A survey. <http://arxiv.org/abs/2305.03273>
- Tseng, Y.-M., Huang, Y.-C., Hsiao, T.-Y., Chen, W.-L., Huang, C.-W., Meng, Y., & Chen, Y.-N. (2024). Two Tales of Persona in LLMs: A Survey of Role-Playing and Personalization. <http://arxiv.org/abs/2406.01171>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). Attention Is All You Need. <http://arxiv.org/abs/1706.03762>
- Velásquez-Henao, J. D., Franco-Cardona, C. J., & Cadavid-Higuaita, L. (2023). Prompt Engineering: a methodology for optimizing interactions with AI-Language Models in the field of engineering. *DYNA (Colombia)*, 90, 9–17. <https://doi.org/10.15446/dyna.v90n230.111700>
- Wang, P., Bai, S., Tan, S., Wang, S., Fan, Z., Bai, J., Chen, K., Liu, X., Wang, J., Ge, W., Fan, Y., Dang, K., Du, M., Ren, X., Men, R., Liu, D., Zhou, C., Zhou, J., & Lin, J. (2024). Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution. <http://arxiv.org/abs/2409.12191>
- Wang, W., Xie, E., Li, X., Fan, D.-P., Song, K., Liang, D., Lu, T., Luo, P., & Shao, L. (2021). Pyramid Vision Transformer: A Versatile Backbone for Dense Prediction without Convolutions. <http://arxiv.org/abs/2102.12122>

- Wang, W., Xie, E., Li, X., Fan, D.-P., Song, K., Liang, D., Lu, T., Luo, P., & Shao, L. (2023). PVT v2: Improved Baselines with Pyramid Vision Transformer. <https://doi.org/10.1007/s41095-022-0274-8>
- Wang, Y., Deng, Y., Zheng, Y., Chattopadhyay, P., & Wang, L. (2025, Januari). Vision Transformers for Image Classification: A Comparative Survey. <https://doi.org/10.3390/technologies13010032>
- Zell, E., & Lesick, T. L. (2022). Big five personality traits and performance: A quantitative synthesis of 50+ meta-analyses. *Journal of Personality*, 90, 559–573. <https://doi.org/10.1111/jopy.12683>
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., ... Wen, J.-R. (2025). A Survey of Large Language Models. <http://arxiv.org/abs/2303.18223>

Halaman ini sengaja dikosongkan

BIOGRAFI PENULIS



Penulis dilahirkan di Gresik, 1 Desember 2004, merupakan anak pertama dari dua bersaudara. Penulis menempuh pendidikan formal di SD Muhammadiyah 8-10 Banjarmasin, SMPN 2 Banjarmasin, dan SMAN Banua Kalsel. Setelah lulus dari SMA pada tahun 2022, penulis diterima di Departemen Teknik Informatika, Fakultas Teknologi Elektro dan Informatika Cerdas (FTEIC), Institut Teknologi Sepuluh Nopember (ITS) melalui jalur SBMPTN dan terdaftar dengan NRP 50252211193.

Selama menjalani studi di Departemen Teknik Informatika, penulis aktif dalam berbagai kegiatan di antaranya mengikuti beberapa lomba karya tulis ilmiah, tutor OSN Informatika tingkat SMA, dan berpartisipasi dalam kegiatan kepanitiaan baik dalam lingkup institut maupun forum daerah penulis.